

**OPTIMASI MOBILENETV2 MENGGUNAKAN STRATEGI
FINE-TUNING UNTUK KLASIFIKASI KESEGARAN IKAN
BERBASIS CITRA DIGITAL**



UMN
UNIVERSITAS
MULTIMEDIA
NUSANTARA

SKRIPSI

JUSTIN STEPHEN

00000072126

**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS TEKNIK DAN INFORMATIKA
UNIVERSITAS MULTIMEDIA NUSANTARA
TANGERANG**

2026

**OPTIMASI MOBILENETV2 MENGGUNAKAN STRATEGI
FINE-TUNING UNTUK KLASIFIKASI KESEGARAN IKAN
BERBASIS CITRA DIGITAL**



SKRIPSI

Diajukan sebagai Salah Satu Syarat untuk Memperoleh

Gelar Sarjana Komputer (S.KOM)

JUSTIN STEPHEN

00000072126

**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS TEKNIK DAN INFORMATIKA
UNIVERSITAS MULTIMEDIA NUSANTARA
TANGERANG**

2026

HALAMAN PERNYATAAN TIDAK PLAGIAT

Dengan ini saya,

Nama : Justin Stephen
Nomor Induk Mahasiswa : 00000072126
Program Studi : Sistem Informasi

Skripsi dengan judul:

“OPTIMASI MOBILENETV2 MENGGUNAKAN STRATEGI *FINE-TUNING*
UNTUK KLASIFIKASI KESEGARAN IKAN BERBASIS CITRA DIGITAL”

Merupakan hasil karya saya sendiri bukan plagiat dari laporan karya tulis ilmiah yang ditulis oleh orang lain, dan semua sumber, baik yang dikutip maupun dirujuk, telah saya nyatakan dengan benar serta dicantumkan di Daftar Pustaka.

Jika di kemudian hari terbukti ditemukan kecurangan/penyimpangan, baik dalam pelaksanaan maupun dalam penulisan laporan karya tulis ilmiah, saya bersedia menerima konsekuensi dinyatakan TIDAK LULUS untuk mata kuliah yang telah saya tempuh.

Tangerang, 20 Maret 2026



(Justin Stephen)

UMN
UNIVERSITAS
MULTIMEDIA
NUSANTARA

LEMBAR PERNYATAAN PENGGUNAAN BANTUAN KECERDASAN ARTIFISIAL (AI)

Saya yang bertanda tangan di bawah ini:

Nama Lengkap : Justin Stephen
NIM : 00000072126
Program Studi : Sistem Informasi
Judul Skripsi : Optimasi MobileNetV2 Menggunakan Strategi
Fine-tuning untuk Klasifikasi Kesegaran Ikan Berbasis Citra Digital

Dengan ini saya menyatakan secara jujur menggunakan bantuan Kecerdasan Artifisial (AI) dalam pengerjaan Tugas/Project/Tugas Akhir sebagai berikut (beri tanda centang yang sesuai):

- ☒ Menggunakan AI sebagaimana diizinkan untuk membantu dalam menghasilkan ide-ide utama saja
- ☒ Menggunakan AI sebagaimana diizinkan untuk membantu menghasilkan teks pertama saja
- ☒ Menggunakan AI untuk menyempurnakan sintaksis dan tata bahasa untuk pengumpulan tugas
- ☐ Karena tidak diizinkan: Tidak menggunakan bantuan AI dengan cara apa pun dalam pembuatan tugas

Saya juga menyatakan bahwa:

- (1) Menyerahkan secara lengkap dan jujur penggunaan perangkat AI yang diperlukan dalam tugas melalui Formulir Penggunaan Perangkat Kecerdasan Artifisial (AI)
- (2) Saya mengakui bahwa saya telah menggunakan bantuan AI dalam tugas saya baik dalam bentuk kata, paraphrase, penyertaan ide atau fakta penting yang disarankan oleh AI dan saya telah menyantumkan dalam sitasi serta referensi

Terlepas dari pernyataan di atas, tugas ini sepenuhnya merupakan karya saya sendiri

Tangerang, 20 Maret 2026

Yang Menyatakan,



(Justin Stephen)

HALAMAN PERSETUJUAN

Skripsi dengan judul
Optimasi MobileNetV2 Menggunakan Strategi *Fine-tuning* untuk Klasifikasi
Kesegaran Ikan Berbasis Citra Digital
Oleh

Nama : Justin Stephen
NIM : 00000072126
Program Studi : Sistem Informasi
Fakultas : Teknik & Informasi

Telah disetujui untuk diajukan pada
Sidang Ujian Skripsi Universitas Multimedia Nusantara
Tangerang, 4 Juni 2026

Pembimbing

Ketua Program Studi Sistem Informasi

04/06/2026



Monika Evelin Johan,
S.Kom.,M.M.S.I
032705950



05.06.2026

Ririn Han Desanti, S.Kom., M.Kom.
313058001

HALAMAN PERSETUJUAN PUBLIKASI KARYA ILMIAH

Yang bertanda tangan di bawah ini:

Nama : Justin Stephen

NIM : 00000072126

Program Studi : Sistem Informasi


Jenjang : S1

Judul Karya Ilmiah : Optimasi MobileNetV2 Menggunakan Strategi *Fine-tuning* untuk Klasifikasi Kesegaran Ikan Berbasis Citra Digital

Menyatakan dengan sesungguhnya bahwa saya bersedia:

- ☒ Saya bersedia memberikan izin sepenuhnya kepada Universitas Multimedia Nusantara untuk mempublikasikan hasil karya ilmiah saya ke dalam repositori Knowledge Center sehingga dapat diakses oleh Sivitas Akademika UMN/Publik. Saya menyatakan bahwa karya ilmiah yang saya buat tidak mengandung data yang bersifat konfidensial.
- ☐ Saya tidak bersedia mempublikasikan hasil karya ilmiah ini ke dalam repositori Knowledge Center, dikarenakan: dalam proses pengajuan publikasi ke jurnal/konferensi nasional/internasional (dibuktikan dengan *letter of acceptance*).
- ☐ Lainnya, pilih salah satu:
 - ☒ Hanya dapat diakses secara internal Universitas Multimedia Nusantara
 - ☐ Embargo publikasi karya ilmiah dalam kurun waktu 3 tahun.

Tangerang, 4 Juni 2026

()

KATA PENGANTAR

Puji dan syukur penulis panjatkan kepada Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga penulis dapat menyelesaikan Tugas Akhir yang berjudul “Optimasi MobileNetV2 Menggunakan Strategi *Fine-tuning* untuk Klasifikasi Kesegaran Ikan Berbasis Citra Digital” dengan baik dan tepat pada waktunya.

Penyusunan Tugas Akhir ini dilakukan sebagai salah satu syarat untuk memperoleh gelar Sarjana Sistem Informasi pada Program Studi Sistem Informasi, Fakultas Teknik dan Informatika, Universitas Multimedia Nusantara.


Mengucapkan terima kasih

1. Dr. Ir. Andrey Andoko, M.Sc., selaku Rektor Universitas Multimedia Nusantara.
2. Dr. Eng. Niki Prastomo, S.T., M.Sc., selaku Dekan Fakultas Teknik dan Informatika Universitas Multimedia Nusantara.
3. Ririn Ikana Desanti, S.Kom., M.Kom., selaku Ketua Program Studi Sistem Informasi Universitas Multimedia Nusantara.
4. Monika Evelin Johan, S.Kom., M.M.S.I., sebagai Pembimbing pertama yang telah memberikan bimbingan, arahan, dan motivasi atas terselesainya tugas akhir ini.
5. Keluarga saya yang telah memberikan bantuan dukungan material dan moral, sehingga penulis dapat menyelesaikan tugas akhir ini.
6. Rekan di kampus, rekan magang serta orang-orang terdekat yang telah memberikan masukan, dukungan serta informasi yang mendukung sehingga penulis dapat menyelesaikan laporan Skripsi ini.


Penulis menyadari bahwa Tugas Akhir ini masih memiliki kekurangan. Oleh karena itu, penulis terbuka terhadap kritik dan saran yang membangun demi perbaikan di masa mendatang. Akhir kata, penulis berharap karya ilmiah ini dapat memberikan kontribusi secara teoritis maupun praktis, khususnya dalam pengembangan ilmu

pengetahuan di bidang Sistem Informasi, serta dapat menjadi referensi bagi penelitian selanjutnya.

Tangerang, 20 Maret 2026



(Justin Stephen)



UMN
UNIVERSITAS
MULTIMEDIA
NUSANTARA

OPTIMASI MOBILENETV2 MENGGUNAKAN STRATEGI *FINE-TUNING* UNTUK KLASIFIKASI KESEGERAN IKAN BERBASIS CITRA DIGITAL

(Justin Stephen)

ABSTRAK

Penelitian ini bertujuan untuk mengembangkan model klasifikasi tingkat kesegaran ikan berbasis citra mata ikan menggunakan arsitektur MobileNetV2. Permasalahan utama dalam penentuan kesegaran ikan secara visual adalah kemiripan karakteristik antar kelas serta subjektivitas penilaian manual. Oleh karena itu, penelitian ini menerapkan metode Convolutional Neural Network (CNN) dengan pendekatan *transfer learning* dan *fine-tuning* pada MobileNetV2 untuk meningkatkan kemampuan ekstraksi fitur visual. Tahapan penelitian dilakukan menggunakan metode Knowledge Discovery in Databases (KDD), yang meliputi seleksi data, preprocessing, augmentasi citra, pelatihan model, dan evaluasi performa. Hasil penelitian menunjukkan bahwa penerapan *fine-tuning* berhasil meningkatkan *validation accuracy* dari 60,14% menjadi 69,48% serta menurunkan *validation loss* dari sekitar 0,86 menjadi sekitar 0,75 dibandingkan tahap transfer learning. Model akhir juga mencapai *accuracy* sebesar 69,70%, *precision* sebesar 69,01%, *recall* sebesar 68,92%, dan F1-score sebesar 68,87% dengan jumlah parameter sekitar 2,59 juta. Meskipun model masih memiliki keterbatasan dalam membedakan kelas dengan kemiripan visual tinggi, *fine-tuning* terbukti meningkatkan performa klasifikasi dan efisiensi model secara keseluruhan.

Kata kunci: augmentasi citra, *fine-tuning*, klasifikasi kesegaran ikan, MobileNetV2, transfer learning

UIN
UNIVERSITAS
MULTIMEDIA
NUSANTARA

OPTIMIZATION OF MOBILENETV2 USING A FINE-TUNING STRATEGY FOR DIGITAL IMAGE-BASED FISH FRESHNESS

CLASSIFICATION

(Justin Stephen)

ABSTRACT (English)

This study aims to develop a fish freshness classification model based on fisheye images using the MobileNetV2 architecture. The main challenge in visually determining fish freshness is the similarity of visual characteristics between classes and the subjectivity of manual assessment. Therefore, this study applies a Convolutional Neural Network (CNN) method using transfer learning and fine-tuning approaches on MobileNetV2 to improve visual feature extraction capability. The research stages follow the Knowledge Discovery in Databases (KDD) method, including data selection, preprocessing, image augmentation, model training, and performance evaluation. The results show that the fine-tuning approach successfully improved validation accuracy from 60.14% to 69.48% and reduced validation loss from approximately 0.86 to 0.75 compared to the transfer learning stage. The final model achieved an accuracy of 69.70%, precision of 69.01%, recall of 68.92%, and F1-score of 68.87% with approximately 2.59 million parameters. Although the model still has limitations in distinguishing classes with highly similar visual characteristics, fine-tuning proved effective in improving overall classification performance and model efficiency.

Keywords: fine-tuning, fish freshness classification, image augmentation, MobileNetV2, transfer learning

DAFTAR ISI

HALAMAN PERNYATAAN TIDAK PLAGIAT	ii
HALAMAN PERSETUJUAN.....	iv
KATA PENGANTAR.....	vi
ABSTRAK	viii
<i>ABSTRACT (English)</i>	ix
DAFTAR ISI.....	x
DAFTAR TABEL.....	xiii
DAFTAR GAMBAR.....	xiv
DAFTAR LAMPIRAN	xv
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Masalah.....	3
1.4 Tujuan dan Manfaat Penelitian	5
1.4.1 Tujuan Penelitian.....	5
1.4.2 Manfaat Penelitian.....	5
1.5 Sistematika Penulisan	6
BAB II LANDASAN TEORI	7
2.1 Penelitian Terdahulu	7
2.2 Teori yang berkaitan.....	17
2.2.1 Ikan sebagai Komoditas Pangan.....	17
2.2.2 Kesegaran Ikan.....	17
2.2.3 Representasi Visual Kesegaran dalam Citra Digital	18
2.2.4 Klasifikasi Kesegaran Ikan	19
2.2.5 Computer Vision	20
2.2.6 <i>Deep Learning</i>	20
2.2.7 Evaluasi Objektif dalam Penilaian Mutu Ikan	21
2.2.8 Grad-CAM (Gradient-weighted Class Activation Mapping)	21
2.3 Framework dan Algoritma yang digunakan	22
2.3.1 Knowledge Discovery in Databases (KDD)	22
2.3.2 Algoritma yang Digunakan.....	26
2.4 Tools/software yang digunakan	34
2.4.1 Jupyter Notebook.....	35

2.4.2 Google Scholar	35
2.4.3 Publish or Perish	36
BAB III METODOLOGI PENELITIAN	37
3.1 Gambaran Umum Objek Penelitian.....	37
3.2 Metode Penelitian	38
3.2.1 Selection	41
3.2.2 Pre-processing	41
3.2.3 Transformation	42
3.2.4 Data Mining.....	42
3.2.5 Evaluation / Interpretation	43
3.3 Teknik Pengumpulan Data	44
3.3.1 Analisis Populasi dan Sampel	46
3.3.2 Data Sebelum Pemrosesan	47
3.4 Variabel Penelitian	49
3.4.1 Variabel Independen (Variabel Bebas).....	50
3.4.2 Variabel Dependen (Variabel Terikat)	50
3.4.3 Variabel Kontrol	50
3.5 Teknik Analisis Data	51
3.5.1 Analisis dan Pemodelan <i>Deep Learning</i>	52
3.5.2 Teknik Evaluasi dan Validasi Model	53
3.5.3 Evaluasi Interpretabilitas Menggunakan Grad-CAM.....	54
BAB IV ANALISIS DAN HASIL PENELITIAN	55
4.1 Selection	55
4.2 Preprocessing (Prapemrosesan dan Kesiapan Data)	58
4.2.4 Data Cleaning (Validasi dan Penghapusan File Corrupt)	59
4.2.1 Resize (Penyeragaman Ukuran Citra).....	61
4.2.2 Konversi ke Format RGB	62
4.2.3 Normalisasi Nilai Piksel.....	63
4.3 Transformation (Transformasi Data dan Kesiapan untuk Training MobileNetV2).....	67
4.3.1 Data Labelling (Integer Encoding).....	67
4.3.2 Data Augmentation	69
4.3.3 Data Splitting.....	72
4.4 Data Modelling (Pemodelan, Transfer Learning, dan <i>Fine-tuning</i> MobileNetV2).....	74

4.4.1 Arsitektur MobileNetV2 sebagai Base Model.....	74
4.4.2 Pelatihan Model Menggunakan Transfer Learning.....	76
4.4.3 Hasil Skenario 1: Transfer Learning (Tanpa <i>Fine-tuning</i>)	79
4.4.4 Hasil Skenario 2: <i>Fine-tuning</i> MobileNetV2	83
4.4.5 Explainable AI (Grad-CAM).....	89
4.5 Analisis Hasil dan Diskusi	95
4.5.1 Ringkasan Hasil Evaluasi Performa MobileNetV2	95
4.5.2 Analisis Confusion Matrix dan Pola Kesalahan	98
4.5.4 Diskusi Efisiensi Parameter dan Kompleksitas Model	105
4.5.5 Diskusi Interpretabilitas Model Menggunakan Grad-CAM.....	107
4.5.6 Diskusi Perbandingan Hasil Penelitian dengan Penelitian Terdahulu	109
BAB V SIMPULAN DAN SARAN.....	112
5.1 Simpulan.....	112
5.2 Saran.....	113
DAFTAR PUSTAKA.....	115
LAMPIRAN.....	122

DAFTAR TABEL

Table 2.1 Penelitian Terdahulu	7
Table 2. 2 Pseudocode CNN	27
Table 2.3 Perbandingan MobileNetV2 dengan Arsitektur Deep Learning Modern	32
Tabel 4.1 Hasil Validasi dan Pembersihan Dataset	59
Tabel 4.2 Perubahan Nilai Pixel Sebelum dan Sesudah Normalisasi.....	66
Tabel 4.3 Parameter Data Augmentation	69
Tabel 4.4 Distribusi Jumlah Data per Kelas pada Setiap Subset	73
Tabel 4.5 Arsitektur Model MobileNetV2.....	75
Tabel 4.6 Konfigurasi Pelatihan Model	77
Tabel 4.7 Detail Konfigurasi Training	78
Tabel 4.8 Ringkasan Hasil Pelatihan Transfer Learning	82
Tabel 4.9 Ringkasan Hasil Pelatihan Fine-tuning.....	87
Tabel 4.10 Perbandingan Performa Transfer Learning dan Fine-tuning	87
Tabel 4.11 Analisis Confusion Matrix Transfer Learning	100
Tabel 4.12 Analisis Confusion Matrix Fine-tuning	101
Tabel 4.13 Perbandingan Kompleksitas Model	105

DAFTAR GAMBAR

Gambar 2.1 Knowledge Discovery in Database Process (KDD) [43]	23
Gambar 2.2 Arsitektur MobileNetV2.....	31
Gambar 3.1 Tingkat Kesegaran Mata Ikan	37
Gambar 3.2 lima fase utama dalam framework KDD.....	40
Gambar 3.3 Isi Folder Dataset [71].....	44
Gambar 4.1 Folder Kelas yang Digunakan	56
Gambar 4.2 Distribusi Kelas Dataset	57
Gambar 4.3 Distribusi Jumlah Citra Spesies Ikan	58
Gambar 4.4 Distribusi File Bermasalah pada Tahap Data Cleaning	60
Gambar 4.5 Output Shape Batch Data Sebelum dan Setelah Resize	61
Gambar 4.6 Visualisasi Citra dalam Format RGB.....	62
Gambar 4.7 Perbandingan Citra Sebelum dan Sesudah Normalisasi	63
Gambar 4.8 Histogram Distribusi Nilai Piksel	64
Gambar 4.9 Mapping Piksel Sebelum vs Sesudah.....	65
Gambar 4.10 Hasil Encoding Label	67
Gambar 4.11 Label Batch Shuffled.....	67
Gambar 4.12 Informasi Kelas Dataset	68
Gambar 4.13 menunjukkan hasil augmentasi dengan perubahan visual yang relatif ringan, yaitu horizontal flip, rotation, dan zoom.....	70
Gambar 4. 14 menunjukkan hasil augmentasi dengan perubahan visual yang lebih besar, yaitu brightness adjustment dan combined augmentation.	71
Gambar 4.15 Komposisi Kelas pada Setiap Subset	73
Gambar 4.16 Grafik Akurasi vs Epoch Transfer Learning.....	79
Gambar 4.17 Grafik Loss vs Epoch Transfer Learning	80
Gambar 4.18 Grafik Learning Rate Schedule Transfer Learning.....	81
Gambar 4.19 Grafik Analysis Transfer Learning	82
Gambar 4.20 Grafik Accuracy vs Epoch Fine-tuning.....	83
Gambar 4.21 Grafik Loss vs Epoch Fine-tuning	84
Gambar 4.22 Grafik Learning Rate Schedule Fine-tuning	85
Gambar 4.23 Grafik Analysis Fine-tuning.....	86
Gambar 4.24 Grad-CAM pada Kelas HighlyFresh (Prediksi Benar)	89
Gambar 4.25 Grad-CAM pada Kelas NotFresh (Prediksi Benar).....	90
Gambar 4.26 Grad-CAM pada Kelas Fresh (Prediksi Benar).....	91
Gambar 4.27 Grad-CAM pada Kasus Fresh Misclassification.....	92
Gambar 4.28 Grad-CAM pada Kasus Fresh Misclassification.....	92
Gambar 4.29 Grad-CAM pada Kasus Fresh Misclassification.....	93
Gambar 4.30 Performa Model pada Data Uji	95
Gambar 4.31 Confusion Matrix	98

DAFTAR LAMPIRAN

Lampiran A Nama Lampiran	122
--------------------------------	-----



UMN

UNIVERSITAS
MULTIMEDIA
NUSANTARA

BAB I

PENDAHULUAN

1.1 Latar Belakang

Indonesia merupakan negara maritim dengan potensi sumber daya perikanan yang melimpah, sehingga sektor perikanan memiliki peran strategis dalam mendukung ketahanan pangan dan perekonomian nasional [1]. Ikan sebagai salah satu sumber protein utama memiliki nilai ekonomi yang tinggi serta tingkat konsumsi yang terus meningkat. Oleh karena itu, kualitas ikan menjadi aspek yang krusial, pada mana tingkat kesegaran dijadikan sebagai indikator utama dalam menentukan kelayakan konsumsi dan nilai jual produk perikanan [2][3].

Dalam praktiknya, penilaian kesegaran ikan di lapangan masih banyak dilakukan secara manual melalui pengamatan visual terhadap kondisi insang, tekstur tubuh, serta kejernihan mata ikan [3]. Metode tersebut bersifat subjektif karena sangat bergantung pada pengalaman individu, sehingga penilaian yang dihasilkan berpotensi tidak konsisten. Ketidakkonsistenan tersebut dapat meningkatkan risiko kesalahan dalam klasifikasi kualitas ikan, yang pada akhirnya berdampak pada distribusi produk yang kurang optimal serta potensi kerugian ekonomi [4][5].

Untuk mengatasi keterbatasan metode konvensional, pendekatan berbasis *deep learning*, khususnya Convolutional Neural Network (CNN), telah banyak diterapkan dalam berbagai penelitian klasifikasi citra. CNN mampu mengekstraksi fitur visual secara otomatis tanpa memerlukan perancangan fitur secara manual, serta dapat menangkap pola spasial dan tekstur secara hierarkis [6][7]. Dengan kemampuan tersebut, proses klasifikasi kesegaran ikan dapat dilakukan secara lebih objektif dan konsisten.

Beberapa penelitian sebelumnya telah menerapkan arsitektur CNN untuk klasifikasi kesegaran ikan. Penelitian oleh Zhang et al menggunakan arsitektur MobileNetV1 dengan pendekatan MB-BE dan menghasilkan akurasi sebesar 63,21%. Di sisi lain, arsitektur yang lebih kompleks seperti ResNet50 mampu mencapai akurasi yang lebih tinggi, yaitu sekitar 84,86%, namun memiliki jumlah parameter yang jauh lebih besar sehingga membutuhkan sumber daya komputasi

yang lebih tinggi [8]. Selain kedua arsitektur tersebut, perkembangan deep learning juga menghasilkan model yang lebih modern seperti EfficientNetV2, ConvNeXt, dan Vision Transformer (ViT) yang menunjukkan performa tinggi pada berbagai tugas klasifikasi citra. Namun, model-model tersebut umumnya memiliki kompleksitas yang lebih besar dibandingkan MobileNetV2.[8][9].

Berdasarkan penelitian-penelitian tersebut, dapat diidentifikasi adanya trade-off antara performa klasifikasi dan efisiensi model. Model dengan parameter kecil memiliki efisiensi yang baik namun performanya masih terbatas, sedangkan model dengan akurasi tinggi cenderung memiliki kompleksitas yang besar [10]. Oleh karena itu, maka diperlukan pendekatan yang mampu menghasilkan performa klasifikasi yang optimal sekaligus tetap efisien secara komputasi.

Selain trade-off tersebut, pengembangan model CNN juga menghadapi tantangan lain, yaitu keterbatasan jumlah data serta kebutuhan komputasi yang tinggi. Pada kondisi dataset yang terbatas, pelatihan model secara langsung dari awal (training from scratch) berisiko menghasilkan performa yang kurang optimal serta cenderung mengalami *overfitting* [11]. Selain itu, proses pelatihan membutuhkan waktu yang lebih lama untuk mencapai konvergensi.

Untuk mengatasi permasalahan tersebut, pendekatan *transfer learning* banyak digunakan dengan memanfaatkan bobot prelatih dari dataset berskala besar seperti ImageNet. Selain itu, strategi *fine-tuning* dapat diterapkan untuk menyesuaikan sebagian lapisan model agar lebih adaptif terhadap karakteristik domain data. Dalam penelitian ini, arsitektur MobileNetV2 digunakan karena merupakan pengembangan dari MobileNetV1 yang dirancang untuk meningkatkan efisiensi serta kualitas representasi fitur [7][12]. MobileNetV2 memiliki jumlah parameter yang relatif kecil namun tetap mampu memberikan performa klasifikasi yang kompetitif.

Berdasarkan permasalahan dan gap yang telah diidentifikasi, penelitian ini dilakukan untuk mengembangkan dan mengoptimasi model klasifikasi kesegaran ikan berbasis citra mata ikan menggunakan arsitektur MobileNetV2 dengan pendekatan *transfer learning* dan *fine-tuning* [13]. Model yang dihasilkan diharapkan mampu memberikan akurasi prediksi yang tinggi, efisien secara

komputasi, serta dapat digunakan sebagai solusi yang lebih objektif dalam proses penilaian kesegaran ikan.

1.2 Rumusan Masalah

Di bawah ini adalah rumusan masalah penelitian ini berdasarkan latar belakang yang telah diuraikan:

1. Bagaimana mengembangkan model klasifikasi kesegaran ikan berbasis citra digital menggunakan Convolutional Neural Network (CNN) dengan arsitektur MobileNetV2?
2. Bagaimana menerapkan strategi optimasi, khususnya *fine-tuning*, pada model CNN dengan arsitektur MobileNetV2 untuk meningkatkan kinerja klasifikasi?
3. Bagaimana performa model klasifikasi kesegaran ikan berbasis MobileNetV2 yang telah dioptimasi berdasarkan metrik evaluasi seperti akurasi, presisi, recall, dan F1-score?

1.3 Batasan Masalah

Penelitian ini berfokus pada pengembangan dan pengujian model klasifikasi kesegaran ikan berbasis citra digital menggunakan pendekatan Convolutional Neural Network (CNN) dengan arsitektur MobileNetV2. Agar penelitian tetap terarah dan sesuai dengan ruang lingkup skripsi, maka ditetapkan batasan masalah sebagai berikut:

1. Sumber dan Karakteristik Data Citra Penelitian ini menggunakan dataset citra ikan publik yang tersedia secara terbuka pada platform berbagi dataset atau repositori penelitian. Dataset tersebut berisi gambar ikan dengan label tingkat kesegaran yang telah ditentukan [14]. Variasi kondisi pengambilan gambar seperti perbedaan latar belakang, sudut pengambilan gambar, dan intensitas pencahayaan mengikuti kondisi pada dataset yang tersedia. Penelitian ini tidak melakukan pengambilan data secara mandiri, serta mengatasi variasi data melalui tahap preprocessing dan augmentasi citra [15].

- 2 Jumlah dan Distribusi Data Dataset yang digunakan memiliki jumlah data yang terbatas dan berpotensi mengalami ketidakseimbangan distribusi kelas antara ikan segar dan tidak segar. Untuk mengurangi dampak ketidakseimbangan kelas, penelitian ini menerapkan teknik augmentasi data seperti rotasi, flipping, dan penyesuaian intensitas cahaya guna meningkatkan variasi data latih.
- 3 Jenis Ikan yang Digunakan Dataset publik yang digunakan tidak mencakup seluruh jenis ikan yang ada di Indonesia. Oleh karena itu, penelitian ini dibatasi pada jenis ikan yang tersedia dalam dataset. Model yang dihasilkan belum tentu dapat digeneralisasikan pada seluruh jenis ikan di luar data penelitian.
- 4 Metode dan Arsitektur Model Penelitian ini menggunakan pendekatan *deep learning* berbasis CNN dengan arsitektur MobileNetV2 serta strategi *fine-tuning* dan *transfer learning* [16]. Sebagai pembanding, digunakan model CNN sederhana (baseline). Arsitektur lain seperti *ResNet* atau *EfficientNet* tidak dibahas dalam penelitian ini [17].
- 5 Lingkungan Pengujian dan Keterbatasan Komputasi Proses pelatihan dan pengujian model dilakukan pada lingkungan Jupyter Notebook dengan keterbatasan perangkat keras tertentu [18]. Oleh karena itu, konfigurasi pelatihan seperti jumlah epoch, ukuran batch, dan kompleksitas model disesuaikan dengan kemampuan komputasi yang tersedia.
- 6 Ruang Lingkup Implementasi Penelitian ini tidak membahas implementasi model dalam bentuk aplikasi komersial maupun integrasi ke dalam sistem informasi yang berjalan. Hasil penelitian berupa model klasifikasi dan analisis performa yang diposisikan sebagai prototipe fungsional untuk pengembangan lebih lanjut.

Berdasarkan batasan-batasan tersebut, penelitian ini difokuskan pada pengembangan dan evaluasi model klasifikasi kesegaran ikan berbasis citra digital dalam ruang lingkup dataset, metode, serta keterbatasan komputasi yang telah ditetapkan. Dengan pengendalian ruang lingkup melalui pemilihan arsitektur MobileNetV2, penerapan strategi *fine-tuning* dan transfer learning, serta teknik augmentasi data, diharapkan penelitian ini mampu menghasilkan model dengan performa klasifikasi yang optimal dan stabil sesuai dengan skala penelitian skripsi.

1.4 Tujuan dan Manfaat Penelitian

1.4.1 Tujuan Penelitian

Tujuan penelitian ini adalah untuk mengembangkan dan mengoptimalkan model klasifikasi kesegaran ikan berbasis citra digital menggunakan pendekatan Convolutional Neural Network (CNN) dengan arsitektur MobileNetV2.

Secara rinci, tujuan penelitian ini adalah sebagai berikut:

- 1 Mengembangkan model klasifikasi kesegaran ikan berbasis citra digital menggunakan CNN dengan arsitektur MobileNetV2 sebagai dasar perancangan model.
- 2 Menerapkan strategi optimasi melalui pendekatan transfer learning dan *fine-tuning* pada arsitektur MobileNetV2 untuk meningkatkan kinerja klasifikasi pada dataset yang terbatas.
- 3 Mengevaluasi hasil performa model klasifikasi kesegaran ikan berbasis MobileNetV2 yang telah dioptimasi berdasarkan metrik evaluasi seperti akurasi, presisi, recall, dan F1-score.

1.4.2 Manfaat Penelitian

1 Manfaat Teoritis

Penelitian ini memberikan kontribusi teoritis ke bidang pemahaman mendalam dan kecerdasan komputer, terutama dalam hal penerapan Convolutional Neural Network berbasis arsitektur MobileNetV2 untuk klasifikasi kesegaran ikan berbasis gambar digital [19]. Studi ini memberikan analisis komparatif antara metode pelatihan model dari awal (training from scratch) dan metode transfer learning, serta memperkaya penelitian tentang penerapan strategi *fine-tuning* dan transfer learning dalam kondisi dataset terbatas dan juga memberikan interpretasi visual terhadap proses pengambilan keputusan model menggunakan Grad-CAM. Studi ini juga menunjukkan bahwa arsitektur ringan dapat membuat model klasifikasi yang efektif tetapi kompetitif [20].

2 Manfaat Praktis

Secara praktis, penelitian ini diharapkan dapat berfungsi sebagai dasar untuk pengembangan sistem pendukung keputusan awal untuk penilaian kesegaran ikan yang lebih akurat dan konsisten. Model ini dapat membantu distributor, pelaku

usaha perikanan, dan pihak terkait menilai kualitas ikan dengan lebih baik, terutama dalam situasi di mana sumber daya komputasi terbatas. Penelitian ini juga dapat membantu pengembang sistem atau peneliti lain membuat solusi klasifikasi gambar berbasis *deep learning* di lingkungan dengan keterbatasan data [21].

1.5 Sistematika Penulisan

Sistematika penulisan laporan penelitian ini disusun untuk memberikan gambaran alur pembahasan secara terstruktur sebagai berikut:

Bab I Pendahuluan

Bab ini memuat latar belakang penelitian, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, serta sistematika penulisan.

Bab II Tinjauan Pustaka

Bab ini membahas penelitian terkait yang relevan, landasan teori yang mendukung penelitian, framework atau algoritma yang digunakan, serta tools penelitian.

Bab III Metodologi Penelitian

Bab ini menjelaskan metode penelitian yang digunakan, tahapan pengolahan data, deskripsi dataset, perancangan model klasifikasi, serta metode evaluasi kinerja model.

Bab IV Analisis dan Hasil Penelitian

Bab ini memaparkan proses implementasi model klasifikasi kesegaran ikan berbasis MobileNetV2, mulai dari tahap preprocessing data, pelatihan model, penerapan strategi *fine-tuning*, hingga evaluasi kinerja model. Selain itu, bab ini juga menyajikan hasil pengujian, analisis performa berdasarkan berbagai metrik evaluasi, serta interpretasi hasil menggunakan visualisasi Grad-CAM untuk memahami proses pengambilan keputusan model.

Bab V Simpulan dan Saran

Bab ini berisi simpulan yang diperoleh berdasarkan hasil penelitian dan analisis yang telah dilakukan untuk menjawab rumusan masalah penelitian. Selain itu, bab ini juga menyajikan saran yang dapat digunakan sebagai acuan untuk pengembangan penelitian selanjutnya maupun implementasi lebih lanjut dari model klasifikasi kesegaran ikan yang diusulkan.

BAB II

LANDASAN TEORI

2.1 Penelitian Terdahulu

Dalam lima tahun terakhir (2021–2026), penelitian literatur telah dilakukan untuk menggambarkan perkembangan metode klasifikasi kesegaran ikan yang menggunakan gambar digital. Analisis ini diperlukan untuk mengidentifikasi kesalahan penelitian yang mendasari pengembangan model penelitian ini. Studi terbaru menunjukkan bahwa pendekatan *deep learning* berbasis *Convolutional Neural Network* (CNN) akan menggantikan pendekatan machine learning konvensional yang melibatkan ekstraksi fitur manual. Namun demikian, Tabel 2.1 menyampaikan beberapa keterbatasan yang masih ditemukan dalam penelitian-penelitian sebelumnya.

Table 2.1 Penelitian Terdahulu

No	Penulis, Judul, Tahun, Penerbit	Teori Penelitian	Fokus Penelitian	Hasil Penelitian
1	Prasetyo, E., Et Al. (2022). <i>Combining MobileNetV1 And Depthwise Separable Convolution Bottleneck With Expansion For Classifying The Freshness Of Fish Eyes. Information Processing In Agriculture</i>	MobileNetV1 + Depthwise Separable Convolution + Bottleneck Expansion	Klasifikasi Kesegaran Mata Ikan Menggunakan Arsitektur MobileNetV1	Akurasi 63,21% Pada Dataset Ffe; Menunjukkan Keterbatasan Representasi Fitur
2	Medeiros, E. C., Almeida, L. M., & Filho, J. G. (2021). <i>Computer Vision And Machine</i>	Cnn Vs Machine Learning (Svm, Knn)	Klasifikasi Kualitas Daging Ikan Tuna Dan Salmon	Cnn Menunjukkan Performa Lebih Baik Dibanding Metode Machine

No	Penulis, Judul, Tahun, Penerbit	Teori Penelitian	Fokus Penelitian	Hasil Penelitian
	<i>Learning For Tuna And Salmon Meat Classification. Informatics (Mdpi)</i>			Learning Konvensional
3	Yildiz, M. B., Yasin, E. T., & Koklu, M. (2024). <i>Fisheye Freshness Detection Using Common Deep Learning Algorithms. European Food Research And Technology</i>	Cnn (Berbagai Arsitektur)	Deteksi Kesegaran Mata Ikan Berbasis Aplikasi Mobile	Model Cnn Menghasilkan Klasifikasi Yang Stabil Dan Akurat
4	Biswas, S., Et Al. (2025). <i>Fish Freshness Detection Via Hybrid Cnn-Lstm. Springer</i>	Hybrid Cnn-Lstm	Deteksi Kesegaran Ikan Berbasis Kombinasi Spasial Dan Temporal	Akurasi Meningkat, Namun Kompleksitas Komputasi Tinggi
5	Sanga, H., Et Al. (2024). <i>Tilapia Fish Freshness Detection Using Cnn Models. Springer</i>	Cnn (Resnet, Mobilenet, Dll)	Klasifikasi Kesegaran Ikan Nila Berbasis Citra	Cnn Meningkatkan Akurasi Dibanding Metode Konvensional
6	Bichri, H., Chergui, A., & Hain, M. (2023). <i>Image Classification With Transfer Learning. Procedia Computer Science</i>	Transfer Learning (Resnet, Vgg, Mobilenet)	Evaluasi Transfer Learning Pada Dataset Kecil	Transfer Learning Meningkatkan Akurasi Dan Stabilitas Dibanding Training From Scratch

No	Penulis, Judul, Tahun, Penerbit	Teori Penelitian	Fokus Penelitian	Hasil Penelitian
7	Peries, R. F. S., Et Al. (2025). <i>Ai-Driven Fish Freshness Classification. Ieee Scse</i>	Densenet121, Resnet, Cnn Lainnya	Evaluasi Berbagai Arsitektur Cnn Pada Bagian Ikan	Akurasi Tertinggi 99,13% Dengan Densenet121 (Klasifikasi Biner)
8	Hoang, V. T., Et Al. (2025). <i>Feature Fusion For Fish Freshness Classification. Arxiv / Elsevier</i>	Machine Learning + Feature Engineering (Svm, Rf)	Klasifikasi Berbasis Fitur Manual Dan Fusion	Akurasi 77,56% Tanpa Augmentasi Dan 97,16% Dengan Augmentasi
9	Balim, C., Olgun, N., & Çalişan, M. (2025). <i>Feature Fusion With Laser Reflectance. Sensors (Mdpi)</i>	Cnn + Sensor Fusion (Laser Reflectance)	Klasifikasi Multimodal Kesegaran Ikan	Akurasi 88,44%; Terbatas Pada Kondisi Tertentu
10	Hasan, M., Et Al. (2024). <i>Fish Freshness Detection Using Mask R-Cnn. Journal Of Agriculture And Food Research</i>	Mask R-Cnn	Deteksi Kesegaran Dan Segmentasi Ikan Busuk	Akurasi $\pm 96,5\%$; Cocok Untuk Sistem Real-Time

Berdasarkan penelitian-penelitian tersebut, terlihat bahwa sebagian besar penelitian menggunakan CNN untuk klasifikasi kesegaran ikan. Penelitian awal berfokus pada modifikasi arsitektur, sedangkan penelitian terbaru mulai memanfaatkan transfer learning dan *fine-tuning*. Meskipun demikian, sebagian besar penelitian masih menghadapi trade-off antara akurasi dan efisiensi model. Oleh karena itu, penelitian ini mengadopsi MobileNetV2 dengan strategi *fine-*

tuning untuk meningkatkan kemampuan adaptasi fitur tanpa meningkatkan kompleksitas model secara signifikan.

Penelitian Pertama

Untuk klasifikasi kesegaran mata ikan pada dataset FFE (Freshness of the Fish Eyes) [8], menggunakan dataset Freshness of Fish Eyes (FFE) untuk mengklasifikasikan tingkat kesegaran ikan berdasarkan citra mata ikan. Pada penelitian tersebut, arsitektur MobileNetV1 MB-BE menghasilkan akurasi sebesar 63,21% dengan kompleksitas model yang relatif rendah. Sementara itu, arsitektur ResNet50 mampu mencapai akurasi yang lebih tinggi, yaitu 84,86%, namun memiliki jumlah parameter sekitar 23,59 juta sehingga membutuhkan sumber daya komputasi yang jauh lebih besar. Hasil tersebut menunjukkan adanya trade-off antara performa klasifikasi dan efisiensi komputasi.

Penelitian tersebut memiliki keterkaitan dengan penelitian ini karena menggunakan dataset yang sama, yaitu FFE, serta berfokus pada klasifikasi kesegaran ikan berdasarkan citra mata ikan. Namun, penelitian sebelumnya menunjukkan bahwa model dengan kompleksitas rendah masih memiliki keterbatasan dalam mencapai performa klasifikasi yang optimal, sedangkan model dengan akurasi tinggi memerlukan jumlah parameter yang sangat besar. Oleh karena itu, penelitian ini menggunakan MobileNetV2 dengan pendekatan transfer learning dan fine-tuning untuk meningkatkan kemampuan ekstraksi fitur tanpa meningkatkan kompleksitas model secara signifikan. Dengan pendekatan tersebut, diharapkan dapat diperoleh keseimbangan yang lebih baik antara performa klasifikasi dan efisiensi komputasi dibandingkan penelitian sebelumnya.

Penelitian Kedua

Computer Vision and Machine Learning for Tuna and Salmon Meat Classification. *Informatics (MDPI)* [14] meneliti penerapan *computer vision* dan machine learning untuk mengklasifikasikan kualitas daging ikan tuna dan salmon berdasarkan citra digital. Penelitian tersebut membandingkan beberapa pendekatan machine learning dan *deep learning* dalam proses klasifikasi kualitas ikan. Hasil penelitian menunjukkan bahwa model berbasis Convolutional Neural Network

(CNN) mampu memberikan performa yang lebih baik dibandingkan metode machine learning konvensional dalam mengekstraksi fitur visual dari citra ikan. Temuan tersebut menunjukkan bahwa CNN memiliki kemampuan yang efektif dalam mengenali karakteristik visual yang berkaitan dengan kualitas produk perikanan.

Meskipun demikian, penelitian tersebut berfokus pada klasifikasi jenis dan kualitas daging ikan, bukan pada klasifikasi tingkat kesegaran ikan sebagai indikator keamanan pangan. Selain itu, objek yang digunakan berupa citra daging ikan, sehingga karakteristik visual yang dianalisis berbeda dengan citra mata ikan yang digunakan dalam penelitian ini. Oleh karena itu, penelitian ini secara khusus memfokuskan pada klasifikasi tingkat kesegaran ikan berdasarkan citra mata ikan yang memiliki keterkaitan langsung dengan perubahan kondisi kesegaran. Penelitian ini juga menggunakan arsitektur MobileNetV2 yang lebih ringan dan menerapkan transfer learning serta *fine-tuning* untuk memperoleh keseimbangan antara performa klasifikasi dan efisiensi komputasi.

Penelitian Ketiga

Fisheye Freshness Detection Using Common *Deep Learning* Algorithms. *European Food Research and Technology* [22] mengembangkan sistem deteksi kesegaran ikan berbasis citra mata ikan dengan memanfaatkan berbagai algoritma *deep learning* dan machine learning. Penelitian tersebut mengintegrasikan model klasifikasi ke dalam aplikasi mobile untuk mendukung proses penilaian kesegaran ikan secara otomatis. Hasil penelitian menunjukkan bahwa pendekatan *deep learning* mampu memberikan performa yang lebih stabil dan akurat dibandingkan metode machine learning konvensional dalam mendeteksi tingkat kesegaran ikan. Temuan tersebut menunjukkan potensi penggunaan teknologi *deep learning* sebagai solusi yang efektif dalam mendukung proses evaluasi kualitas ikan berbasis citra digital.

Meskipun demikian, penelitian tersebut menggunakan arsitektur seperti VGG19 dan SqueezeNet yang tetap memiliki kebutuhan komputasi relatif tinggi ketika diimplementasikan pada perangkat mobile. Penggunaan model dengan kompleksitas yang lebih besar berpotensi meningkatkan waktu inferensi dan

konsumsi sumber daya perangkat. Oleh karena itu, penelitian ini menggunakan MobileNetV2 yang dirancang khusus sebagai arsitektur CNN ringan melalui mekanisme inverted residual dan linear bottleneck untuk meningkatkan efisiensi komputasi tanpa mengorbankan kemampuan ekstraksi fitur secara signifikan. Selain itu, penerapan transfer learning dan *fine-tuning* pada penelitian ini diharapkan mampu menghasilkan keseimbangan yang lebih baik antara akurasi klasifikasi, efisiensi komputasi, dan kemudahan implementasi pada perangkat dengan sumber daya terbatas.

Penelitian Keempat

Dalam penelitian Fish Freshness Detection via Hybrid CNN-LSTM. *Springer* [23], mengusulkan pendekatan hybrid dengan menggabungkan Convolutional Neural Network (CNN) dan Long Short-Term Memory (LSTM) untuk mendeteksi tingkat kesegaran ikan. CNN digunakan untuk mengekstraksi fitur visual dari citra ikan, sedangkan LSTM dimanfaatkan untuk memodelkan hubungan antar fitur yang diperoleh. Hasil penelitian menunjukkan bahwa kombinasi kedua arsitektur tersebut mampu meningkatkan performa klasifikasi dibandingkan penggunaan CNN secara tunggal. Temuan ini menunjukkan bahwa integrasi ekstraksi fitur visual dan pemodelan sekuensial dapat memberikan representasi data yang lebih komprehensif dalam proses deteksi kesegaran ikan.

Meskipun menghasilkan performa yang baik, penggunaan arsitektur hybrid CNN-LSTM menyebabkan peningkatan kompleksitas model, kebutuhan memori, serta waktu pelatihan yang lebih besar. Kompleksitas tersebut dapat menjadi kendala ketika model diterapkan pada perangkat dengan sumber daya komputasi yang terbatas. Berbeda dengan penelitian tersebut, penelitian ini menggunakan MobileNetV2 sebagai arsitektur CNN tunggal yang dirancang untuk memberikan efisiensi komputasi yang lebih tinggi dengan jumlah parameter yang relatif lebih kecil. Selain itu, strategi transfer learning dan *fine-tuning* diterapkan untuk meningkatkan kemampuan model dalam mengenali karakteristik visual kesegaran ikan tanpa menambah kompleksitas model secara signifikan.

Penelitian Kelima

Studi yang dilakukan pada Tilapia Fish Freshness Detection Using CNN Models. *Springer* [24] mengevaluasi beberapa arsitektur Convolutional Neural Network (CNN) untuk menentukan model yang paling efektif dalam mengklasifikasikan tingkat kesegaran ikan nila. Penelitian tersebut membandingkan performa berbagai model CNN berdasarkan kemampuan klasifikasi yang dihasilkan pada dataset citra ikan nila. Hasil penelitian menunjukkan bahwa pendekatan CNN mampu meningkatkan kualitas klasifikasi dibandingkan metode konvensional melalui kemampuan ekstraksi fitur visual secara otomatis. Temuan tersebut memperkuat efektivitas *deep learning* dalam mendukung proses penilaian kesegaran ikan berbasis citra digital.

Meskipun demikian, penelitian tersebut hanya berfokus pada satu spesies ikan, yaitu ikan nila, sehingga kemampuan generalisasi model terhadap spesies ikan lainnya belum dapat dipastikan. Keterbatasan cakupan dataset tersebut berpotensi memengaruhi kemampuan model ketika diterapkan pada kondisi yang lebih beragam di dunia nyata. Berbeda dengan penelitian tersebut, penelitian ini menggunakan dataset yang tidak dibatasi pada satu spesies ikan tertentu dan menerapkan klasifikasi multi-kelas berdasarkan tingkat kesegaran ikan. Dengan pendekatan tersebut, model diharapkan memiliki cakupan penerapan yang lebih luas serta mampu menangani variasi karakteristik visual yang lebih beragam dibandingkan penelitian sebelumnya.

Penelitian Keenam

Tujuan dari penelitian Image Classification with Transfer Learning. *Procedia Computer Science* [25] mengevaluasi efektivitas transfer learning pada berbagai arsitektur Convolutional Neural Network (CNN) pralatih untuk tugas klasifikasi citra. Penelitian tersebut menggunakan model yang telah dilatih pada dataset berskala besar dan kemudian mengadaptasikannya pada dataset yang lebih terbatas. Hasil penelitian menunjukkan bahwa transfer learning mampu meningkatkan stabilitas pelatihan, mempercepat proses konvergensi, dan menghasilkan akurasi yang lebih baik dibandingkan pelatihan model dari awal (training from scratch). Temuan tersebut menunjukkan bahwa transfer learning

merupakan pendekatan yang efektif untuk mengatasi keterbatasan jumlah data pada berbagai permasalahan klasifikasi citra.

Meskipun demikian, penelitian tersebut tidak secara khusus membahas klasifikasi kesegaran ikan maupun karakteristik visual yang terkait dengan perubahan tingkat kesegaran. Selain itu, penelitian tersebut lebih berfokus pada evaluasi transfer learning sebagai metode umum tanpa mengkaji penerapannya pada domain perikanan. Oleh karena itu, penelitian ini mengimplementasikan transfer learning secara langsung pada klasifikasi kesegaran ikan berbasis citra mata ikan untuk menguji efektivitasnya pada permasalahan yang lebih spesifik. Selain memanfaatkan bobot pralatih, penelitian ini juga menerapkan *fine-tuning* pada MobileNetV2 agar model dapat beradaptasi lebih baik terhadap karakteristik visual yang berkaitan dengan tingkat kesegaran ikan.

Penelitian Ketujuh

AI-Driven Fish Freshness Classification. *IEEE SCSE* [26] membandingkan beberapa arsitektur Convolutional Neural Network (CNN), yaitu DenseNet121, MobileNetV2, dan ResNet50, untuk mengklasifikasikan kesegaran ikan berdasarkan citra mata, insang, dan tubuh ikan. Penelitian tersebut bertujuan mengevaluasi performa masing-masing arsitektur dalam membedakan tingkat kesegaran ikan menggunakan berbagai indikator visual. Hasil penelitian menunjukkan bahwa DenseNet121 memperoleh performa terbaik dengan akurasi mencapai 99,13%. Temuan tersebut menunjukkan bahwa arsitektur CNN yang lebih dalam mampu menghasilkan representasi fitur yang sangat baik untuk tugas klasifikasi kesegaran ikan.

Meskipun demikian, penelitian tersebut menggunakan pendekatan klasifikasi biner sehingga hanya membedakan ikan segar dan tidak segar. Pendekatan tersebut belum mampu merepresentasikan tingkat kesegaran yang lebih rinci sebagaimana kondisi nyata yang sering bersifat bertahap. Oleh karena itu, penelitian ini menerapkan klasifikasi tiga kelas, yaitu Highly Fresh, Fresh, dan Not Fresh untuk memberikan gradasi penilaian yang lebih komprehensif. Selain itu, penelitian ini berfokus pada penggunaan MobileNetV2 yang lebih ringan sehingga

tetap mempertahankan efisiensi komputasi tanpa mengabaikan performa klasifikasi.

Penelitian Kedelapan

Feature Fusion for Fish Freshness Classification. *arXiv / Elsevier* [27] mengusulkan pendekatan klasifikasi kesegaran ikan pada dataset Freshness of the Fish Eyes (FFE) menggunakan kombinasi fitur warna, Local Binary Pattern (LBP), dan Gray Level Co-occurrence Matrix (GLCM). Fitur-fitur tersebut kemudian digabungkan melalui strategi incremental feature fusion sebelum digunakan sebagai masukan bagi model Artificial Neural Network (ANN). Hasil penelitian menunjukkan bahwa pendekatan tersebut mampu mencapai akurasi hingga 97,16%. Temuan ini menunjukkan bahwa kombinasi beberapa fitur visual dapat meningkatkan kemampuan model dalam membedakan tingkat kesegaran ikan.

Meskipun menghasilkan performa yang tinggi, pendekatan tersebut masih bergantung pada proses rekayasa fitur manual yang memerlukan pemilihan dan perancangan fitur secara khusus. Ketergantungan terhadap fitur manual dapat membatasi fleksibilitas model ketika diterapkan pada dataset atau kondisi yang berbeda. Oleh karena itu, penelitian ini menggunakan pendekatan CNN berbasis MobileNetV2 yang mampu melakukan ekstraksi fitur secara otomatis melalui proses pembelajaran end-to-end. Dengan pendekatan tersebut, model dapat mempelajari representasi visual yang relevan secara langsung dari data tanpa memerlukan proses perancangan fitur manual.

Penelitian Kesembilan

Untuk mengklasifikasikan kesegaran ikan dalam tiga tingkat, Feature Fusion with Laser Reflectance. *Sensors (MDPI)* [28] mengembangkan pendekatan multimodal untuk klasifikasi kesegaran ikan tiga tingkat dengan menggabungkan citra digital dan data reflektansi laser. Kombinasi kedua sumber informasi tersebut bertujuan meningkatkan kemampuan model dalam menangkap karakteristik visual dan fisik yang berkaitan dengan tingkat kesegaran ikan. Hasil penelitian menunjukkan bahwa pendekatan multimodal mampu mencapai akurasi sebesar

88,44%. Temuan ini menunjukkan bahwa integrasi berbagai jenis data dapat meningkatkan performa klasifikasi kesegaran ikan.

Meskipun demikian, penggunaan sensor tambahan berupa laser meningkatkan kompleksitas sistem baik dari sisi perangkat keras maupun proses akuisisi data. Ketergantungan terhadap sensor khusus juga dapat membatasi fleksibilitas implementasi dan meningkatkan biaya operasional sistem. Berbeda dengan penelitian tersebut, penelitian ini hanya memanfaatkan citra digital sebagai sumber data utama sehingga proses pengumpulan data menjadi lebih sederhana dan ekonomis. Selain itu, penggunaan MobileNetV2 memungkinkan pengembangan sistem yang lebih ringan dan mudah diterapkan pada berbagai perangkat dengan sumber daya komputasi yang terbatas.

Penelitian Kesepuluh

Fish Freshness Detection Using Mask R-CNN. *Journal of Agriculture and Food Research* [29] mengembangkan sistem deteksi kesegaran ikan dan identifikasi ikan busuk menggunakan arsitektur Mask R-CNN yang terintegrasi dengan lengan robotik. Pendekatan tersebut memanfaatkan kemampuan segmentasi objek untuk mengidentifikasi bagian ikan yang relevan sebelum dilakukan proses klasifikasi. Hasil penelitian menunjukkan bahwa sistem mampu bekerja secara real-time dengan tingkat akurasi sekitar 96,5%. Temuan tersebut menunjukkan bahwa kombinasi *computer vision* dan sistem robotik memiliki potensi yang besar untuk mendukung otomatisasi proses inspeksi kualitas ikan.

Meskipun menghasilkan performa yang tinggi, integrasi segmentasi berbasis Mask R-CNN dan perangkat robotik menyebabkan peningkatan kompleksitas sistem serta biaya implementasi yang lebih besar. Penggunaan perangkat keras tambahan juga dapat membatasi penerapan sistem pada lingkungan yang memiliki keterbatasan sumber daya. Oleh karena itu, penelitian ini berfokus pada pengembangan sistem klasifikasi berbasis MobileNetV2 yang lebih ringan dan sederhana tanpa memerlukan integrasi perangkat keras tambahan. Dengan pendekatan tersebut, sistem yang diusulkan diharapkan dapat berfungsi sebagai alat pendukung keputusan awal yang lebih mudah diterapkan dan memiliki biaya implementasi yang lebih rendah.

2.2 Teori yang berkaitan

2.2.1 Ikan sebagai Komoditas Pangan

Ikan merupakan salah satu sumber protein hewani utama yang memiliki nilai gizi tinggi dan berperan penting dalam pemenuhan kebutuhan nutrisi masyarakat. Kandungan protein, asam lemak omega-3, vitamin, dan mineral yang terdapat pada ikan menjadikannya komoditas pangan yang penting untuk mendukung kesehatan dan pertumbuhan manusia [22]. Selain memiliki nilai gizi yang tinggi, ikan juga memiliki nilai ekonomi yang signifikan dalam sektor perikanan tangkap maupun budidaya [30]. Khususnya di negara maritim seperti Indonesia, ikan menjadi salah satu komoditas strategis yang berkontribusi terhadap ketahanan pangan, peningkatan pendapatan masyarakat, serta pertumbuhan sektor perikanan nasional [31].

Namun demikian, ikan termasuk komoditas yang mudah mengalami penurunan mutu setelah proses penangkapan atau pemanenan. Proses biologis dan kimiawi yang terjadi pasca-mortem menyebabkan perubahan karakteristik fisik dan organoleptik ikan [32]. Oleh karena itu, pengendalian kualitas ikan menjadi aspek yang sangat penting untuk menjaga keamanan pangan dan kepercayaan konsumen. Dalam konteks penelitian ini, ikan diposisikan sebagai objek utama yang dianalisis tingkat kesegarannya melalui pendekatan berbasis citra digital. Dengan demikian, pemahaman terhadap karakteristik mutu ikan menjadi landasan penting dalam pengembangan sistem klasifikasi kesegaran.

2.2.2 Kesegaran Ikan

Kesegaran ikan didefinisikan sebagai kondisi mutu ikan yang mencerminkan tingkat perubahan fisik, kimia, dan biologis setelah proses penangkapan [3]. Tingkat kesegaran umumnya dikategorikan ke dalam beberapa kelas, seperti sangat segar, segar, dan tidak segar. Penentuan tingkat kesegaran dilakukan berdasarkan indikator visual maupun sensorik yang dapat diamati secara langsung. Klasifikasi tingkat kesegaran tersebut penting karena berhubungan dengan kualitas produk, nilai ekonomi, serta keamanan ikan untuk dikonsumsi.

Beberapa indikator visual yang sering digunakan dalam penilaian kesegaran ikan meliputi kejernihan mata, warna insang, tekstur daging, serta kondisi permukaan kulit [33]. Pada ikan yang masih sangat segar, mata tampak jernih dan menonjol, insang berwarna merah cerah, serta tekstur daging masih elastis. Sebaliknya, pada ikan yang mengalami penurunan mutu, mata cenderung keruh dan cekung, warna insang menjadi pucat atau kecoklatan, dan tekstur daging menjadi lunak [3]. Perbedaan karakteristik visual tersebut menjadikan indikator fisik sebagai salah satu metode yang paling umum digunakan dalam proses evaluasi kesegaran ikan.

Perubahan-perubahan tersebut terjadi akibat aktivitas enzimatik dan pertumbuhan mikroorganisme selama proses penyimpanan. Aktivitas biologis tersebut menyebabkan terjadinya degradasi kualitas ikan yang ditandai dengan perubahan warna, tekstur, dan aroma. Oleh karena itu, kesegaran ikan tidak hanya menjadi indikator kualitas visual, tetapi juga berkaitan erat dengan keamanan konsumsi [34]. Dalam penelitian ini, tingkat kesegaran ikan dijadikan sebagai variabel klasifikasi yang ditentukan berdasarkan karakteristik visual yang terekam dalam citra digital.

2.2.3 Representasi Visual Kesegaran dalam Citra Digital

Karakteristik kesegaran ikan yang bersifat visual dapat direpresentasikan dalam bentuk citra digital. Representasi ini memungkinkan informasi mengenai warna, tekstur, dan pola permukaan ikan diubah menjadi data numerik yang dapat dianalisis secara komputasional [14]. Setiap piksel dalam citra digital menyimpan informasi intensitas warna yang dapat digunakan untuk membedakan kondisi ikan pada tingkat kesegaran yang berbeda [35].

Perubahan kesegaran seringkali ditandai oleh pergeseran warna dan distribusi intensitas cahaya pada area tertentu, seperti mata dan insang. Variasi tekstur dan kecerahan yang muncul akibat proses degradasi biologis juga dapat terdeteksi melalui pola piksel pada citra [36]. Dengan demikian, citra digital tidak hanya berfungsi sebagai media visual, tetapi juga sebagai sumber data kuantitatif yang merepresentasikan kondisi mutu ikan [29].

Pemanfaatan citra digital dalam penelitian ini memungkinkan proses evaluasi kesegaran dilakukan secara objektif dan terstandarisasi [1]. Informasi visual yang sebelumnya dinilai secara subjektif oleh manusia dapat dianalisis menggunakan pendekatan berbasis data sehingga konsistensi hasil penilaian dapat ditingkatkan. Selain itu, penggunaan citra digital memungkinkan proses analisis dilakukan secara otomatis dengan bantuan algoritma kecerdasan buatan yang mampu mengenali pola visual secara efisien. Dengan demikian, evaluasi kesegaran ikan dapat dilakukan secara lebih cepat, konsisten, dan akurat dibandingkan metode inspeksi manual.

2.2.4 Klasifikasi Kesegaran Ikan

Klasifikasi merupakan proses pengelompokan objek ke dalam kategori tertentu berdasarkan karakteristik yang dimiliki. Dalam konteks kesegaran ikan, klasifikasi dilakukan untuk menentukan tingkat mutu ikan berdasarkan indikator visual yang teramati [37]. Proses ini bertujuan untuk membedakan ikan ke dalam kelas-kelas kesegaran yang telah ditentukan sebelumnya. Hasil klasifikasi kemudian dapat digunakan sebagai dasar dalam proses pengambilan keputusan terkait kualitas dan kelayakan konsumsi ikan.

Pada sistem berbasis citra, klasifikasi dilakukan dengan menganalisis pola visual yang terekam dalam gambar digital. Karakteristik seperti warna, tekstur, dan distribusi intensitas cahaya digunakan sebagai dasar pengambilan keputusan. Proses klasifikasi dapat dilakukan secara otomatis menggunakan model komputasional yang dilatih untuk mengenali perbedaan antar kelas [37]. Kemampuan model dalam mengenali pola-pola tersebut sangat memengaruhi tingkat akurasi dan keandalan hasil klasifikasi yang dihasilkan.

Klasifikasi kesegaran ikan dapat dilakukan ke dalam dua atau lebih kategori sesuai dengan tujuan dan kebutuhan analisis. Pada klasifikasi multi-kelas, objek dikelompokkan ke dalam beberapa tingkat kesegaran yang berbeda sehingga mampu memberikan informasi yang lebih rinci dibandingkan klasifikasi biner yang hanya membedakan dua kondisi [38]. Pendekatan ini banyak digunakan pada penelitian klasifikasi kesegaran ikan karena dapat merepresentasikan perubahan kualitas ikan secara lebih bertahap.

Penerapan klasifikasi multi-kelas memungkinkan sistem untuk mengenali perbedaan karakteristik visual pada setiap tingkat kesegaran. Dengan memanfaatkan informasi visual yang terdapat pada citra, model klasifikasi dapat mempelajari pola yang membedakan masing-masing kategori sehingga mendukung proses identifikasi tingkat kesegaran ikan secara lebih terstruktur dan objektif.

2.2.5 Computer Vision

Computer vision adalah bidang ilmu yang mempelajari bagaimana komputer dapat memperoleh, memproses, dan memahami gambar digital atau video. Tujuan utama dari bidang ini adalah meniru kemampuan visual manusia dalam mengenali objek, pola, dan kondisi tertentu secara otomatis [39]. Dengan memanfaatkan berbagai algoritma dan teknik pemrosesan citra, *computer vision* memungkinkan sistem untuk mengekstraksi informasi penting dari data visual secara efisien. Kemampuan tersebut menjadikan *computer vision* banyak diterapkan dalam berbagai bidang, termasuk pengenalan objek, sistem keamanan, kendaraan otonom, serta klasifikasi citra berbasis kecerdasan buatan.

Sebelum proses klasifikasi dilakukan, *computer vision* berfungsi sebagai dasar dalam pengolahan citra ikan pada penelitian ini. Melalui pendekatan *computer vision*, informasi visual yang terkandung dalam citra dapat diubah menjadi representasi data yang dapat diproses secara komputasional. Sistem mampu mengidentifikasi pola-pola visual yang relevan seperti warna, tekstur, dan tingkat kecerahan pada objek ikan. Selain itu, *computer vision* juga mendukung proses preprocessing dan ekstraksi fitur otomatis sehingga proses analisis kesegaran ikan dapat dilakukan secara lebih konsisten dan objektif [40].

2.2.6 Deep Learning

Salah satu cabang pembelajaran mesin adalah *deep learning* yang menggunakan jaringan saraf tiruan dengan banyak lapisan untuk mempelajari representasi data secara hierarkis. Pendekatan ini memungkinkan model mempelajari pola yang sederhana hingga kompleks secara bertahap melalui proses pelatihan. Metode *deep learning* mampu melakukan ekstraksi fitur secara otomatis sehingga mengurangi ketergantungan terhadap proses perancangan fitur secara manual oleh peneliti [41].

Kemampuan tersebut menjadikan *deep learning* sebagai salah satu pendekatan yang banyak digunakan dalam berbagai permasalahan pengenalan pola dan klasifikasi data.

Karena kemampuan untuk mengenali pola visual yang kompleks, *deep learning* telah banyak digunakan dalam pengolahan gambar [42]. Pendekatan ini mampu mempelajari hubungan nonlinier yang sulit ditangkap oleh metode machine learning konvensional. Oleh karena itu, *deep learning* sering digunakan untuk menyelesaikan permasalahan klasifikasi citra dengan variasi data yang tinggi dan karakteristik visual yang kompleks [22]. Dalam beberapa tahun terakhir, perkembangan *deep learning* juga telah mendorong peningkatan performa berbagai aplikasi *computer vision* di berbagai bidang penelitian.

2.2.7 Evaluasi Objektif dalam Penilaian Mutu Ikan

Dalam penelitian ini, sistem klasifikasi kesegaran ikan dirancang sebagai bentuk pendukung keputusan awal yang membantu proses evaluasi mutu secara lebih efisien [31]. Sistem yang dikembangkan memanfaatkan citra digital dan algoritma kecerdasan buatan untuk mengurangi ketergantungan terhadap penilaian subjektif manusia. Dengan pendekatan ini, proses identifikasi tingkat kesegaran ikan dapat dilakukan secara lebih cepat dan konsisten pada berbagai kondisi pengamatan. Selain itu, hasil klasifikasi yang diperoleh diharapkan dapat menjadi sumber informasi tambahan yang mendukung proses pengambilan keputusan terkait kualitas dan keamanan produk perikanan.[38].

2.2.8 Grad-CAM (Gradient-weighted Class Activation Mapping)

Grad-CAM (*Gradient-weighted Class Activation Mapping*) merupakan salah satu metode *Explainable Artificial Intelligence* (XAI) yang digunakan untuk membantu menjelaskan proses pengambilan keputusan pada model *Convolutional Neural Network* (CNN). Metode ini menghasilkan visualisasi berupa *heatmap* yang menunjukkan area citra yang memberikan kontribusi terbesar terhadap hasil prediksi model [xx]. Dengan demikian, Grad-CAM dapat membantu pengguna memahami bagian citra mana yang menjadi fokus perhatian model selama proses klasifikasi.

Grad-CAM bekerja dengan memanfaatkan informasi gradien dari kelas target terhadap *feature map* pada layer konvolusi terakhir. Nilai gradien tersebut digunakan untuk menghitung tingkat kepentingan masing-masing *feature map*, kemudian dikombinasikan untuk menghasilkan peta aktivasi yang menunjukkan area penting pada citra [xx]. Area dengan intensitas warna yang lebih tinggi menunjukkan kontribusi yang lebih besar terhadap keputusan model, sedangkan area dengan intensitas yang lebih rendah menunjukkan kontribusi yang lebih kecil.

Metode Grad-CAM banyak digunakan pada penelitian klasifikasi citra karena mampu memberikan interpretasi visual tanpa mengubah struktur model yang digunakan. Selain membantu meningkatkan transparansi model, visualisasi Grad-CAM juga dapat digunakan untuk memverifikasi apakah model mempelajari fitur yang relevan dengan objek penelitian atau justru memanfaatkan pola yang tidak berkaitan dengan proses klasifikasi [xx].

Pada penelitian ini, Grad-CAM digunakan untuk mengevaluasi area perhatian model pada citra mata ikan yang diklasifikasikan ke dalam tingkat kesegaran tertentu. Visualisasi yang dihasilkan digunakan untuk menganalisis apakah model memfokuskan perhatian pada bagian yang relevan, seperti kornea, pupil, dan refleksi cahaya, yang diketahui merupakan indikator visual penting dalam penilaian kesegaran ikan. Dengan demikian, Grad-CAM tidak hanya digunakan sebagai alat interpretasi, tetapi juga sebagai pendukung validitas hasil klasifikasi yang diperoleh.


2.3 Framework dan Algoritma yang digunakan

2.3.1 Knowledge Discovery in Databases (KDD)

Pendekatan Knowledge Discovery in Databases (KDD) merupakan kerangka kerja sistematis yang digunakan dalam proses penggalian pengetahuan dari data. Framework ini dirancang untuk memastikan bahwa data yang tersedia dapat diolah secara terstruktur sehingga menghasilkan informasi atau model yang bermakna. Berbeda dengan CRISP-DM yang mencakup tahapan deployment, KDD berfokus pada proses ekstraksi pola dan evaluasi hasil tanpa menekankan

implementasi produksi [43]. Oleh karena itu, KDD banyak digunakan dalam penelitian yang bertujuan menemukan pola, hubungan, atau informasi tersembunyi dari data untuk mendukung proses pengambilan keputusan.

Dalam penelitian ini, framework KDD digunakan untuk memandu proses pengembangan model klasifikasi kesegaran ikan berbasis citra digital. Setiap tahapan dalam KDD disesuaikan dengan karakteristik dataset citra ikan serta pendekatan *deep learning* yang digunakan. Penerapan framework ini memungkinkan proses pengolahan data dilakukan secara sistematis, mulai dari pemilihan data hingga evaluasi hasil klasifikasi yang dihasilkan oleh model. Dengan demikian, penggunaan KDD diharapkan dapat membantu menghasilkan model klasifikasi yang lebih terstruktur, akurat, dan sesuai dengan tujuan penelitian.



Gambar 2.1 Knowledge Discovery in Database Process (KDD) [43]

1. Selection

Tahap selection merupakan proses pemilihan data yang relevan dengan tujuan penelitian. Pada tahap ini, dataset citra ikan dipilih dari sumber dataset publik yang memuat label tingkat kesegaran. Data yang digunakan terdiri atas citra ikan dengan kategori sangat segar, segar, dan tidak segar [43]. Pemilihan dataset yang sesuai menjadi langkah penting karena kualitas dan karakteristik data akan memengaruhi performa model klasifikasi yang dikembangkan.

Proses seleksi dilakukan untuk memastikan bahwa hanya data yang memiliki kualitas memadai dan label yang jelas yang digunakan dalam penelitian. Selain itu, dilakukan identifikasi terhadap jumlah data pada setiap kelas untuk memahami distribusi awal dataset. Tahap ini bertujuan untuk memastikan bahwa data yang digunakan benar-benar merepresentasikan permasalahan klasifikasi kesegaran ikan yang akan diteliti. Dengan demikian, proses pengembangan model dapat dilakukan menggunakan data yang valid, konsisten, dan sesuai dengan tujuan penelitian.

2. Preprocessing

Tahap preprocessing dilakukan untuk membersihkan dan menyiapkan data sebelum digunakan dalam proses pemodelan. Pada penelitian ini, preprocessing dilakukan terhadap citra digital ikan untuk memastikan keseragaman format dan kualitas gambar [44].

Beberapa proses yang dilakukan meliputi:

- A. Penyesuaian ukuran (resizing) agar seluruh citra memiliki dimensi yang seragam
- B. Normalisasi nilai piksel untuk menyesuaikan rentang intensitas
- C. Penghapusan data yang rusak atau tidak terbaca

Tahap ini penting karena model *deep learning* sangat sensitif terhadap inkonsistensi ukuran dan distribusi data. Dengan preprocessing yang tepat, kualitas input model dapat ditingkatkan sehingga proses pelatihan menjadi lebih stabil.

3. Transformation

Tahap transformation bertujuan untuk mengubah data ke dalam bentuk yang lebih sesuai untuk proses data mining. Dalam konteks penelitian ini, transformasi dilakukan melalui teknik augmentasi data untuk meningkatkan variasi dataset [45].

Teknik augmentasi yang digunakan meliputi:

- 1. Rotasi
- 2. Flipping horizontal
- 3. Penyesuaian kecerahan

Transformasi ini dilakukan untuk memperkaya variasi pola visual tanpa menambah data baru secara manual. Selain itu, pada tahap ini juga dilakukan pembagian dataset (data splitting) ke dalam data pelatihan dan data pengujian dengan rasio tertentu [46]. Transformasi ini bertujuan untuk meningkatkan kemampuan generalisasi model serta mengurangi risiko akibat keterbatasan jumlah data [7].

4. Data Mining (Modeling)

Tahap data mining merupakan inti dari proses KDD, yaitu proses ekstraksi pola dari data menggunakan metode komputasional [43]. Dalam penelitian ini, data mining dilakukan melalui pengembangan model klasifikasi berbasis Convolutional Neural Network (CNN) dengan arsitektur MobileNetV2 [47].

Model dikembangkan menggunakan pendekatan transfer learning dengan strategi *fine-tuning* untuk mengoptimalkan performa pada dataset terbatas. Selain itu, model baseline CNN sederhana digunakan sebagai pembandingan untuk menilai efektivitas arsitektur yang digunakan. Pada tahap ini, dilakukan proses pelatihan model dengan parameter tertentu seperti jumlah epoch dan ukuran batch. Hasil dari tahap ini berupa model terlatih yang mampu mengklasifikasikan tingkat kesegaran ikan berdasarkan citra digital [48].

5. Evaluation dan Interpretation

Tahap evaluation dilakukan untuk menilai performa model yang telah dikembangkan. Evaluasi dilakukan menggunakan metrik klasifikasi seperti accuracy, precision, recall, dan F1-score [49]. Penggunaan beberapa metrik bertujuan untuk memberikan gambaran menyeluruh mengenai kemampuan model dalam mengenali setiap kelas kesegaran. Selain evaluasi kuantitatif, dilakukan pula interpretasi terhadap hasil klasifikasi untuk memahami pola kesalahan yang terjadi. Analisis confusion matrix digunakan untuk mengidentifikasi kelas yang paling sering mengalami kesalahan prediksi [50].

Tahap ini menghasilkan kesimpulan mengenai efektivitas model MobileNetV2 dalam mengklasifikasikan kesegaran ikan [30]. Hasil evaluasi

digunakan untuk mengetahui sejauh mana model mampu membedakan setiap kategori kesegaran berdasarkan karakteristik visual yang terdapat pada citra ikan. Selain itu, interpretasi terhadap hasil klasifikasi memberikan informasi mengenai kelebihan dan keterbatasan model yang dikembangkan. Karena penelitian ini berfokus pada pengembangan dan evaluasi model, proses tidak dilanjutkan ke tahap deployment, melainkan dibatasi pada analisis performa sebagai bentuk sistem pendukung keputusan awal.

2.3.2 Algoritma yang Digunakan

1. Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) merupakan arsitektur *deep learning* yang dirancang untuk memproses data berbentuk citra digital. Berbeda dengan jaringan saraf tiruan konvensional yang menerima input dalam bentuk vektor satu dimensi, CNN mempertahankan struktur spasial dua dimensi dari citra sehingga hubungan antar piksel tetap terjaga [51]. Dengan mempertahankan struktur spasial ini, pola visual seperti bentuk, tekstur, serta distribusi warna dapat dipelajari secara lebih efektif [52].

Dalam penelitian ini, CNN digunakan sebagai dasar pendekatan klasifikasi kesegaran ikan berbasis citra digital. Karakteristik visual seperti perubahan kejernihan mata, gradasi warna, serta tekstur permukaan ikan dipelajari secara otomatis oleh jaringan melalui proses ekstraksi fitur bertingkat [53]. Lapisan awal CNN umumnya menangkap fitur tingkat rendah seperti tepi dan gradien warna, sedangkan lapisan yang lebih dalam menangkap pola visual yang lebih kompleks dan spesifik terhadap objek [41]. Kemampuan CNN dalam melakukan ekstraksi fitur secara otomatis menjadikannya sesuai untuk menangani variasi kondisi citra, seperti perbedaan pencahayaan dan sudut pengambilan gambar yang terdapat pada dataset penelitian [54].

2. Pseudocode yang digunakan dalam Convolutional Neural Network (CNN)

Alur proses pelatihan Convolutional Neural Network (CNN) pada data citra digital dapat digambarkan secara konseptual menggunakan pseudocode.

Pseudocode digunakan untuk memberikan gambaran umum mengenai tahapan yang dilakukan model selama proses pembelajaran tanpa bergantung pada bahasa pemrograman tertentu. Tahapan tersebut meliputi proses inisialisasi model, propagasi maju (forward propagation), perhitungan nilai kehilangan (loss calculation), serta pembaruan bobot melalui mekanisme backpropagation [55]. Dengan adanya representasi pseudocode, alur kerja CNN dapat dipahami secara lebih sistematis sebelum diimplementasikan ke dalam kode program yang sebenarnya.

Table 2. 2 Pseudocode CNN

Setiap lapisan CNN menerima nilai berat dan bias tertentu pada awal pelatihan. Tujuan dari bobot ini adalah untuk mengetahui bagaimana fitur visual dapat diekstraksi dari gambar input. Untuk setiap gambar yang dimasukkan ke dalam dataset, gunakan filter untuk membuat map fitur dengan operasi konvolusi; gunakan fungsi aktivasi untuk menambahkan non-linearitas ke hasil konvolusi; dan lakukan operasi pooling. <i>Feature map</i> diratakan (<i>flattening</i>) menjadi vektor satu dimensi dan mempertahankan informasi penting[56]. Map fitur dikurangi: Peta fitur lapisan terakhir dikurangi atau diratakan menjadi vektor satu dimensi. Vektor ini digunakan sebagai input untuk lapisan yang penuh terhubung [8]. Hitung output klasifikasi: Output prediksi kelas berdasarkan fitur yang telah diekstraksi dibuat dengan menggunakan lapisan yang penuh terhubung [57]. Hitung fungsi kerugian: Fungsi kerugian digunakan untuk menghitung perbedaan antara hasil prediksi dan label sebenarnya untuk mengevaluasi kinerja model [58]. Untuk menghitung gradien dan memperbarui bobot model, backpropagation dan pembaruan bobot menggunakan kesalahan yang dihasilkan [59]. Ulangi proses berulang kali. Pelatihan diulangi berulang kali hingga model berfungsi dengan baik.

Berdasarkan Tabel 2.2, proses pelatihan CNN diawali dengan inisialisasi bobot dan bias pada setiap lapisan. Selanjutnya citra masukan diproses melalui operasi konvolusi, fungsi aktivasi, dan pooling untuk menghasilkan representasi fitur yang lebih informatif. Hasil ekstraksi fitur kemudian diteruskan ke fully

connected layer untuk menghasilkan prediksi kelas. Setelah itu dilakukan perhitungan fungsi loss dan pembaruan bobot menggunakan backpropagation hingga model mencapai performa yang optimal.

Pseudocode ini menggambarkan alur dasar pelatihan CNN, mulai dari ekstraksi fitur visual hingga proses optimasi bobot model. CNN mempelajari representasi visual secara bertahap, sehingga mampu membedakan kelas citra berdasarkan karakteristik yang relevan [60]. Proses pembelajaran dilakukan melalui penyesuaian bobot secara iteratif berdasarkan kesalahan prediksi yang dihasilkan pada setiap epoch pelatihan. Dengan mekanisme tersebut, model diharapkan dapat mengenali pola-pola visual yang berkaitan dengan tingkat kesegaran ikan secara lebih akurat dan konsisten.

3. Operasi Dasar dalam CNN

Proses pembelajaran pada CNN melibatkan beberapa komponen utama, yaitu operasi konvolusi, fungsi aktivasi, pooling, dan lapisan klasifikasi.

A. Operasi Konvolusi

Operasi konvolusi dilakukan dengan menggeser kernel atau filter pada citra input untuk menghasilkan feature map. Proses ini memungkinkan jaringan mengekstraksi pola visual lokal dari citra [58].

Secara matematis, operasi konvolusi dapat dinyatakan sebagai:

$$z(i,j) = (x * k)(i,j) + b$$

Rumus 2.1 Operasi Konvolusi

Di mana:

X merupakan citra input

K merupakan kernel atau filter

b merupakan bias

$Z(i,j)$ merupakan nilai output pada posisi (i,j)

B. Fungsi Aktivasi

Setelah operasi konvolusi dilakukan, fungsi aktivasi diterapkan untuk memperkenalkan non-linearitas ke dalam model. Fungsi aktivasi yang umum

digunakan pada CNN adalah Rectified Linear Unit (ReLU) [61], yang dirumuskan sebagai berikut:

$$f(x) = \max(0, x)$$

Rumus 2.2 Fungsi Aktivasi

Fungsi ReLU digunakan untuk mempercepat proses pelatihan dan mengurangi permasalahan vanishing gradient pada jaringan saraf dalam.

C. Pooling Layer

Pooling digunakan untuk mengurangi dimensi feature map tanpa menghilangkan informasi penting. Teknik yang umum digunakan adalah max pooling, yang mengambil nilai maksimum dalam suatu area tertentu[7].

Proses ini membantu mengurangi kompleksitas komputasi dan meningkatkan ketahanan model terhadap variasi kecil pada posisi objek dalam citra [62].

D. Softmax untuk Klasifikasi

Pada lapisan akhir, fungsi softmax digunakan untuk menghasilkan probabilitas setiap kelas kesegaran ikan:

$$P(y_i) = \frac{e^{z_i}}{\sum_{j=1}^c e^{z_j}}$$

Rumus 2.3 Softmax untuk Klasifikasi

Fungsi ini memastikan bahwa total probabilitas seluruh kelas bernilai satu dan memungkinkan model menentukan kelas dengan probabilitas tertinggi sebagai hasil prediksi [63].

4. Transfer Learning

Transfer learning merupakan pendekatan pembelajaran mesin yang memanfaatkan model yang telah dilatih sebelumnya pada dataset berskala besar untuk menyelesaikan permasalahan baru yang memiliki karakteristik serupa. Dalam konteks penelitian ini, model pralatih yang digunakan adalah MobileNetV2 yang sebelumnya dilatih menggunakan dataset ImageNet [25]. Bobot awal yang telah mempelajari fitur visual umum seperti bentuk dasar, tepi, dan pola tekstur digunakan sebagai dasar pembelajaran. Dengan pendekatan ini, proses pelatihan tidak dimulai dari nol, sehingga waktu pelatihan dapat dipersingkat dan kebutuhan data yang besar dapat diminimalkan [64].

Transfer learning dinilai sangat relevan untuk diterapkan pada penelitian ini karena dataset kesegaran ikan yang digunakan memiliki jumlah data yang relatif terbatas. Kondisi tersebut menyebabkan proses pelatihan model dari awal (training from scratch) berpotensi menghasilkan performa yang kurang stabil dan cenderung mengalami overfitting. Overfitting dapat terjadi ketika model terlalu menyesuaikan diri terhadap pola pada data pelatihan, sehingga kemampuan generalisasi terhadap data baru menjadi menurun. Oleh karena itu, pemanfaatan bobot awal (*pre-trained weights*) dari model yang telah dilatih pada dataset berskala besar seperti ImageNet diharapkan mampu membantu proses ekstraksi fitur menjadi lebih optimal serta meningkatkan stabilitas pembelajaran model [12].


5. Fine-tuning

Fine-tuning merupakan teknik lanjutan dalam transfer learning yang dilakukan dengan membuka kembali sebagian lapisan model pralatih untuk dilatih ulang menggunakan dataset target [16]. Pada tahap awal, sebagian besar lapisan dasar dibekukan (*freeze*) untuk mempertahankan fitur umum yang telah dipelajari. Selanjutnya, beberapa lapisan akhir dibuka kembali (*unfreeze*) untuk menyesuaikan representasi fitur dengan karakteristik spesifik citra kesegaran ikan [65]. Dalam penelitian ini, *fine-tuning* dilakukan secara bertahap untuk meningkatkan kemampuan model dalam mengenali perbedaan antar kelas kesegaran tanpa meningkatkan kompleksitas parameter secara signifikan [66]. Strategi ini membantu meningkatkan performa klasifikasi sekaligus menjaga stabilitas pelatihan [67].

6. Arsitektur MobileNetV2

MobileNetV2 merupakan arsitektur CNN yang dirancang untuk efisiensi komputasi dan penggunaan pada perangkat dengan sumber daya terbatas. Arsitektur ini menggunakan konsep inverted residual dan linear bottleneck untuk menjaga kualitas representasi fitur dengan jumlah parameter yang relatif kecil [68]. Dibandingkan dengan arsitektur CNN konvensional, MobileNetV2 mampu mengurangi kebutuhan komputasi tanpa mengorbankan performa secara signifikan.

Karakteristik tersebut menjadikan MobileNetV2 banyak digunakan pada berbagai aplikasi *computer vision* yang membutuhkan keseimbangan antara akurasi dan efisiensi komputasi.



Gambar 2.2 Arsitektur MobileNetV2

MobileNetV2 dipilih karena memiliki arsitektur yang ringan dan efisien sehingga mampu mengurangi kompleksitas komputasi dan jumlah parameter tanpa mengurangi performa ekstraksi fitur secara signifikan [69]. Oleh karena itu, model ini sesuai untuk klasifikasi citra dengan kebutuhan komputasi yang lebih efisien. Dengan ukuran model yang relatif ringan dibandingkan arsitektur lain seperti ResNet atau DenseNet, MobileNetV2 memungkinkan proses pelatihan dilakukan dalam lingkungan komputasi terbatas tanpa mengorbankan performa secara signifikan [70].

MobileNetV2 dipilih karena menawarkan keseimbangan antara performa klasifikasi dan efisiensi komputasi melalui penggunaan *depthwise separable convolution* dan *inverted residual block*. Dibandingkan beberapa arsitektur CNN

yang lebih kompleks, MobileNetV2 memiliki jumlah parameter yang relatif lebih kecil sehingga lebih ringan dalam proses pelatihan maupun inferensi. Selain itu, MobileNetV2 telah banyak digunakan pada berbagai penelitian klasifikasi citra dan terbukti mampu menghasilkan performa yang kompetitif pada dataset dengan ukuran menengah. Oleh karena itu, MobileNetV2 dipandang sesuai dengan tujuan penelitian yang tidak hanya mempertimbangkan performa klasifikasi, tetapi juga efisiensi model.

Meskipun telah tersedia arsitektur yang lebih modern seperti EfficientNetV2, Vision Transformer (ViT), dan ConvNeXt, penelitian ini berfokus pada optimasi MobileNetV2 melalui pendekatan *transfer learning* dan *fine-tuning*. Pemilihan tersebut dilakukan untuk mengevaluasi sejauh mana peningkatan performa dapat diperoleh melalui strategi pelatihan tanpa harus meningkatkan kompleksitas model secara signifikan.

7. Perbandingan MobileNetV2 dengan Arsitektur Deep Learning Modern

Perkembangan deep learning telah menghasilkan berbagai arsitektur modern yang menawarkan peningkatan performa pada tugas klasifikasi citra. Selain MobileNetV2, beberapa arsitektur yang banyak digunakan dalam penelitian terkini adalah EfficientNetV2, ConvNeXt, dan Vision Transformer (ViT). Masing-masing arsitektur memiliki karakteristik, kelebihan, dan kebutuhan komputasi yang berbeda. Oleh karena itu, pemilihan model perlu disesuaikan dengan tujuan penelitian, ukuran dataset, dan sumber daya komputasi yang tersedia.

Table 2.3 Perbandingan MobileNetV2 dengan Arsitektur Deep Learning Modern

Arsitektur	Tahun	Karakteristik Utama	Kelebihan	Kekurangan
MobileNetV2	2018	Inverted Residual dan Linear Bottleneck	Ringan, efisien, jumlah parameter relatif kecil, cocok untuk	Akurasi umumnya lebih rendah dibanding model yang lebih kompleks

Arsitektur	Tahun	Karakteristik Utama	Kelebihan	Kekurangan
			transfer learning	
EfficientNetV2	2021	Compound Scaling dan Fused-MBConv	Akurasi tinggi dengan efisiensi yang baik	Membutuhkan sumber daya komputasi lebih besar dibanding MobileNetV2
ConvNeXt	2022	Arsitektur CNN modern yang mengadopsi beberapa konsep Transformer	Performa klasifikasi tinggi dan representasi fitur kuat	Jumlah parameter dan kebutuhan memori relatif besar
Vision Transformer (ViT)	2021	Self-Attention Mechanism	Mampu menangkap hubungan global pada citra secara efektif	Membutuhkan dataset besar dan komputasi tinggi untuk pelatihan optimal

Berdasarkan Tabel 2.3, EfficientNetV2, ConvNeXt, dan Vision Transformer (ViT) merupakan arsitektur yang lebih modern dibandingkan MobileNetV2. Namun demikian, penelitian ini menggunakan MobileNetV2 karena memiliki keseimbangan yang baik antara performa klasifikasi dan efisiensi komputasi. MobileNetV2 dirancang untuk menghasilkan representasi fitur yang efektif dengan jumlah parameter yang relatif kecil sehingga sesuai untuk penelitian yang menggunakan dataset berskala menengah.

Selain itu, fokus utama penelitian ini bukan pada perbandingan antar arsitektur deep learning, melainkan pada optimasi performa MobileNetV2 melalui penerapan transfer learning dan fine-tuning. Dengan kompleksitas model yang

lebih ringan, MobileNetV2 memungkinkan proses pelatihan dilakukan secara lebih efisien tanpa memerlukan sumber daya komputasi yang tinggi. Oleh karena itu, MobileNetV2 dipilih sebagai arsitektur yang sesuai untuk mencapai tujuan penelitian, yaitu menghasilkan model klasifikasi kesegaran ikan yang memiliki performa baik sekaligus tetap efisien secara komputasi.

8. Depthwise Separable Convolution

Depthwise separable convolution merupakan komponen utama dalam arsitektur MobileNetV2 yang bertujuan untuk meningkatkan efisiensi komputasi. Operasi ini memisahkan konvolusi standar menjadi dua tahap, yaitu depthwise convolution dan pointwise convolution [71]. Depthwise convolution dilakukan dengan menerapkan satu filter pada setiap kanal input secara terpisah. Selanjutnya, pointwise convolution (konvolusi 1×1) digunakan untuk menggabungkan informasi antar kanal [58]. Pendekatan ini secara signifikan mengurangi jumlah parameter dan operasi komputasi dibandingkan konvolusi konvensional. Relevansi komponen ini dalam penelitian terletak pada kemampuannya menghasilkan model yang ringan namun tetap mampu mengekstraksi fitur visual secara efektif [72]. Hal ini sesuai dengan kebutuhan penelitian yang memiliki keterbatasan sumber daya komputasi.

2.4 Tools/software yang digunakan

Dalam pelaksanaan penelitian ini, digunakan beberapa perangkat lunak untuk mendukung proses pengumpulan referensi, pengolahan data, pengembangan model, penyusunan laporan, serta pemeriksaan kualitas naskah. Penggunaan *tools* yang sesuai bertujuan untuk memastikan setiap tahapan penelitian dapat dilakukan secara sistematis, terdokumentasi dengan baik, dan menghasilkan keluaran yang sesuai dengan tujuan penelitian. Selain itu, perangkat lunak yang digunakan juga membantu meningkatkan efisiensi proses penelitian, terutama pada tahap pengolahan data dan pelatihan model klasifikasi.

Perangkat lunak yang digunakan memiliki fungsi yang berbeda pada setiap tahapan penelitian. Beberapa perangkat lunak digunakan untuk pengembangan dan pelatihan model *deep learning*, sementara perangkat lunak lainnya digunakan untuk

pengolahan data, visualisasi hasil, manajemen referensi, serta penyusunan laporan penelitian. Dengan dukungan berbagai perangkat lunak tersebut, proses penelitian dapat dilakukan secara lebih terstruktur, akurat, dan mudah direproduksi sehingga mendukung validitas hasil penelitian yang diperoleh.

2.4.1 Jupyter Notebook

Jupyter Notebook digunakan sebagai lingkungan pengembangan utama dalam proses implementasi model klasifikasi kesegaran ikan. Platform ini memungkinkan penulisan dan eksekusi kode secara interaktif dalam satu dokumen yang terintegrasi dengan visualisasi output. Dalam penelitian ini, Jupyter Notebook dimanfaatkan untuk melakukan preprocessing data citra, penerapan teknik augmentasi, pembangunan model Convolutional Neural Network berbasis MobileNetV2, serta proses pelatihan dan evaluasi model. Selain itu, grafik akurasi, loss, dan confusion matrix juga dihasilkan melalui lingkungan ini untuk membantu analisis performa model [18]. Penggunaan Jupyter Notebook mendukung pendekatan eksperimental yang iteratif, sehingga penyesuaian parameter seperti jumlah epoch, ukuran batch, dan learning rate dapat dilakukan secara fleksibel dan terdokumentasi dengan baik [18].

2.4.2 Google Scholar

Google Scholar digunakan sebagai sumber utama dalam proses pencarian literatur ilmiah yang relevan dengan topik penelitian. Melalui platform ini, berbagai jurnal internasional, prosiding konferensi, dan artikel ilmiah terkait *deep learning*, *computer vision*, CNN, serta klasifikasi kesegaran ikan dapat diakses dan dianalisis. Penggunaan Google Scholar membantu memastikan bahwa landasan teori dan penelitian terdahulu yang digunakan dalam skripsi ini berasal dari sumber akademik yang kredibel dan terindeks [73]. Selain itu, fitur sitasi pada Google Scholar memudahkan dalam menelusuri perkembangan penelitian yang memiliki keterkaitan dengan arsitektur MobileNetV2 dan pendekatan transfer learning.

2.4.3 Publish or Perish

Publish or Perish digunakan sebagai alat bantu dalam mengevaluasi kualitas dan dampak publikasi ilmiah yang ditemukan melalui Google Scholar. Perangkat lunak ini membantu dalam menganalisis jumlah sitasi, indeks h, serta metrik bibliometrik lainnya dari suatu artikel atau penulis. Dalam penelitian ini, Publish or Perish dimanfaatkan untuk menyaring referensi berdasarkan tingkat relevansi dan pengaruh akademiknya. Dengan demikian, literatur yang digunakan tidak hanya relevan secara topik, tetapi juga memiliki kontribusi ilmiah yang signifikan dalam bidang *deep learning* dan klasifikasi citra [74].



BAB III

METODOLOGI PENELITIAN

3.1 Gambaran Umum Objek Penelitian

Objek penelitian dalam studi ini adalah citra digital ikan yang digunakan untuk mengklasifikasikan tingkat kesegaran. Data yang digunakan berasal dari dataset publik yang berisi gambar ikan dengan label tingkat kesegaran, yaitu highly fresh, fresh, dan not fresh. Setiap citra merepresentasikan kondisi visual ikan pada tingkat kesegaran tertentu dan menjadi dasar dalam proses pembelajaran model. Karakteristik visual seperti warna, tekstur, dan kondisi mata ikan yang terekam dalam citra digunakan sebagai sumber informasi utama dalam proses klasifikasi. Melalui analisis terhadap karakteristik tersebut, model diharapkan mampu membedakan tingkat kesegaran ikan secara otomatis dan objektif.



Gambar 3.1 Tingkat Kesegaran Mata Ikan

Citra dalam dataset menampilkan bagian mata ikan sebagai indikator utama kesegaran. Secara umum, ikan dengan kategori highly fresh memiliki mata yang jernih, cembung, dan memantulkan cahaya dengan jelas [71]. Pada kategori fresh, kejernihan mata mulai berkurang namun masih mempertahankan bentuk yang relatif utuh. Sementara itu, pada kategori not fresh, mata cenderung tampak keruh, cekung, dan mengalami perubahan warna yang lebih gelap. Contoh citra dari masing-masing kategori ditunjukkan pada Gambar 3.1.

Meskipun perbedaan visual tersebut dapat diamati, proses klasifikasi tidak selalu sederhana. Perbedaan antara kelas highly fresh dan fresh sering kali bersifat gradual dan tipis, sehingga sulit dibedakan secara konsisten melalui pengamatan manual [3]. Selain itu, variasi pencahayaan, sudut pengambilan gambar, latar

belakang, serta tingkat ketajaman citra menambah kompleksitas dalam proses identifikasi pola. Tantangan ini menuntut model klasifikasi yang mampu mengekstraksi fitur visual secara otomatis dan mendalam [75]. Oleh karena itu, pendekatan Convolutional Neural Network (CNN) dengan arsitektur MobileNetV2 digunakan dalam penelitian ini untuk mempelajari representasi visual dari citra ikan dan membedakan tingkat kesegaran secara lebih objektif dan konsisten [51].

3.2 Metode Penelitian

Metode penelitian yang digunakan dalam penelitian ini adalah Knowledge Discovery in Database (KDD) [43]. KDD merupakan metodologi dalam bidang penambangan data yang terdiri dari lima tahapan utama, yaitu Selection, Pre-processing, Transformation, Data Mining, serta Evaluation/Interpretation. Metodologi ini berfokus pada proses pengolahan data secara sistematis mulai dari pemilihan data hingga interpretasi hasil model yang dihasilkan.

Tabel 3.1 menyajikan perbandingan beberapa framework dalam Data Mining, yaitu CRISP-DM, KDD, dan SEMMA.




Tabel 3.1 perbandingan framework CRISP-DM, KDD, dan SEMMA

CRISP-DM	KDD	SEMMA
Memiliki 6 tahapan: Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, Deployment	Memiliki 5 tahapan: Selection, Pre-processing, Transformation, Data Mining, Evaluation/Interpretation	Memiliki 5 tahapan: Sample, Explore, Modify, Model, Assess
Terdapat tahap Deployment	Tidak terdapat tahap Deployment	Tidak terdapat tahap Deployment
Fokus pada pemahaman bisnis dan implementasi	Fokus pada proses ekstraksi pengetahuan dari data	Fokus pada pemrosesan teknis dan eksplorasi data

Penelitian ini menggunakan framework Knowledge Discovery in Database (KDD) sebagai metodologi utama dalam proses optimasi model klasifikasi kesegaran ikan berbasis citra digital [43]. KDD merupakan pendekatan sistematis dalam penemuan pola dan pengetahuan dari data yang terdiri atas lima tahapan utama, yaitu Selection, Pre-processing, Transformation, Data Mining, dan Evaluation/Interpretation [43]. Framework ini dipilih karena mampu menyediakan alur kerja yang terstruktur dalam mengelola data hingga menghasilkan model yang dapat dievaluasi secara objektif. Melalui penerapan tahapan-tahapan KDD, proses pengembangan model diharapkan dapat dilakukan secara sistematis sehingga menghasilkan model klasifikasi yang efektif dan sesuai dengan tujuan penelitian.

Pemilihan KDD dalam penelitian ini didasarkan pada karakteristik penelitian yang berorientasi pada proses ekstraksi pola klasifikasi dari dataset citra digital hingga tahap evaluasi performa model, tanpa implementasi sistem secara

langsung ke lingkungan produksi. Berbeda dengan CRISP-DM yang mencakup tahapan Deployment, penelitian ini tidak bertujuan untuk melakukan implementasi sistem secara operasional, melainkan berfokus pada pembangunan dan analisis performa model [76]. Oleh karena itu, framework KDD dinilai lebih relevan dan proporsional terhadap ruang lingkup penelitian. Selain itu, KDD memberikan struktur yang jelas dalam pengolahan data, sehingga setiap tahapan mulai dari seleksi data hingga evaluasi model dapat dilakukan secara terkontrol dan terukur. Pendekatan ini mendukung pengembangan model *deep learning* secara sistematis serta memungkinkan interpretasi hasil dilakukan secara komprehensif.



Gambar 3.2 lima fase utama dalam framework KDD

3.2.1 Selection

Tahap Selection bertujuan untuk menentukan data yang relevan dan representatif terhadap permasalahan penelitian. Dataset yang digunakan merupakan citra mata ikan dari sumber dataset publik yang telah memiliki label tingkat kesegaran. Penelitian ini difokuskan pada klasifikasi multi-kelas dengan tiga kategori, yaitu Highly Fresh, Fresh, dan Not Fresh [71]. Pemilihan tiga kelas dilakukan untuk memberikan representasi gradasi kesegaran yang lebih informatif dibandingkan klasifikasi biner, sehingga model tidak hanya membedakan kondisi segar dan tidak segar, tetapi juga mampu menangkap perbedaan tingkat kesegaran secara lebih detail.

Analisis distribusi kelas dilakukan untuk mengidentifikasi potensi ketidakseimbangan data (class imbalance) yang dapat memengaruhi performa model. Selain itu, ukuran citra disesuaikan menjadi 224×224 piksel agar kompatibel dengan arsitektur MobileNetV2 [77]. Penyesuaian ini tidak hanya bersifat teknis, tetapi juga memastikan bahwa struktur spasial citra tetap terjaga tanpa distorsi signifikan. Tahap ini memastikan bahwa data yang dipilih telah memenuhi kriteria representatif, konsisten, dan sesuai dengan kebutuhan arsitektur model [22].

3.2.2 Pre-processing

Tahap Pre-processing dilakukan untuk meningkatkan kualitas dan konsistensi data sebelum digunakan dalam proses pelatihan model. Pada tahap ini dilakukan resizing citra menjadi 224×224 piksel menggunakan metode bilinear interpolation, yang dipilih karena mampu mempertahankan kualitas visual lebih baik dibandingkan metode interpolasi sederhana [26]. Konversi citra ke format RGB dilakukan untuk menjaga keseragaman kanal warna. Selanjutnya, dilakukan normalisasi nilai piksel ke rentang -1 hingga 1 sesuai dengan standar preprocessing MobileNetV2 [24]. Normalisasi ini penting untuk menjaga stabilitas gradien selama proses pelatihan dan mempercepat konvergensi model.

Proses pembersihan data juga dilakukan untuk menghapus citra yang rusak atau tidak valid. Langkah ini penting karena model *deep learning* sangat sensitif terhadap anomali data yang dapat mengganggu proses optimasi. Dengan demikian,

tahap pre-processing tidak hanya bersifat teknis, tetapi juga berfungsi untuk memastikan kualitas input model berada dalam kondisi optimal. Selain itu, kualitas data yang baik dapat membantu model mempelajari pola visual secara lebih efektif sehingga menghasilkan performa klasifikasi yang lebih akurat dan stabil.

3.2.3 Transformation

Tahap Transformation bertujuan untuk meningkatkan kesiapan data dalam proses pemodelan. Pada tahap ini dilakukan konversi label kelas ke dalam bentuk integer encoding, sehingga kompatibel dengan *fungsi loss Sparse Categorical Crossentropy* [78]. Augmentasi data berupa rotasi $\pm 14^\circ$ diterapkan untuk meningkatkan variasi data pelatihan tanpa mengubah karakteristik dasar objek. Pemilihan rotasi terbatas pada $\pm 14^\circ$ dilakukan untuk mempertahankan kealamian orientasi citra mata ikan, sehingga tidak menghasilkan distorsi yang berlebihan.

Dataset kemudian dibagi menjadi data pelatihan dan data pengujian dengan rasio 80%:20%. Rasio ini dipilih untuk memastikan jumlah data pelatihan cukup besar untuk proses pembelajaran model, sekaligus tetap menyediakan data pengujian yang representatif untuk evaluasi performa secara objektif. Tahap transformasi ini dirancang untuk meningkatkan kemampuan generalisasi model sekaligus meminimalkan risiko overfitting. Dengan pembagian data yang seimbang, proses pelatihan dan evaluasi dapat dilakukan secara lebih efektif sehingga hasil pengujian mampu mencerminkan kemampuan model pada data yang belum pernah dilihat sebelumnya.

3.2.4 Data Mining

Tahap Data Mining merupakan inti penelitian, yaitu pembangunan model klasifikasi menggunakan pendekatan Convolutional Neural Network (CNN) [10]. Arsitektur yang dipilih adalah MobileNetV2, yang telah dilatih sebelumnya pada dataset ImageNet [79]. Pemilihan MobileNetV2 dilakukan secara argumentatif dengan mempertimbangkan keseimbangan antara akurasi dan efisiensi komputasi. Dibandingkan dengan arsitektur seperti ResNet50 yang memiliki sekitar 23,59 juta parameter, MobileNetV2 hanya memiliki sekitar 2,59 juta parameter dalam

konfigurasi penelitian ini [68]. Jumlah parameter yang lebih kecil memungkinkan proses pelatihan dilakukan secara lebih efisien tanpa memerlukan sumber daya komputasi tinggi, namun tetap mampu menghasilkan performa yang kompetitif.

Pada tahap awal, base layers dibekukan untuk mempertahankan kemampuan ekstraksi fitur umum. Selanjutnya, ditambahkan lapisan Global Average Pooling dan Dense layer dengan tiga output kelas menggunakan aktivasi Softmax. Proses pelatihan dilakukan menggunakan optimizer Adam karena kemampuannya dalam menyesuaikan learning rate secara adaptif [23]. Fungsi loss yang digunakan adalah Sparse Categorical Crossentropy, yang sesuai untuk klasifikasi multi-kelas dengan label dalam bentuk integer. Setelah pelatihan awal, dilakukan *fine-tuning* dengan membuka sebagian lapisan akhir untuk meningkatkan adaptasi fitur terhadap karakteristik visual kesegaran ikan. Strategi ini memungkinkan model menyesuaikan representasi fitur secara spesifik terhadap domain penelitian tanpa kehilangan keunggulan fitur dasar yang telah dipelajari sebelumnya [80].

3.2.5 Evaluation / Interpretation

Tahap Evaluation dilakukan untuk menilai performa model secara kuantitatif dan kualitatif. Metrik yang digunakan meliputi accuracy, precision, recall, serta confusion matrix. Accuracy digunakan untuk mengukur performa keseluruhan model, Precision dan recall digunakan untuk mengevaluasi kemampuan model dalam mengenali masing-masing kelas kesegaran. Confusion matrix digunakan untuk menganalisis pola kesalahan klasifikasi, khususnya pada kelas yang memiliki karakteristik visual yang serupa [7].

Analisis kesalahan dilakukan untuk memahami keterbatasan model, seperti kemungkinan kebingungan antara kelas Fresh dan Highly Fresh yang memiliki perbedaan visual tipis. Karena penelitian ini berfokus pada pembangunan dan evaluasi model sebagai sistem pendukung keputusan awal, proses tidak dilanjutkan ke tahap implementasi atau deployment. Pembatasan ini dilakukan untuk menjaga fokus penelitian pada aspek analisis dan performa model [81].

3.3 Teknik Pengumpulan Data

Penelitian ini menggunakan dataset publik The Freshness of the Fish Eyes (FFE) yang tersedia melalui platform Mendeley Data [71]. Dataset ini berisi citra digital mata ikan yang digunakan untuk mengklasifikasikan tingkat kesegaran berdasarkan karakteristik visual mata ikan. Dataset FFE telah dimanfaatkan dalam beberapa penelitian sebelumnya terkait klasifikasi kesegaran ikan berbasis citra digital, sehingga memiliki relevansi akademik yang kuat.

Dataset FFE terdiri dari citra mata ikan dari delapan spesies, yaitu *Chanos Chanos*, *Johnius Trachycephalus*, *Nibea Albiflora*, *Rastrelliger Faughni*, *Upeneus Moluccensis*, *Eleutheronema Tetradactylum*, *Oreochromis Mossambicus*, dan *Oreochromis Niloticus*. Setiap citra diberi label berdasarkan hari penyimpanan ikan, yang kemudian dikelompokkan menjadi tiga tingkat kesegaran [71], yaitu:

Isi folder dataset:

- *Oreochromis Mossambicus* - Not Fresh
- *Johnius Trachycephalus* - Highly Fresh
- *Rastrelliger Faughni* - Not Fresh
- *Chanos Chanos* - Fresh
- *Oreochromis Niloticus* - Not Fresh
- *Oreochromis Mossambicus* - Highly Fresh
- .DS_Store
- *Oreochromis Niloticus* - Highly Fresh
- *Eleutheronema Tetradactylum* - Highly Fresh
- *Chanos Chanos* - Not Fresh
- *Johnius Trachycephalus* - Fresh
- *Rastrelliger Faughni* - Fresh
- *Rastrelliger Faughni* - Highly Fresh
- *Oreochromis Mossambicus* - Fresh
- *Nibea Albiflora* - Highly Fresh
- *Upeneus Moluccensis* - Not Fresh
- *Oreochromis Niloticus* - Fresh
- *Johnius Trachycephalus* - Not Fresh
- *Chanos Chanos* - Highly Fresh
- *Upeneus Moluccensis* - Highly Fresh
- *Nibea Albiflora* - Fresh
- *Eleutheronema Tetradactylum* - Not Fresh
- *Nibea Albiflora* - Not Fresh
- *Upeneus Moluccensis* - Fresh
- *Eleutheronema Tetradactylum* - Fresh

Gambar 3.3 Isi Folder Dataset [71]

1. Highly Fresh (hari ke-1 dan ke-2), yang merepresentasikan kondisi ikan dengan tingkat kesegaran sangat tinggi, ditandai oleh mata ikan yang masih jernih, kornea transparan, dan refleksi cahaya yang masih terlihat jelas [71].
2. Fresh (hari ke-3 dan ke-4), yang merepresentasikan kondisi ikan yang masih layak dikonsumsi, namun mulai menunjukkan perubahan visual seperti berkurangnya kejernihan kornea dan menurunnya intensitas refleksi Cahaya [71].
3. Not Fresh (hari ke-5 dan ke-6), yang merepresentasikan kondisi ikan dengan tingkat kesegaran rendah, ditandai oleh mata yang lebih keruh, warna yang cenderung kusam, serta batas pupil yang semakin sulit diamati[71].

Pengelompokan berdasarkan rentang hari tersebut digunakan karena proses penurunan kesegaran ikan berlangsung secara bertahap. Seiring bertambahnya waktu penyimpanan, karakteristik visual pada mata ikan mengalami perubahan yang dapat diamati secara langsung. Oleh karena itu, pembagian kelas berdasarkan hari penyimpanan digunakan sebagai dasar pemberian label kesegaran pada dataset. Dalam penelitian ini, label spesies ikan tidak digunakan sebagai variabel klasifikasi. Fokus penelitian diarahkan pada identifikasi tingkat kesegaran ikan berdasarkan karakteristik visual mata ikan, bukan pada proses pengenalan jenis ikan. Oleh karena itu, seluruh citra dari delapan spesies ikan digabungkan ke dalam tiga kelas kesegaran sesuai label yang tersedia pada dataset.

Pendekatan ini dipilih untuk memastikan bahwa model mempelajari pola visual yang berkaitan dengan tingkat kesegaran, seperti kejernihan kornea, kondisi pupil, dan distribusi refleksi cahaya, bukan karakteristik morfologi yang membedakan setiap spesies ikan. Dengan demikian, model yang dihasilkan bersifat **species-agnostic**, yaitu tidak bergantung pada jenis ikan tertentu, sehingga diharapkan memiliki kemampuan generalisasi yang lebih baik ketika digunakan pada berbagai spesies ikan yang memiliki indikator visual kesegaran yang serupa.

3.3.1 Analisis Populasi dan Sampel

Populasi dalam penelitian ini adalah seluruh citra mata ikan yang tersedia dalam dataset FFE [71]. Berdasarkan hasil pengunduhan dataset, jumlah citra awal yang diperoleh adalah 4.400 citra. Sebelum digunakan dalam proses pelatihan model, dilakukan validasi integritas file untuk memastikan seluruh citra dapat dibaca dengan baik oleh sistem. Proses ini dilakukan secara otomatis menggunakan Python dengan pustaka PIL (Python Imaging Library) [82]. Hasil pemeriksaan menunjukkan bahwa terdapat 10 citra yang mengalami kerusakan (corrupt) dan tidak dapat diproses. Kedua citra tersebut kemudian dihapus dari dataset.

Dengan demikian, jumlah dataset akhir yang digunakan dalam penelitian ini adalah 4.390 citra. Seluruh citra yang lolos tahap validasi digunakan sebagai sampel penelitian (total sampling), sehingga data yang digunakan tetap representatif terhadap variasi kondisi visual kesegaran mata ikan dari berbagai spesies. Penggunaan metode total sampling dilakukan untuk memaksimalkan pemanfaatan data yang tersedia dan menghindari hilangnya informasi yang berpotensi penting bagi proses pembelajaran model. Dengan jumlah data yang relatif besar dan beragam, model diharapkan mampu mempelajari karakteristik visual kesegaran ikan secara lebih komprehensif serta memiliki kemampuan generalisasi yang lebih baik.

Dataset kemudian dibagi menjadi tiga subset, yaitu:

1. 3.512 citra (80%) sebagai data latih,
2. 439 citra (10%) sebagai data validasi,
3. 439 citra (10%) sebagai data uji.

Proporsi pembagian dataset sebesar 80:10:10 dipilih untuk memberikan keseimbangan antara jumlah data pelatihan yang cukup besar dan data evaluasi yang representatif. Sebanyak 80% data digunakan untuk memastikan model memiliki variasi sampel yang memadai dalam mempelajari pola fitur visual. Sementara itu, 10% data validasi digunakan untuk memantau performa selama proses pelatihan serta membantu mendeteksi overfitting. Adapun 10% data uji digunakan untuk mengevaluasi performa akhir model secara objektif. Pembagian ini merupakan praktik umum dalam pengembangan model pembelajaran mesin pada dataset berskala menengah.

Selain itu, rasio pembagian data 80:10:10 dipilih karena memberikan porsi data latih yang lebih besar sehingga model memiliki lebih banyak sampel untuk mempelajari karakteristik visual kesegaran ikan. Pada penelitian berbasis *deep learning*, jumlah data latih yang memadai merupakan faktor penting untuk membantu model membangun representasi fitur yang lebih baik dan mengurangi risiko *underfitting*. Oleh karena itu, proporsi 80% data latih dinilai sesuai dengan karakteristik dataset yang digunakan dalam penelitian ini.

Pemilihan rasio 80:10:10 juga didasarkan pada karakteristik dataset yang memiliki jumlah data relatif terbatas, yaitu sebanyak 4.390 citra. Dengan menggunakan 80% data sebagai data latih, model memperoleh 3.512 citra yang cukup beragam untuk mempelajari pola visual kesegaran ikan. Sementara itu, 10% data validasi dan 10% data uji dinilai telah memadai untuk memantau proses pelatihan serta mengevaluasi performa model secara objektif.

Penelitian ini hanya menggunakan satu skenario pembagian data, yaitu 80:10:10, sehingga belum dilakukan analisis terhadap pengaruh skenario pembagian data lainnya seperti 70:15:15 atau 70:20:10. Oleh karena itu, hasil evaluasi yang diperoleh masih bergantung pada distribusi data pada pembagian tersebut. Penelitian selanjutnya dapat melakukan pengujian menggunakan beberapa skenario pembagian data atau metode validasi yang lebih komprehensif, seperti *K-Fold Cross Validation*, untuk mengevaluasi stabilitas performa model secara lebih menyeluruh.

3.3.2 Data Sebelum Pemrosesan

Sebelum memasuki tahap pemodelan, dataset melalui proses prapemrosesan untuk memastikan konsistensi format, kualitas citra, serta kesesuaian dengan arsitektur model yang digunakan. Tahapan ini dilakukan secara otomatis menggunakan Python dalam lingkungan Jupyter Notebook [18].

Langkah-langkah prapemrosesan meliputi:

1. Validasi Integritas File

Setiap citra diperiksa untuk memastikan file dapat dibuka dan dibaca dengan benar. Proses validasi dilakukan menggunakan pustaka PIL (*Python Imaging*

Library) untuk mendeteksi file yang mengalami kerusakan (*corrupt*) atau tidak dapat diproses oleh sistem.

Tahap ini penting karena file yang rusak dapat menyebabkan kegagalan pada proses pemuatan data maupun pelatihan model. Oleh karena itu, citra yang teridentifikasi mengalami kerusakan dihapus dari dataset sehingga hanya data yang valid yang digunakan pada penelitian.

2. Penyesuaian Ukuran Citra

Seluruh citra diubah ukurannya menjadi 224×224 piksel menggunakan metode *bilinear interpolation* agar sesuai dengan spesifikasi input arsitektur MobileNetV2. Ukuran 224×224 dipilih karena merupakan ukuran input standar yang digunakan pada proses *pretraining* MobileNetV2 menggunakan dataset ImageNet. Dengan menggunakan ukuran yang sama, representasi fitur yang telah dipelajari selama proses *pretraining* dapat dimanfaatkan secara lebih optimal pada tahap *transfer learning*.

Selain itu, ukuran 224×224 memberikan keseimbangan antara kualitas informasi visual dan efisiensi komputasi. Ukuran yang lebih kecil berpotensi menghilangkan detail visual penting pada area mata ikan, seperti kejernihan kornea, pupil, dan refleksi cahaya. Sebaliknya, penggunaan ukuran yang lebih besar akan meningkatkan kebutuhan memori dan waktu komputasi tanpa menjamin peningkatan performa model secara signifikan. Oleh karena itu, ukuran 224×224 dipilih sebagai ukuran yang sesuai untuk mendukung proses pelatihan MobileNetV2 dalam penelitian ini.

3. Normalisasi Nilai Piksel

Nilai piksel dinormalisasi ke dalam rentang -1 hingga 1 menggunakan fungsi *preprocess_input* yang disediakan oleh MobileNetV2. Proses ini dilakukan agar distribusi data masukan sesuai dengan distribusi data yang digunakan selama proses *pretraining* pada dataset ImageNet.

Normalisasi juga membantu meningkatkan stabilitas proses pelatihan dengan mengurangi perbedaan skala antar fitur pada citra. Dengan demikian, proses optimasi dapat berlangsung lebih efektif dan model lebih mudah mencapai kondisi konvergen selama pelatihan.

4. Augmentasi Data (pada Data Latih)

Untuk meningkatkan variasi data latih, diterapkan beberapa teknik augmentasi berupa rotasi ringan, pembalikan horizontal (*horizontal flip*), perubahan tingkat kecerahan (*brightness adjustment*), dan *zoom* ringan. Teknik ini digunakan untuk menghasilkan variasi citra baru tanpa mengubah label kelas yang dimiliki.

Penerapan augmentasi bertujuan untuk meningkatkan kemampuan generalisasi model terhadap variasi kondisi citra yang mungkin ditemui pada data baru. Selain itu, augmentasi juga membantu mengurangi risiko *overfitting* karena model tidak hanya mempelajari pola dari citra asli, tetapi juga dari variasi citra yang dihasilkan selama proses pelatihan.

Meskipun distribusi kelas dalam dataset tidak sepenuhnya seimbang, teknik oversampling tidak diterapkan dalam penelitian ini. Keputusan ini diambil untuk menjaga distribusi asli data serta menghindari potensi *overfitting* akibat duplikasi citra pada kelas minoritas [83]. Sebagai gantinya, evaluasi model dilakukan menggunakan metrik yang sensitif terhadap distribusi kelas, seperti Macro Precision, Macro Recall, dan Macro F1-Score, sehingga performa masing-masing kelas tetap dapat diukur secara proporsional. Melalui tahapan ini, dataset menjadi lebih bersih, terstruktur, dan siap digunakan dalam proses pelatihan model klasifikasi kesegaran ikan berbasis Convolutional Neural Network (CNN).

3.4 Variabel Penelitian

Dalam penelitian ini, variabel penelitian ditentukan berdasarkan tujuan untuk mengevaluasi pengaruh penggunaan arsitektur MobileNetV2 dengan pendekatan transfer learning dan *fine-tuning* terhadap performa klasifikasi kesegaran ikan berbasis citra digital. Secara umum, variabel dalam penelitian ini terdiri atas variabel independen, variabel dependen, dan variabel kontrol. Penentuan variabel penelitian dilakukan untuk memastikan bahwa proses pengujian dan analisis dapat dilakukan secara sistematis serta sesuai dengan tujuan penelitian yang telah ditetapkan. Dengan identifikasi variabel yang jelas, hubungan antara faktor yang memengaruhi model dan hasil yang diperoleh dapat dianalisis secara lebih objektif dan terstruktur.

3.4.1 Variabel Independen (Variabel Bebas)

Variabel independen dalam penelitian ini adalah metode dan arsitektur model yang digunakan dalam proses klasifikasi [27].

Variabel ini terdiri atas:

1. Model CNN sederhana (training from scratch) sebagai baseline.
2. Model MobileNetV2 dengan pendekatan transfer learning.
3. Model MobileNetV2 dengan strategi *fine-tuning* bertahap.

Variabel independen ini merepresentasikan pendekatan pemodelan yang berbeda untuk mengetahui apakah penggunaan arsitektur prelatih dan *fine-tuning* memberikan peningkatan performa dibandingkan model yang dilatih dari awal.

3.4.2 Variabel Dependen (Variabel Terikat)

Variabel dependen dalam penelitian ini adalah performa model klasifikasi kesegaran ikan [27].

Performa model diukur menggunakan metrik evaluasi berikut:

1. Accuracy
2. Precision
3. Recall
4. F1-Score
5. Confusion Matrix

Nilai dari metrik-metrik tersebut digunakan untuk menilai efektivitas masing-masing model dalam mengklasifikasikan tingkat kesegaran ikan ke dalam tiga kelas (Highly Fresh, Fresh, Not Fresh).

3.4.3 Variabel Kontrol

Untuk memastikan bahwa perbandingan performa antar model dilakukan secara adil dan objektif, beberapa variabel dikendalikan (dikontrol) [84], yaitu:

1. Dataset yang digunakan (FFE dataset): Seluruh skenario pelatihan menggunakan dataset yang sama sehingga perbedaan performa tidak dipengaruhi oleh perbedaan sumber atau jumlah data.

2. Proporsi pembagian data (80:10:10): Pembagian data latih, validasi, dan uji dibuat sama pada setiap skenario untuk menjaga konsistensi proses pelatihan dan evaluasi.
3. Ukuran input citra (224×224 piksel): Seluruh citra diubah ke ukuran yang sama agar model menerima masukan dengan dimensi yang seragam sesuai spesifikasi MobileNetV2.
4. Proses preprocessing dan augmentasi data: Tahapan seperti konversi warna, normalisasi piksel, serta augmentasi data diterapkan secara konsisten pada seluruh skenario sehingga tidak memengaruhi hasil perbandingan.
5. Metode optimasi model (Adam Optimizer): Optimizer yang digunakan untuk memperbarui bobot model selama proses pelatihan dibuat sama pada seluruh skenario agar proses pembelajaran berlangsung dalam kondisi yang setara.
6. Fungsi evaluasi kesalahan model (Sparse Categorical Crossentropy): Fungsi ini digunakan untuk mengukur perbedaan antara hasil prediksi model dengan label sebenarnya pada masalah klasifikasi multi-kelas. Penggunaan fungsi yang sama memastikan bahwa proses pembelajaran dan evaluasi dilakukan dengan kriteria yang konsisten.

Pemilihan MobileNetV2 didasarkan pada pertimbangan efisiensi parameter dan kebutuhan komputasi yang relatif rendah. Dibandingkan arsitektur yang lebih modern seperti EfficientNetV2, Vision Transformer (ViT), dan ConvNeXt, MobileNetV2 memiliki kompleksitas model yang lebih ringan sehingga lebih sesuai untuk penelitian yang berfokus pada optimasi transfer learning dan fine-tuning pada dataset berskala menengah. Dengan mengontrol variabel-variabel tersebut, perbedaan performa yang dihasilkan dapat lebih meyakinkan dikaitkan dengan perbedaan arsitektur dan strategi pelatihan, bukan akibat faktor eksternal lainnya.

3.5 Teknik Analisis Data

Teknik analisis data dalam penelitian ini dilakukan untuk mengevaluasi performa model klasifikasi kesegaran ikan berbasis citra digital menggunakan pendekatan *deep learning* [85]. Proses analisis difokuskan pada pembangunan model Convolutional Neural Network (CNN) dengan arsitektur MobileNetV2 serta pengukuran performa model menggunakan metrik evaluasi klasifikasi multi-kelas. Analisis dilakukan secara eksperimental dengan membandingkan dua pendekatan pemodelan, yaitu model CNN sederhana yang dilatih dari awal (training from scratch) sebagai baseline, dan model MobileNetV2 yang menggunakan pendekatan transfer learning serta *fine-tuning* [86]. Pendekatan ini bertujuan untuk mengevaluasi efektivitas penggunaan arsitektur pralatih dalam meningkatkan performa klasifikasi pada dataset citra berskala menengah.

3.5.1 Analisis dan Pemodelan *Deep Learning*

Pada tahap ini dilakukan pembangunan model klasifikasi berbasis Convolutional Neural Network (CNN). Dua pendekatan pemodelan digunakan dalam penelitian ini, yaitu:

1. Model CNN sederhana (baseline) yang dilatih dari awal tanpa menggunakan bobot pralatih.
2. Model MobileNetV2 dengan pendekatan transfer learning dan *fine-tuning*.

Model baseline digunakan sebagai pembanding untuk mengukur kontribusi penggunaan arsitektur pralatih terhadap peningkatan performa. MobileNetV2 dipilih karena memiliki jumlah parameter yang relatif ringan dan efisien secara komputasi. Dalam penelitian ini digunakan MobileNetV2 dengan nilai $\alpha = 0,5$, sehingga total parameter model hanya sebesar 2,59 parameter, jauh lebih kecil dibandingkan arsitektur seperti ResNet50 (± 23 juta parameter), namun tetap memiliki kemampuan representasi fitur yang baik [58].

Pada tahap transfer learning, lapisan dasar MobileNetV2 dibekukan (freeze) untuk mempertahankan fitur umum yang telah dipelajari dari dataset ImageNet. Selanjutnya ditambahkan lapisan klasifikasi baru berupa Global Average Pooling,

Dropout, dan Dense layer dengan aktivasi softmax sesuai dengan jumlah kelas kesegaran ikan.

Setelah proses pelatihan awal selesai, dilakukan tahap *fine-tuning* dengan membuka sebagian lapisan akhir (50 layer terakhir) untuk memungkinkan model beradaptasi lebih spesifik terhadap karakteristik visual dataset FFE. Strategi ini bertujuan meningkatkan performa tanpa menambah jumlah parameter secara signifikan. Proses pelatihan dilakukan menggunakan optimizer Adam dengan fungsi loss Sparse Categorical Crossentropy, yang sesuai untuk permasalahan klasifikasi multi-kelas dengan label dalam bentuk integer [87].

3.5.2 Teknik Evaluasi dan Validasi Model

Evaluasi model dilakukan untuk mengukur kemampuan klasifikasi terhadap tiga kelas kesegaran ikan, yaitu Highly Fresh, Fresh, dan Not Fresh. Evaluasi dilakukan menggunakan data uji yang terpisah dari proses pelatihan. Teknik evaluasi utama yang digunakan adalah confusion matrix, yang menampilkan jumlah prediksi benar dan salah untuk setiap kelas. Berdasarkan confusion matrix tersebut dihitung beberapa metrik evaluasi, yaitu:

1. Accuracy
2. Precision
3. Recall
4. F1-Score

Selain accuracy sebagai indikator performa keseluruhan, digunakan pula macro precision, macro recall, dan macro F1-score. Metrik macro dipilih karena memberikan bobot yang sama pada setiap kelas, sehingga lebih representatif dalam kondisi distribusi kelas yang tidak sepenuhnya seimbang [49]. Validasi model dilakukan menggunakan metode random hold-out sampling dengan proporsi 80% data latih, 10% data validasi, dan 10% data uji. Data validasi digunakan untuk memantau performa selama proses pelatihan serta membantu dalam mencegah *overfitting* melalui mekanisme early stopping dan penyesuaian learning rate. Sementara itu, data uji digunakan untuk evaluasi akhir yang bersifat objektif terhadap kemampuan generalisasi model [49]. Hasil evaluasi dari masing-masing

pendekatan dibandingkan untuk menentukan model yang paling efektif dan efisien dalam mengklasifikasikan kesegaran ikan berbasis citra digital.

3.5.3 Evaluasi Interpretabilitas Menggunakan Grad-CAM

Selain menggunakan metrik evaluasi kuantitatif seperti accuracy, precision, recall, F1-score, dan confusion matrix, penelitian ini juga melakukan evaluasi interpretabilitas model menggunakan metode Grad-CAM (Gradient-weighted Class Activation Mapping). Metode ini digunakan untuk memvisualisasikan area citra yang memberikan kontribusi terbesar terhadap keputusan klasifikasi yang dihasilkan model.

Proses visualisasi dilakukan dengan memanfaatkan gradien dari kelas target terhadap layer konvolusi terakhir pada model MobileNetV2. Hasil visualisasi berupa heatmap digunakan untuk menunjukkan area yang menjadi fokus perhatian model selama proses prediksi. Area dengan intensitas warna yang lebih tinggi menunjukkan kontribusi yang lebih besar terhadap hasil klasifikasi.

Untuk memperoleh analisis yang lebih komprehensif, visualisasi Grad-CAM dilakukan pada enam sampel citra yang terdiri atas tiga sampel dengan prediksi benar (correct classification) dan tiga sampel dengan prediksi salah (misclassification). Pemilihan kedua kondisi tersebut bertujuan untuk membandingkan pola perhatian model pada kasus yang berhasil maupun gagal diklasifikasikan.

Hasil visualisasi kemudian dianalisis untuk mengevaluasi apakah model memfokuskan perhatian pada area yang relevan dengan indikator kesegaran ikan, seperti kornea, pupil, dan refleksi cahaya. Melalui pendekatan ini, interpretabilitas model dapat ditingkatkan sehingga proses pengambilan keputusan model menjadi lebih mudah dipahami dan dievaluasi.

BAB IV

ANALISIS DAN HASIL PENELITIAN

Pada bab ini disajikan hasil penelitian serta analisis yang diperoleh dari penerapan metode yang telah dirancang pada bab sebelumnya. Penyajian hasil dilakukan berdasarkan tahapan dalam kerangka *Knowledge Discovery in Databases* (KDD) yang digunakan dalam penelitian. Melalui pendekatan tersebut, proses pengolahan data, pembangunan model, serta evaluasi hasil dapat dijelaskan secara sistematis sehingga hubungan antara setiap tahapan penelitian dengan hasil yang diperoleh dapat terlihat dengan jelas.

Pembahasan diawali dengan tahap *selection* untuk menjelaskan dataset yang digunakan dalam penelitian. Selanjutnya dilakukan tahap *preprocessing* yang meliputi validasi data, penyesuaian ukuran citra, normalisasi, dan augmentasi data. Setelah itu dijelaskan tahap *transformation* untuk menyiapkan data agar sesuai dengan kebutuhan model. Tahap berikutnya adalah *data mining*, yaitu proses pelatihan model MobileNetV2 menggunakan skenario *transfer learning* dan *fine-tuning*. Terakhir, pada tahap *evaluation and interpretation* dilakukan analisis performa model menggunakan metrik *accuracy*, *precision*, *recall*, *F1-score*, *confusion matrix*, serta visualisasi Grad-CAM untuk membantu interpretasi hasil prediksi model.

Melalui penyusunan berdasarkan tahapan KDD tersebut, hasil penelitian tidak hanya disajikan dalam bentuk nilai performa model, tetapi juga dianalisis berdasarkan proses yang memengaruhi hasil tersebut. Dengan demikian, pembahasan yang dilakukan dapat memberikan gambaran yang lebih komprehensif mengenai efektivitas metode yang digunakan, faktor-faktor yang berkontribusi terhadap peningkatan performa model, serta keterbatasan yang masih ditemukan selama penelitian.

4.1 Selection

Tahap *selection* dilakukan untuk menentukan data yang relevan dengan tujuan penelitian, yaitu klasifikasi tingkat kesegaran ikan berbasis citra mata ikan. Dataset yang digunakan merupakan *Freshness of Fish Eyes (FFE)* yang terdiri dari

tiga kelas kesegaran, yaitu *Fresh*, *HighlyFresh*, dan *NotFresh*. Setelah melalui proses validasi dan *data cleaning*, jumlah citra yang digunakan dalam penelitian ini adalah sebanyak 4.400 citra, yang terdiri atas 588 citra *Fresh*, 2.222 citra *HighlyFresh*, dan 1.590 citra *NotFresh*.

```
Folder kelas yang digunakan setelah cleaning:

Kelas: Fresh
Jumlah file valid: 588
Contoh file: ['Oreochromis Mossambicus - Fresh_IMG_20191113_054823.jpg', 'Oreochromis Mossambicus - Fresh_IMG_20191113_054712_2.jpg', 'Oreochromis Mossambicus - Fresh_IMG_20191113_055019_1.jpg', 'Johnius Trachycephalus - Fresh_IMG_20191016_065708.jpg', 'Chanos Chanos - Fresh_IMG_20191112_051910.jpg']


Kelas: HighlyFresh
Jumlah file valid: 2226
Contoh file: ['Oreochromis Niloticus - Highly Fresh_IMG_20191111_054650_6.jpg', 'Oreochromis Niloticus - Highly Fresh_IMG_20191001_064844.jpg', 'Rastrelliger Faughni - Highly Fresh_IMG_20191110_074835_mv1.jpg', 'Oreochromis Niloticus - Highly Fresh_IMG_20191111_054650_1.jpg', 'Rastrelliger Faughni - Highly Fresh_IMG_20191110_055522_5.jpg']

Kelas: NotFresh
Jumlah file valid: 1590
Contoh file: ['Rastrelliger Faughni - Not Fresh_IMG_20191114_061916.jpg', 'Chanos Chanos - Not Fresh_IMG_20191005_071854_mv1.jpg', 'Chanos Chanos - Not Fresh_IMG_20191114_054215.jpg', 'Oreochromis Mossambicus - Not Fresh_IMG_20191115_060007_1.jpg', 'Rastrelliger Faughni - Not Fresh_IMG_20191114_061342_mv1.jpg']
```

Gambar 4.1 Folder Kelas yang Digunakan

Gambar 4.1 menunjukkan struktur folder dataset setelah proses *cleaning*. Seluruh citra yang digunakan telah melalui proses validasi, sehingga hanya file yang dapat dibaca dan sesuai format yang dipertahankan. Hal ini memastikan bahwa tidak terdapat gangguan teknis pada saat proses pelatihan model. Pemilihan citra mata ikan sebagai objek penelitian didasarkan pada karakteristik visual yang berkaitan langsung dengan tingkat kesegaran. Perubahan pada kejernihan kornea, pola refleksi cahaya, dan tekstur permukaan mata menjadi indikator utama yang digunakan dalam proses klasifikasi. Dengan memfokuskan analisis pada area mata, model dapat mempelajari fitur yang lebih spesifik dan relevan terhadap tujuan penelitian.


Distribusi kelas:
Fresh: 588
HighlyFresh: 2226
NotFresh: 1590



Gambar 4.2 Distribusi Kelas Dataset

Distribusi kelas pada dataset akhir ditampilkan pada Gambar 4.2. Terlihat bahwa jumlah data antar kelas tidak seimbang (*class imbalance*), di mana kelas Highly Fresh memiliki jumlah citra paling besar, diikuti oleh Not Fresh, sedangkan Fresh memiliki jumlah citra paling sedikit. Kondisi ini menunjukkan bahwa model berpotensi lebih banyak mempelajari pola dari kelas mayoritas dibandingkan kelas minoritas.

Ketidakseimbangan kelas dapat memengaruhi performa model, terutama pada kemampuan dalam mengenali kelas dengan jumlah data yang lebih sedikit. Oleh karena itu, evaluasi model dalam penelitian ini tidak hanya menggunakan *accuracy*, tetapi juga *precision*, *recall*, dan *F1-score* untuk memberikan gambaran performa yang lebih representatif pada setiap kelas. Dengan demikian, hasil evaluasi dapat diinterpretasikan secara lebih objektif meskipun distribusi data tidak sepenuhnya seimbang.



Gambar 4.3 Distribusi Jumlah Citra Spesies Ikan

Selain berdasarkan tingkat kesegaran, dataset juga terdiri dari beberapa spesies ikan. Variasi ini menunjukkan bahwa data memiliki keragaman visual yang cukup tinggi. Namun demikian, penelitian ini tidak berfokus pada klasifikasi spesies, melainkan pada tingkat kesegaran. Oleh karena itu, seluruh citra digabung berdasarkan label kesegaran untuk menjaga fokus permasalahan dan menyederhanakan kompleksitas model. Pendekatan ini memungkinkan model untuk mempelajari karakteristik visual yang berkaitan dengan kesegaran ikan tanpa dipengaruhi oleh perbedaan karakteristik antar spesies.

Selain dilakukan analisis distribusi Jumlah Citra Spesies Ikan, dilakukan pula pengamatan terhadap karakteristik visual setiap kelas kesegaran. Pada kelas Highly Fresh, mata ikan umumnya memiliki kornea yang jernih, refleksi cahaya yang kuat, serta warna yang relatif cerah. Pada kelas Fresh, kejernihan kornea mulai berkurang dan refleksi cahaya terlihat lebih lemah. Sementara itu, pada kelas Not Fresh, kornea cenderung lebih keruh, warna mata lebih gelap, dan refleksi cahaya semakin berkurang. Perbedaan karakteristik visual ini menjadi dasar yang digunakan model dalam membedakan tingkat kesegaran ikan.

4.2 Preprocessing (Prapemrosesan dan Kesiapan Data)

Tahap preprocessing dilakukan untuk memastikan bahwa seluruh citra berada dalam kondisi yang seragam dan sesuai dengan spesifikasi input MobileNetV2. Pada tahap ini, setiap citra diproses agar memiliki ukuran, format warna, dan distribusi nilai piksel yang konsisten sehingga dapat digunakan secara optimal

dalam proses pelatihan model. Proses preprocessing yang dilakukan meliputi beberapa tahapan utama, yaitu resizing citra menjadi 224×224 piksel, konversi format warna ke RGB, normalisasi nilai piksel, serta validasi data untuk menghapus citra yang tidak valid. Setiap tahapan dirancang untuk mengurangi variasi teknis pada data sehingga model dapat lebih fokus dalam mempelajari pola visual yang relevan dengan tingkat kesegaran ikan.

4.2.4 Data Cleaning (Validasi dan Penghapusan File Corrupt)


Tahap data cleaning dilakukan untuk memastikan bahwa seluruh citra dalam dataset berada dalam kondisi valid dan dapat diproses tanpa error selama pelatihan model. Proses ini mencakup pemeriksaan file untuk mendeteksi citra yang rusak (corrupt), tidak dapat dibaca, atau tidak sesuai format. Hasil validasi dataset dirangkum pada Tabel 4.2. Tahap ini penting karena kualitas data yang digunakan akan secara langsung memengaruhi stabilitas dan performa model selama proses pelatihan.

Tabel 4.1 Hasil Validasi dan Pembersihan Dataset

<i>No</i>	<i>Kategori</i>	<i>Jumlah</i>
1	<i>Total dataset awal</i>	4404
2	<i>Zero-byte files</i>	0
3	<i>Non-image files</i>	0
4	<i>Corrupt files</i>	10
5	<i>Dataset final (valid)</i>	4390

Berdasarkan Tabel 4.2, tidak ditemukan file dengan ukuran nol maupun file non-citra. Namun, terdapat 10 file corrupt yang tidak dapat dibaca oleh sistem. Seluruh file tersebut dihapus untuk mencegah gangguan pada proses pelatihan. Proses data cleaning pada penelitian ini difokuskan pada validasi integritas file untuk memastikan bahwa seluruh citra dapat dibaca dan diproses dengan baik oleh sistem. Analisis terhadap citra blur maupun duplikasi citra tidak dilakukan secara

khusus, sehingga aspek tersebut menjadi salah satu keterbatasan penelitian yang dapat dikembangkan lebih lanjut pada penelitian berikutnya.



Gambar 4.4 Distribusi File Bermasalah pada Tahap Data Cleaning


Distribusi file bermasalah pada Gambar 4.9 menunjukkan bahwa seluruh error berasal dari kategori file corrupt, tanpa adanya zero-byte maupun file non-citra. Temuan ini menunjukkan bahwa kualitas dataset secara umum sudah cukup baik karena sebagian besar file berada dalam kondisi valid. Dengan demikian, proses data cleaning memastikan bahwa seluruh citra yang digunakan dalam penelitian merupakan data yang layak untuk diproses lebih lanjut. Kondisi tersebut membantu menjaga stabilitas proses pelatihan serta mengurangi risiko terjadinya kesalahan yang disebabkan oleh data yang tidak valid.

Selain validasi integritas file, dilakukan inspeksi visual secara acak terhadap sampel citra dari setiap kelas untuk memastikan bahwa objek mata ikan masih dapat diamati dengan jelas. Hasil inspeksi menunjukkan bahwa sebagian besar citra memiliki kualitas visual yang memadai untuk proses klasifikasi. Meskipun demikian, variasi pencahayaan, sudut pengambilan gambar, dan tingkat ketajaman citra masih ditemukan pada beberapa sampel, yang berpotensi memengaruhi proses ekstraksi fitur oleh model.

4.2.1 Resize (Penyeragaman Ukuran Citra)

Hasil inspeksi awal menunjukkan bahwa seluruh citra pada dataset memiliki ukuran yang seragam, yaitu 323×315 piksel. Meskipun tidak terdapat variasi ukuran antar citra, dimensi tersebut belum sesuai dengan spesifikasi input MobileNetV2 yang membutuhkan ukuran 224×224 piksel. Oleh karena itu, seluruh citra diubah ukurannya menjadi 224×224 piksel agar dapat digunakan sebagai masukan model. Proses resize dilakukan untuk memastikan kesesuaian dimensi input sekaligus menjaga konsistensi representasi data selama proses pelatihan.

Analisis distribusi ukuran citra menunjukkan bahwa dataset tidak memiliki variasi resolusi karena seluruh citra memiliki dimensi yang sama, yaitu 323×315 piksel. Kondisi ini menunjukkan bahwa proses akuisisi data pada dataset FFE telah dilakukan secara konsisten. Dengan demikian, tujuan utama resize pada penelitian ini bukan untuk menyeragamkan ukuran citra yang berbeda-beda, melainkan untuk menyesuaikan ukuran citra dengan kebutuhan arsitektur MobileNetV2.




Gambar 4.5 Output Shape Batch Data Sebelum dan Setelah Resize

Berdasarkan Gambar 4.4, proses resizing tidak mengubah struktur utama objek pada citra, melainkan hanya menyesuaikan dimensi gambar agar seragam. Setelah proses resize, seluruh citra memiliki ukuran (224, 224, 3), di mana 224 menunjukkan tinggi dan lebar citra, sedangkan angka 3 menunjukkan tiga kanal warna RGB (*Red, Green, Blue*). Penyeragaman ukuran ini penting untuk memastikan seluruh data memenuhi spesifikasi input MobileNetV2 sehingga proses ekstraksi fitur dan pelatihan model dapat dilakukan secara konsisten.

4.2.2 Konversi ke Format RGB

Tahap berikutnya adalah memastikan bahwa seluruh citra berada dalam format RGB dengan tiga channel warna. Hal ini diperlukan karena arsitektur MobileNetV2 dirancang untuk menerima input citra dengan tiga channel. Jika terdapat citra dengan jumlah channel berbeda, maka dapat terjadi ketidaksesuaian dimensi pada saat proses pelatihan. Untuk menjaga konsistensi format, seluruh citra dikonversi ke RGB pada saat proses pemuatan dataset menggunakan parameter `color_mode="rgb"`. Dengan pendekatan ini, setiap citra dipastikan memiliki tiga channel warna yang seragam, sehingga dapat diproses secara langsung oleh model tanpa memerlukan penyesuaian tambahan.



Gambar 4.6 Visualisasi Citra dalam Format RGB

Gambar 4.5 menampilkan representasi citra dalam tiga channel warna, yaitu red, green, dan blue. Setiap channel merepresentasikan intensitas warna dalam

bentuk citra grayscale, di mana nilai piksel yang lebih tinggi menunjukkan intensitas warna yang lebih kuat pada channel tersebut. Selain itu, histogram pada masing-masing channel menunjukkan distribusi nilai piksel yang berbeda. Perbedaan distribusi ini mengindikasikan bahwa setiap channel menyimpan informasi visual yang saling melengkapi. Variasi intensitas warna dan pencahayaan pada area mata ikan menjadi salah satu faktor penting dalam membedakan tingkat kesegaran. Dengan penggunaan format RGB yang konsisten, model dapat memanfaatkan informasi warna secara optimal dalam proses ekstraksi fitur, sehingga meningkatkan kemampuan dalam membedakan karakteristik visual antar kelas kesegaran.

4.2.3 Normalisasi Nilai Piksel


Sebelum normalisasi, nilai piksel citra berada pada rentang 0–255 dengan hasil inspeksi menunjukkan rentang aktual 37 hingga 255, rata-rata 113,73, dan standar deviasi 42,76. Rentang ini relatif lebar dan dapat menyebabkan perbedaan skala antar citra selama proses pelatihan model. Untuk menyesuaikan dengan preprocessing standar MobileNetV2, nilai piksel kemudian dinormalisasi ke dalam rentang -1 hingga 1. Setelah normalisasi, diperoleh rentang nilai -0,71 hingga 1,00, dengan rata-rata -0,11 dan standar deviasi 0,34. Transformasi ini bertujuan untuk meningkatkan stabilitas proses optimasi serta membantu model dalam mempelajari pola visual secara lebih efektif.



Gambar 4.7 Perbandingan Citra Sebelum dan Sesudah Normalisasi


Berdasarkan Gambar 4.6, normalisasi tidak mengubah struktur visual citra secara signifikan, tetapi hanya mengubah representasi numerik dari nilai piksel. Hal

ini menunjukkan bahwa informasi visual utama tetap dipertahankan selama proses transformasi data. Perubahan yang terjadi hanya pada skala intensitas piksel yang digunakan sebagai masukan model. Dengan demikian, karakteristik visual yang berkaitan dengan tingkat kesegaran ikan tetap dapat dipelajari tanpa kehilangan informasi penting.



Gambar 4.8 Histogram Distribusi Nilai Piksel

Histogram pada Gambar 4.7 menunjukkan bahwa distribusi nilai piksel sebelum normalisasi berada pada skala 0–255, sedangkan setelah normalisasi berpindah ke skala -1 hingga 1. Bentuk distribusi tetap relatif sama karena transformasi yang dilakukan bersifat linear. Meskipun demikian, perubahan skala tersebut membuat data menjadi lebih sesuai dengan kebutuhan input MobileNetV2 yang telah dilatih menggunakan preprocessing serupa. Kondisi ini membantu mempercepat proses konvergensi model dan meningkatkan stabilitas selama pelatihan.



Gambar 4.9 Mapping Pixel Sebelum vs Sesudah

Hubungan antara nilai piksel sebelum dan sesudah normalisasi ditunjukkan pada Gambar 4.8. Terlihat bahwa transformasi bersifat linear, di mana setiap nilai piksel diskalakan secara proporsional tanpa mengubah hubungan relatif antar nilai. Karakteristik tersebut menunjukkan bahwa proses normalisasi tidak menyebabkan distorsi maupun perubahan pola distribusi data secara signifikan. Dengan demikian, informasi yang terkandung dalam citra tetap terjaga dan dapat dimanfaatkan secara optimal oleh model selama proses pembelajaran.

UMN
UNIVERSITAS
MULTIMEDIA
NUSANTARA

Tabel 4.2 Perubahan Nilai Piksel Sebelum dan Sesudah Normalisasi

<i>No</i>	<i>R Sebelum</i>	<i>G Sebelum</i>	<i>B Sebelum</i>	<i>R Sesudah</i>	<i>G Sesudah</i>	<i>B Sesudah</i>
1	125.0	86.0	72.0	-0.0196	-0.3255	-0.4353
2	171.0	128.0	111.0	0.3412	0.0039	-0.1294
3	184.0	192.0	195.0	0.4431	0.5059	0.5294
4	90.0	75.0	74.0	-0.2941	-0.4118	-0.4196
5	88.0	69.0	63.0	-0.3098	-0.4588	-0.5059
6	109.0	79.0	69.0	-0.1451	-0.3804	-0.4588
7	145.0	153.0	155.0	0.1373	0.2000	0.2157
8	97.0	79.0	75.0	-0.2392	-0.3804	-0.4118
9	160.0	128.0	107.0	0.2549	0.0039	-0.1608
10	179.0	186.0	192.0	0.4039	0.4588	0.5059

Tabel 4.2 menunjukkan contoh perubahan nilai piksel RGB sebelum dan sesudah proses normalisasi. Nilai piksel awal berada pada rentang 0–255, kemudian ditransformasikan ke rentang -1 hingga 1 menggunakan fungsi *preprocess_input()* yang digunakan oleh MobileNetV2. Sebagai contoh, nilai kanal R sebesar 125 pada baris pertama berubah menjadi -0,0196 setelah normalisasi, sedangkan nilai yang lebih tinggi seperti 184 berubah menjadi 0,4431. Perubahan ini menunjukkan bahwa proses normalisasi mengubah skala nilai piksel tanpa mengubah hubungan relatif antar piksel. Dengan demikian, distribusi intensitas citra tetap dipertahankan, namun dalam rentang yang lebih sesuai dengan kebutuhan model MobileNetV2. Normalisasi ini membantu meningkatkan stabilitas proses pelatihan karena distribusi data input menjadi lebih konsisten dengan distribusi data yang digunakan pada tahap pretraining, sehingga proses optimisasi dapat berlangsung lebih stabil dan konvergensi model dapat dicapai dengan lebih baik.

4.3 Transformation (Transformasi Data dan Kesiapan untuk Training MobileNetV2)

4.3.1 Data Labelling (Integer Encoding)

Pada penelitian ini, proses pelabelan data dilakukan secara otomatis berdasarkan struktur direktori dataset. Setiap folder merepresentasikan satu kelas kesegaran ikan, yaitu Fresh, HighlyFresh, dan NotFresh. Dengan menggunakan fungsi `image_dataset_from_directory()`, sistem secara langsung membaca struktur folder dan mengonversi label ke dalam bentuk bilangan bulat (integer encoding). Pendekatan ini mempermudah proses pengelolaan dataset serta memastikan bahwa label yang digunakan selama pelatihan model bersifat konsisten dan terstandarisasi.

Skema Integer Encoding Label

Mapping Label Integer ke Nama Kelas

0 → Fresh
1 → HighlyFresh
2 → NotFresh


Gambar 4.10 Hasil Encoding Label

Berdasarkan Gambar 4.10, setiap kelas dipetakan ke dalam indeks numerik, yaitu 0 untuk Fresh, 1 untuk HighlyFresh, dan 2 untuk NotFresh. Representasi ini digunakan sebagai format label selama proses pelatihan model. Penggunaan integer encoding diperlukan karena algoritma *deep learning* tidak dapat memproses label dalam bentuk teks secara langsung. Dengan demikian, proses pelabelan yang telah dikonversi ke format numerik memungkinkan model melakukan proses pembelajaran dan perhitungan loss secara lebih efisien.

```
Label batch shuffled (integer):  
[2, 1, 1, 0, 2, 1, 1, 2, 2, 1, 2, 2, 2, 1, 1, 2, 2, 1, 0, 1, 1, 1, 1, 2, 1, 1, 1, 0, 1, 1, 1, 2]  
  
Decoded class names:  
['NotFresh', 'HighlyFresh', 'HighlyFresh', 'Fresh', 'NotFresh', 'HighlyFresh', 'HighlyFresh', 'NotFresh', 'NotFresh', 'HighlyFresh', 'NotFresh', 'NotFresh', 'NotFresh', 'NotFresh', 'NotFresh', 'HighlyFresh', 'HighlyFresh']
```

Gambar 4.11 Label Batch Shuffled

Gambar 4.11 menunjukkan bahwa label pada setiap batch telah diacak (shuffled). Proses ini memastikan bahwa distribusi data dalam batch tidak terkelompok berdasarkan kelas sehingga model belajar dari pola visual, bukan urutan data. Pengacakan data juga membantu mengurangi potensi bias selama proses pelatihan karena setiap batch memiliki kombinasi sampel yang lebih beragam. Dengan demikian, model diharapkan memiliki kemampuan generalisasi yang lebih baik ketika dihadapkan pada data baru yang belum pernah dilihat sebelumnya.



Gambar 4.12 Informasi Kelas Dataset

Berdasarkan Gambar 4.12, sistem mendeteksi tiga kelas utama pada dataset, yaitu *Fresh*, *HighlyFresh*, dan *NotFresh*. Informasi ini digunakan dalam konfigurasi layer output pada model. Penggunaan integer encoding disesuaikan dengan fungsi loss yang digunakan, yaitu *Sparse Categorical Crossentropy*,

sehingga label dapat digunakan secara langsung tanpa konversi tambahan. Selain itu, pelabelan otomatis berbasis struktur folder memastikan konsistensi label pada seluruh dataset. Dengan demikian, proses pelabelan menghasilkan representasi label yang sederhana, konsisten, dan sesuai dengan kebutuhan pelatihan model.

4.3.2 Data Augmentation


Pada penelitian ini, augmentasi data diterapkan untuk meningkatkan keberagaman data latih serta mengatasi keterbatasan variasi citra yang dapat menyebabkan model mengalami overfitting. Proses augmentasi dilakukan secara dinamis menggunakan beberapa teknik transformasi citra. Untuk memudahkan analisis, hasil augmentasi yang diterapkan pada penelitian ini dikelompokkan berdasarkan tingkat perubahan visual yang dihasilkan. Beberapa teknik seperti *horizontal flip*, *rotation*, dan *zoom* menghasilkan perubahan yang relatif ringan terhadap citra asli, sedangkan *brightness adjustment* dan *combined augmentation* menghasilkan perubahan visual yang lebih besar. Pengelompokan ini digunakan untuk menjelaskan karakteristik hasil augmentasi dan bukan sebagai skenario pelatihan yang berbeda.

Tabel 4.3 Parameter Data Augmentation

No	Teknik Augmentasi	Nilai Parameter	Tujuan
1	Horizontal Flip	Horizontal	Mensimulasikan perubahan orientasi lateral objek
2	Rotation	20°	Mensimulasikan variasi sudut pengambilan gambar
3	Zoom	20% (Zoom-in)	Mensimulasikan variasi jarak pengambilan gambar
4	Brightness Adjustment	+30%	Mensimulasikan variasi kondisi pencahayaan
5	Combined Augmentation	Flip + Rotation + Zoom + Brightness	Mensimulasikan kondisi variasi kompleks secara bersamaan

Nilai parameter augmentasi ditentukan berdasarkan pertimbangan agar variasi citra yang dihasilkan tetap merepresentasikan kondisi nyata pada proses


pengambilan gambar ikan. Rotasi sebesar 20° dipilih untuk mensimulasikan perubahan sudut pengambilan gambar tanpa mengubah orientasi objek secara berlebihan. Zoom sebesar 20% digunakan untuk mensimulasikan variasi jarak kamera terhadap objek, sedangkan peningkatan kecerahan sebesar 30% digunakan untuk merepresentasikan variasi kondisi pencahayaan yang umum ditemukan pada lingkungan pengambilan citra. Pemilihan parameter yang terlalu besar berpotensi menghasilkan distorsi visual yang tidak realistis dan dapat mengurangi kualitas proses pembelajaran model.



Gambar 4.13 menunjukkan hasil augmentasi dengan perubahan visual yang relatif ringan, yaitu horizontal flip, rotation, dan zoom.

Augmentasi normal ditunjukkan pada Gambar 4.13, yang terdiri dari transformasi dengan tingkat perubahan yang relatif kecil dan masih mendekati kondisi asli citra. Pada augmentasi horizontal flip, orientasi objek diubah secara lateral tanpa mengubah struktur visual utama. Transformasi ini menyebabkan model tidak bergantung pada posisi objek tertentu, sehingga meningkatkan kemampuan generalisasi terhadap arah pengambilan gambar. Pada augmentasi rotasi sebesar $\pm 20^\circ$, objek mengalami perubahan sudut yang masih dalam batas realistis. Struktur mata ikan seperti kornea dan pupil tetap terlihat jelas. Hal ini

memungkinkan model tetap mengenali objek meskipun terjadi perubahan sudut pandang. Pada augmentasi zoom sebesar 20%, area mata diperbesar sehingga fitur utama menjadi lebih dominan. Dampaknya, model menjadi lebih fokus pada bagian penting seperti kejernihan mata dan refleksi cahaya. Secara keseluruhan, augmentasi normal menghasilkan variasi citra yang masih sangat menyerupai kondisi asli. Oleh karena itu, augmentasi ini berperan dalam membantu model memahami pola dasar tanpa menyebabkan distorsi visual yang signifikan.



Gambar 4. 14 menunjukkan hasil augmentasi dengan perubahan visual yang lebih besar, yaitu brightness adjustment dan combined augmentation.

Augmentasi signifikan ditunjukkan pada Gambar 4.14, yang menghasilkan perubahan citra yang lebih kuat dibandingkan augmentasi normal. Pada augmentasi brightness sebesar +30%, terjadi peningkatan intensitas cahaya yang cukup tinggi. Perubahan ini menyebabkan area refleksi pada mata menjadi lebih terang, sehingga mempengaruhi persepsi kejernihan mata. Kondisi ini penting karena indikator kesegaran ikan sangat dipengaruhi oleh pencahayaan. Pada augmentasi kombinasi (*all combined*), beberapa transformasi diterapkan secara bersamaan, yaitu flip, rotasi, zoom, dan brightness. Kombinasi ini menghasilkan citra dengan kondisi yang lebih kompleks, seperti perubahan sudut, pencahayaan, dan skala secara

simultan. Akibat dari augmentasi signifikan, citra menjadi lebih bervariasi dan tidak selalu menyerupai kondisi ideal. Hal ini memaksa model untuk belajar mengenali pola penting meskipun terdapat gangguan visual. Dengan demikian, model menjadi lebih robust terhadap variasi kondisi input. Perbedaan utama antara augmentasi normal dan augmentasi signifikan terletak pada tingkat perubahan citra yang dihasilkan. Pada augmentasi normal, perubahan yang diberikan bersifat ringan sehingga struktur visual tetap sangat mirip dengan citra asli. Akibatnya, model lebih mudah mempelajari pola dasar, namun variasi yang dihasilkan masih terbatas.

Sebaliknya, pada augmentasi signifikan, perubahan citra bersifat lebih kompleks dan bervariasi. Hal ini menyebabkan model dipaksa untuk mengenali fitur yang lebih esensial, bukan hanya pola visual sederhana. Namun, jika augmentasi dilakukan secara berlebihan, terdapat risiko distorsi citra yang tidak realistis. Kondisi ini dapat menyebabkan model mempelajari pola yang tidak relevan. Oleh karena itu, parameter augmentasi dipilih dalam batas yang masih representatif terhadap kondisi nyata. Dengan penerapan dua tingkat augmentasi ini, model tidak hanya dilatih menggunakan data dengan variasi ringan, tetapi juga pada kondisi yang lebih kompleks. Penerapan augmentasi bertujuan untuk meningkatkan variasi data latih sehingga model memperoleh lebih banyak variasi kondisi citra selama proses pembelajaran. Dengan variasi data yang lebih beragam, model diharapkan memiliki kemampuan generalisasi yang lebih baik terhadap data yang belum pernah dilihat sebelumnya.

4.3.3 Data Splitting

Dataset yang telah melalui tahap transformasi kemudian dibagi ke dalam tiga subset utama, yaitu data latih (*training*), data validasi (*validation*), dan data uji (*test*). Pembagian ini dilakukan untuk memastikan bahwa proses pelatihan dan evaluasi model berlangsung secara terpisah, sehingga kemampuan generalisasi model dapat diukur secara objektif.

Berdasarkan hasil pembagian, dari total 4.390 citra diperoleh:

- Data latih: 3.512 citra (80%)


- Data validasi: 439 citra (10%)
- Data uji: 439 citra (10%)

Distribusi jumlah data per kelas pada masing-masing subset ditunjukkan pada Tabel 4.4.

Tabel 4.4 Distribusi Jumlah Data per Kelas pada Setiap Subset

Kelas	Train	Validation	Test
<i>Fresh</i>	<i>1056</i>	<i>132</i>	<i>132</i>
<i>HighlyFresh</i>	<i>1411</i>	<i>176</i>	<i>177</i>
<i>NotFresh</i>	<i>1045</i>	<i>131</i>	<i>130</i>

Untuk memberikan gambaran komposisi data secara keseluruhan, distribusi kelas pada setiap subset ditampilkan dalam bentuk diagram batang pada Gambar 4.15.



Gambar 4.15 Komposisi Kelas pada Setiap Subset

Visualisasi tersebut menunjukkan bahwa distribusi kelas pada data latih, data validasi, dan data uji tetap mempertahankan proporsi yang serupa dengan distribusi dataset asli. Kelas HighlyFresh memiliki jumlah data paling banyak, sedangkan kelas Fresh dan NotFresh memiliki jumlah data yang relatif mendekati satu sama lain. Konsistensi distribusi ini menunjukkan bahwa proses pembagian data berhasil mempertahankan karakteristik dataset pada setiap subset sehingga proses pelatihan dan evaluasi dapat dilakukan secara lebih representatif.

Berdasarkan hasil pembagian data, proporsi kelas pada dataset berada pada kisaran:

- Fresh = 30%

- HighlyFresh = 40%
- NotFresh = 30%

Meskipun distribusi kelas tidak sepenuhnya seimbang, proporsi kelas pada setiap subset tetap terjaga sehingga tidak terjadi dominasi kelas tertentu akibat proses pembagian data. Oleh karena itu, selain menggunakan metrik accuracy, penelitian ini juga menggunakan macro precision, macro recall, dan macro F1-score untuk memberikan evaluasi performa yang lebih representatif terhadap seluruh kelas.

4.4 Data Modelling (Pemodelan, Transfer Learning, dan *Fine-tuning* MobileNetV2)

4.4.1 Arsitektur MobileNetV2 sebagai Base Model

Pada penelitian ini, model klasifikasi dibangun menggunakan arsitektur MobileNetV2 sebagai *backbone* utama dengan ukuran input 224×224 piksel dan tiga kanal warna RGB. MobileNetV2 digunakan sebagai ekstraktor fitur untuk menangkap karakteristik visual yang berkaitan dengan tingkat kesegaran ikan berdasarkan citra mata ikan. Arsitektur ini dipilih karena memiliki jumlah parameter yang relatif kecil dibandingkan model CNN yang lebih kompleks, namun tetap mampu menghasilkan performa klasifikasi yang baik. Struktur arsitektur model yang digunakan ditunjukkan pada Tabel 4.5.



Tabel 4.5 Arsitektur Model MobileNetV2

NO	LAYER	OUTPUT SHAPE	PARAMETER	KETERANGAN
1	INPUT LAYER	(224, 224, 3)	0	INPUT CITRA RGB
2	MOBILENETV2 (BACKBONE)	(7, 7, 1280)	2.257.984	EKSTRAKSI FITUR CITRA
3	GLOBAL AVERAGE POOLING	(1280)	0	REDUKSI DIMENSI FITUR
4	DROPOUT	(1280)	0	REGULARISASI UNTUK MENGURANGI OVERFITTING
5	DENSE (SOFTMAX)	(3)	3.843	OUTPUT KLASIFIKASI (3 KELAS)

Keterangan: Keterangan: Parameter menunjukkan jumlah bobot (*weights*) dan bias yang digunakan oleh setiap layer selama proses pembelajaran model.

Berdasarkan Tabel 4.5, citra input terlebih dahulu diproses oleh *backbone* MobileNetV2 untuk menghasilkan representasi fitur berdimensi $7 \times 7 \times 1280$. Representasi fitur tersebut kemudian direduksi menggunakan *Global Average Pooling* sehingga menghasilkan vektor satu dimensi yang lebih ringkas. Selanjutnya, vektor fitur diteruskan ke *Dropout Layer* untuk membantu mengurangi risiko *overfitting*, sebelum akhirnya diproses oleh *Dense Layer* dengan fungsi aktivasi *softmax* untuk menghasilkan probabilitas klasifikasi ke dalam tiga kelas, yaitu Highly Fresh, Fresh, dan Not Fresh.

Jumlah parameter terbesar terdapat pada *backbone* MobileNetV2, yaitu sebanyak 2.257.984 parameter yang berfungsi untuk mengekstraksi fitur visual dari citra mata ikan. Sementara itu, *Dense Layer* memiliki 3.843 parameter yang digunakan untuk memetakan fitur hasil ekstraksi ke dalam tiga kelas keluaran. Jumlah parameter tersebut menunjukkan kapasitas model dalam mempelajari pola visual yang berkaitan dengan tingkat kesegaran ikan.

Pada tahap *transfer learning*, seluruh layer pada *backbone* MobileNetV2 dibekukan (*freeze*) sehingga parameter pada *backbone* tidak diperbarui selama proses pelatihan. Dengan pendekatan ini, model memanfaatkan fitur generik yang telah dipelajari sebelumnya melalui proses *pretraining* pada dataset ImageNet. Setelah diperoleh performa dasar (*baseline*), dilakukan tahap *fine-tuning* dengan membuka kembali sebagian layer pada *backbone* MobileNetV2 sehingga parameter tertentu dapat diperbarui sesuai karakteristik dataset penelitian.

Pendekatan *fine-tuning* digunakan untuk meningkatkan kemampuan model dalam mempelajari fitur yang lebih spesifik terhadap citra mata ikan. Dengan demikian, penelitian ini dapat membandingkan performa antara model yang hanya memanfaatkan fitur generik hasil *pretraining* (*transfer learning*) dan model yang telah menyesuaikan representasi fiturnya terhadap domain data yang digunakan (*fine-tuning*).

4.4.2 Pelatihan Model Menggunakan Transfer Learning

Konfigurasi pelatihan pada penelitian ini dirancang untuk membandingkan dua skenario utama, yaitu *transfer learning* dan *fine-tuning*. Perbedaan utama kedua skenario terletak pada strategi pembaruan bobot pada *backbone* MobileNetV2 dan nilai *learning rate* yang digunakan selama proses pelatihan. Perbandingan ini dilakukan untuk mengevaluasi sejauh mana proses *fine-tuning* mampu meningkatkan kemampuan model dalam mempelajari karakteristik visual kesegaran ikan dibandingkan pendekatan *transfer learning* standar.

Tabel 4.6 Konfigurasi Pelatihan Model

Parameter	Transfer Learning	<i>Fine-tuning</i>
Optimizer	Adam	Adam
Loss Function	Sparse Categorical Crossentropy	Sparse Categorical Crossentropy
Batch Size	32	32
Epochs	30	30
Learning Rate	3×10^{-4}	1×10^{-5}
Learning Rate Strategy	Fixed	ReduceLROnPlateau
Backbone	Frozen (tidak dilatih)	Partial Unfreeze
Callback	EarlyStopping, ReduceLROnPlateau, ModelCheckpoint	EarlyStopping, ReduceLROnPlateau, ModelCheckpoint

Tabel 4.6 menunjukkan konfigurasi pelatihan yang digunakan pada skenario *transfer learning* dan *fine-tuning*. Pada tahap *transfer learning*, seluruh layer pada *backbone* MobileNetV2 dibekukan (*frozen*) sehingga hanya layer klasifikasi yang diperbarui selama proses pelatihan. Sebaliknya, pada tahap *fine-tuning*, sebagian layer *backbone* dibuka kembali (*partial unfreeze*) sehingga model dapat menyesuaikan representasi fitur dengan karakteristik citra mata ikan yang digunakan dalam penelitian.

Selain perbedaan pada status *backbone*, kedua skenario juga menggunakan nilai *learning rate* yang berbeda. Tahap *transfer learning* menggunakan *learning rate* sebesar 3×10^{-4} (0,0003) untuk mempercepat proses adaptasi pada layer klasifikasi. Sementara itu, tahap *fine-tuning* menggunakan *learning rate* yang lebih kecil, yaitu 1×10^{-5} (0,00001), agar pembaruan bobot berlangsung lebih stabil dan tidak merusak fitur yang telah dipelajari sebelumnya pada tahap *pretraining*.

Penggunaan *learning rate* yang lebih kecil pada tahap *fine-tuning* memungkinkan model melakukan penyesuaian fitur secara bertahap terhadap karakteristik visual kesegaran ikan. Dengan demikian, model dapat mempertahankan pengetahuan umum yang diperoleh dari dataset ImageNet sekaligus mempelajari pola visual yang lebih spesifik sesuai dengan domain penelitian.

Tabel 4.7 Detail Konfigurasi Training

Setting	Value
<i>Framework</i>	TensorFlow / Keras
<i>Pre-trained Model</i>	MobileNetV2
<i>Input Size</i>	224 × 224 piksel
<i>Data Augmentation</i>	Rotation, Flip, Brightness, Zoom
<i>Early Stopping Patience</i>	10 epoch
<i>Model Checkpoint</i>	Save Best Model
Estimasi Waktu Training	15–20 menit
Penggunaan Memori	±2–4 GB


Tabel 4.8 menunjukkan lingkungan dan konfigurasi pelatihan yang digunakan selama penelitian. Pemilihan konfigurasi tersebut didasarkan pada karakteristik dataset yang memiliki variasi visual yang cukup tinggi serta jumlah data yang relatif terbatas dibandingkan dataset ImageNet yang digunakan pada tahap *pretraining*. Oleh karena itu, kombinasi *transfer learning* dan *fine-tuning* dipilih untuk memanfaatkan pengetahuan awal yang telah dimiliki model sekaligus menyesuaikannya dengan domain klasifikasi kesegaran ikan.

Untuk menjaga stabilitas proses pelatihan, digunakan beberapa *callback* seperti *EarlyStopping*, *ReduceLROnPlateau*, dan *ModelCheckpoint*. *EarlyStopping* berfungsi menghentikan proses pelatihan secara otomatis ketika tidak lagi terjadi peningkatan performa validasi yang signifikan. Sementara itu, *ReduceLROnPlateau* digunakan untuk menurunkan *learning rate* secara otomatis ketika *validation loss* mengalami stagnasi, sehingga proses optimasi dapat berlangsung lebih stabil. Adapun *ModelCheckpoint* digunakan untuk menyimpan model terbaik yang diperoleh selama proses pelatihan berdasarkan performa validasi.

Secara keseluruhan, konfigurasi pelatihan yang digunakan dirancang untuk menghasilkan proses pembelajaran yang stabil, efisien, dan mampu memanfaatkan keunggulan *transfer learning* maupun *fine-tuning*. Hasil dari kedua skenario tersebut selanjutnya akan dievaluasi dan dibandingkan pada subbab berikutnya untuk mengetahui pengaruh *fine-tuning* terhadap performa klasifikasi kesegaran ikan.

4.4.3 Hasil Skenario 1: Transfer Learning (Tanpa *Fine-tuning*)

Pada skenario pertama, model dilatih menggunakan pendekatan transfer learning dengan seluruh layer backbone MobileNetV2 dipertahankan dalam kondisi non-trainable. Dengan konfigurasi ini, proses pembelajaran hanya dilakukan pada layer klasifikasi di bagian akhir model. Pendekatan tersebut digunakan sebagai baseline untuk mengevaluasi sejauh mana fitur generik hasil *pretraining* pada ImageNet dapat dimanfaatkan untuk klasifikasi tingkat kesegaran ikan. Hasil dari skenario ini kemudian digunakan sebagai acuan untuk menilai efektivitas proses *fine-tuning* dalam meningkatkan kemampuan model mengenali karakteristik visual kesegaran ikan yang lebih spesifik.



Gambar 4.16 Grafik Akurasi vs Epoch Transfer Learning

Berdasarkan Gambar 4.16, *training accuracy* menunjukkan tren peningkatan yang relatif konsisten sejak awal pelatihan. Pada epoch pertama, nilai *training accuracy* masih berada di sekitar 0,36, kemudian meningkat menjadi sekitar 0,47–0,50 pada epoch ke-4 sampai epoch ke-6. Setelah itu, peningkatan masih terjadi meskipun lebih lambat, hingga mencapai kisaran 0,58–0,60 pada epoch ke-16 sampai epoch ke-23. Kondisi ini menunjukkan bahwa layer klasifikasi mampu mempelajari hubungan antara fitur yang diekstraksi oleh backbone MobileNetV2 dan label kelas pada data latih.

Sementara itu, *validation accuracy sejak awal* sudah berada pada kisaran 0,43, lalu meningkat menjadi sekitar 0,50–0,53 pada epoch ke-3 sampai epoch ke-7. Pada pertengahan pelatihan, nilai ini sempat mengalami fluktuasi kecil, misalnya

turun dari sekitar 0,58 ke 0,55 di sekitar epoch ke-13, kemudian kembali meningkat. Nilai terbaik diperoleh pada epoch ke-17 dengan *validation accuracy* sebesar 0,6014 atau 60,14%. Setelah epoch tersebut, nilai *validation accuracy* cenderung stabil di kisaran 0,57–0,60 hingga akhir pelatihan.

Selisih antara *training accuracy* dan *validation accuracy* terlihat relatif kecil pada sebagian besar epoch. Hal ini menunjukkan bahwa *overfitting* berat belum terjadi. Namun, karena kedua kurva berhenti pada kisaran sekitar 0,60, dapat disimpulkan bahwa kemampuan model masih terbatas. Akibatnya, model belum mampu menangkap perbedaan visual antar kelas secara optimal apabila hanya mengandalkan fitur generik tanpa penyesuaian pada backbone.



Gambar 4.17 Grafik Loss vs Epoch Transfer Learning

Pada Gambar 4.17, training loss menurun secara konsisten dari sekitar 1,35 pada epoch pertama menjadi sekitar 0,86 pada epoch ke-23. Penurunan yang tajam terjadi pada awal pelatihan, terutama dari epoch pertama hingga sekitar epoch ke-6, yang menunjukkan bahwa model dengan cepat mempelajari pola dasar pada data latih. Setelah itu, penurunan berlangsung lebih lambat dan cenderung stabil. Kondisi ini mengindikasikan bahwa proses optimasi berjalan dengan baik dan model secara bertahap mendekati kondisi konvergen seiring bertambahnya jumlah epoch pelatihan.

Validation loss juga menunjukkan tren penurunan dari sekitar 1,15 pada awal pelatihan menjadi sekitar 0,86 pada akhir pelatihan. Meskipun demikian, beberapa fluktuasi kecil masih terlihat. Misalnya, *validation loss* sempat naik tipis

di sekitar epoch ke-4 hingga epoch ke-6, lalu kembali menurun. Kenaikan kecil juga masih muncul pada beberapa epoch akhir, misalnya di sekitar epoch ke-19 sampai epoch ke-22. Nilai minimum *validation loss* ditandai pada epoch ke-23, yaitu sekitar 0,86. Pola ini menunjukkan bahwa proses optimisasi berjalan stabil, tetapi perbaikan performa pada data validasi berlangsung terbatas. Jika kondisi ini dibiarkan tanpa penyesuaian fitur yang lebih spesifik, maka performa model akan cenderung berhenti pada tingkat akurasi yang sedang.



Gambar 4.18 Grafik Learning Rate Schedule Transfer Learning

Berdasarkan Gambar 4.18, *learning rate* pada tahap awal dipertahankan stabil di sekitar 3×10^{-4} . Nilai ini digunakan agar proses pembelajaran pada layer klasifikasi berlangsung cukup cepat, karena backbone tidak ikut dilatih. Menjelang akhir pelatihan, tepatnya setelah sekitar epoch ke-19, *learning rate* diturunkan menjadi sekitar $1,5 \times 10^{-4}$ melalui mekanisme *ReduceLROnPlateau*. Penurunan ini dilakukan karena perbaikan *validation loss* mulai melambat. Akibatnya, langkah pembaruan bobot dibuat lebih kecil agar proses optimisasi berlangsung lebih halus. Manfaatnya, model dapat menyesuaikan bobot akhir dengan lebih stabil tanpa menyebabkan perubahan yang terlalu agresif.



Gambar 4.19 Grafik Analysis Transfer Learning

Analisis *overfitting* pada Gambar 4.19 menunjukkan bahwa selisih antara *training accuracy* dan *validation accuracy* berada di sekitar nol pada sebagian besar epoch. Pada beberapa epoch awal, nilai gap masih negatif, yang berarti *validation accuracy* sempat sedikit lebih tinggi dibanding *training accuracy*. Kondisi ini wajar karena pada tahap awal model belum stabil sepenuhnya. Di pertengahan hingga akhir pelatihan, gap mulai bergerak kecil ke arah positif, misalnya di sekitar 0,01 hingga 0,03. Nilai tertinggi tampak berada di sekitar epoch ke-13 dan epoch ke-19, tetapi masih dalam rentang yang rendah. Hal ini menunjukkan bahwa gejala *overfitting* hanya muncul secara ringan. Dengan kata lain, masalah utama pada skenario ini bukan *overfitting* berat, melainkan keterbatasan kemampuan fitur generik dalam membedakan kelas yang memiliki kemiripan visual.

Tabel 4.8 Ringkasan Hasil Pelatihan Transfer Learning

Parameter	Transfer Learning
Total Epoch (Request)	30
Epoch Berjalan	23
Best Epoch	17
Best Validation Accuracy	60,14%
Early Stopping	Tidak
Min Validation Loss	≈ 0,86
Epoch Min Validation Loss	23

Berdasarkan Tabel 4.9, model pada skenario *transfer learning* mencapai *validation accuracy* terbaik sebesar 60,14% pada epoch ke-17, sedangkan *validation loss* minimum diperoleh pada epoch ke-23. Perbedaan antara epoch

akurasi terbaik dan epoch loss minimum menunjukkan bahwa setelah epoch ke-17, model masih mengalami penyesuaian kecil pada fungsi kerugian, tetapi peningkatan kemampuan klasifikasi secara langsung sudah tidak terlalu signifikan. Secara keseluruhan, hasil pada skenario ini menunjukkan bahwa proses pembelajaran berlangsung stabil, tetapi performa model masih terbatas. Hal ini disebabkan karena backbone MobileNetV2 belum disesuaikan dengan karakteristik citra mata ikan. Akibatnya, fitur yang digunakan masih terlalu umum, sehingga perbedaan visual antar kelas yang bersifat halus belum dapat dipisahkan secara optimal. Kondisi inilah yang kemudian menjadi dasar dilakukannya tahap *fine-tuning* pada skenario berikutnya.

4.4.4 Hasil Skenario 2: *Fine-tuning MobileNetV2*

Setelah tahap *transfer learning*, pelatihan dilanjutkan dengan proses *fine-tuning* dengan membuka sebagian layer pada backbone MobileNetV2. Pada tahap ini, bobot model tidak hanya diperbarui pada layer klasifikasi, tetapi juga pada sebagian layer konvolusi sehingga representasi fitur dapat disesuaikan dengan karakteristik citra mata ikan. Learning rate yang digunakan sebesar 1×10^{-5} , yang lebih kecil dibandingkan tahap sebelumnya. Penggunaan nilai ini bertujuan untuk menjaga stabilitas pembaruan bobot, sehingga penyesuaian fitur berlangsung secara bertahap tanpa merusak representasi awal hasil *pretraining*.




Gambar 4.20 Grafik Accuracy vs Epoch Fine-tuning

Berdasarkan Gambar 4.20, *training accuracy* meningkat secara konsisten sejak awal pelatihan. Pada epoch pertama, nilai *training accuracy* berada di sekitar

0,58, kemudian meningkat menjadi sekitar 0,65 pada epoch ke-5. Peningkatan berlanjut secara bertahap hingga mencapai kisaran 0,72–0,75 pada epoch ke-10 sampai ke-12, dan akhirnya mencapai sekitar 0,79–0,80 pada epoch akhir. Sementara itu, *validation accuracy* menunjukkan pola peningkatan yang lebih fluktuatif. Pada epoch awal (epoch 1–5), nilai *validation accuracy* berada pada kisaran 0,55–0,60, bahkan sempat mengalami penurunan pada sekitar epoch ke-3 hingga mendekati 0,55. Kondisi ini menunjukkan bahwa model masih dalam tahap penyesuaian terhadap fitur baru yang dilatih.

Setelah epoch ke-6, *validation accuracy* mulai meningkat secara lebih stabil hingga mencapai kisaran 0,65–0,68 pada epoch ke-10 sampai ke-12. Nilai terbaik diperoleh pada epoch ke-13 dengan *validation accuracy* sebesar 0,6948 (69,48%). Setelah epoch tersebut, nilai *validation accuracy* cenderung stagnan dan sedikit berfluktuasi di kisaran 0,65–0,68 hingga akhir pelatihan. Selisih antara *training accuracy* dan *validation accuracy* mulai terlihat meningkat setelah epoch ke-10. Hal ini menunjukkan bahwa model mulai mempelajari pola yang lebih spesifik pada data latih, namun sebagian pola tersebut tidak sepenuhnya tergeneralisasi pada data validasi. Akibatnya, mulai muncul tingkat overfitting tergolong ringan hingga sedang, namun belum menyebabkan penurunan *validation accuracy* secara drastis..



Gambar 4.21 Grafik Loss vs Epoch Fine-tuning

Pada Gambar 4.21, training loss menunjukkan penurunan yang konsisten dari sekitar 0,90 pada awal pelatihan menjadi sekitar 0,52 pada epoch akhir. Penurunan paling signifikan terjadi pada epoch 1–10, yang menunjukkan bahwa

model dengan cepat mempelajari pola utama dari data latih. Setelah fase tersebut, penurunan training loss berlangsung lebih lambat dan cenderung stabil. Kondisi ini menunjukkan bahwa proses optimasi berjalan dengan baik dan model secara bertahap mendekati kondisi konvergen.


Sebaliknya, validation loss menunjukkan pola yang lebih fluktuatif. Pada epoch awal, nilai validation loss sempat meningkat dari sekitar 0,86 ke 0,92 pada epoch ke-2, kemudian turun kembali. Setelah itu, validation loss secara umum menurun hingga mencapai nilai minimum sekitar 0,75 pada epoch ke-13. Fluktuasi yang terjadi mengindikasikan bahwa kemampuan generalisasi model masih mengalami penyesuaian terhadap data yang tidak digunakan selama proses pelatihan.

Setelah epoch ke-13, validation loss tidak lagi menunjukkan penurunan yang signifikan, bahkan cenderung berfluktuasi di kisaran 0,75–0,82. Kondisi ini menunjukkan bahwa model telah mencapai titik optimal pada epoch tersebut. Jika pelatihan dilanjutkan tanpa kontrol, maka model berpotensi mengalami *overfitting* karena training loss terus menurun sementara validation loss tidak ikut membaik. Temuan ini menunjukkan bahwa penggunaan mekanisme EarlyStopping dan ReduceLROnPlateau berperan penting dalam menjaga keseimbangan antara kemampuan pembelajaran model dan kemampuan generalisasinya terhadap data baru.



Gambar 4.22 Grafik Learning Rate Schedule Fine-tuning

Berdasarkan Gambar 4.23, *learning rate* pada awal pelatihan dipertahankan pada nilai 1×10^{-5} hingga sekitar epoch ke-10. Setelah itu, terjadi penurunan bertahap menjadi sekitar 5×10^{-6} , kemudian kembali diturunkan hingga mendekati $2,5 \times 10^{-6}$ pada epoch akhir. Penurunan ini dipicu oleh mekanisme *ReduceLROnPlateau* yang aktif ketika *validation loss* tidak menunjukkan perbaikan. Akibatnya, pembaruan bobot menjadi lebih kecil sehingga proses optimisasi berlangsung lebih halus. Manfaat dari mekanisme ini adalah mencegah perubahan bobot yang terlalu besar pada fase akhir pelatihan, sehingga model dapat mencapai kondisi konvergensi yang lebih stabil.



Gambar 4.23 Grafik Analysis Fine-tuning

Analisis *overfitting* menunjukkan bahwa pada epoch awal (epoch 1–3), selisih antara *training accuracy* dan *validation accuracy* masih kecil, bahkan sempat bernilai negatif. Hal ini menunjukkan bahwa model belum mengalami *overfitting*. Namun, mulai dari sekitar epoch ke-5, gap mulai meningkat ke kisaran 0,04–0,06, dan terus bertambah hingga mencapai sekitar 0,12–0,14 pada epoch akhir. Peningkatan gap ini menunjukkan bahwa model semakin menyesuaikan diri dengan data latih secara spesifik. Akibatnya, kemampuan generalisasi model sedikit menurun pada fase akhir pelatihan. Meskipun demikian, tingkat *overfitting* yang terjadi masih tergolong ringan dan tidak menyebabkan penurunan drastis pada *validation accuracy*. Kondisi ini menunjukkan bahwa *fine-tuning* berhasil meningkatkan kemampuan model tanpa menyebabkan *overfitting* yang berlebihan.

Tabel 4.9 Ringkasan Hasil Pelatihan Fine-tuning

Parameter	<i>Fine-tuning</i>
Total Epoch (Request)	30
Epoch Berjalan	19
Best Epoch	13
Best Validation Accuracy	69,48%
Early Stopping	Ya
Min Validation Loss	$\approx 0,75$
Epoch Min Validation Loss	13

Berdasarkan Tabel 4.10, proses pelatihan dihentikan pada epoch ke-19 menggunakan mekanisme *EarlyStopping*. Nilai performa terbaik diperoleh pada epoch ke-13, dengan *validation accuracy* sebesar 69,48% dan *validation loss* minimum sekitar 0,75. Penghentian pelatihan dilakukan karena setelah epoch tersebut tidak terdapat peningkatan signifikan pada *validation loss*. Jika pelatihan tetap dilanjutkan, maka risiko *overfitting* akan meningkat tanpa memberikan peningkatan performa yang berarti.

Secara keseluruhan, dapat disimpulkan bahwa transfer learning lebih unggul dalam hal stabilitas pelatihan dan kemampuan generalisasi awal, namun memiliki keterbatasan dalam menangkap fitur spesifik pada citra mata ikan. Sebaliknya, *fine-tuning* terbukti lebih efektif dalam meningkatkan performa klasifikasi melalui penyesuaian fitur yang lebih mendalam, meskipun disertai dengan risiko *overfitting* ringan. Oleh karena itu, pemilihan pendekatan pelatihan perlu mempertimbangkan keseimbangan antara stabilitas model dan kemampuan adaptasi terhadap karakteristik data.

Tabel 4.10 Perbandingan Performa Transfer Learning dan Fine-tuning

Parameter	Transfer Learning	<i>Fine-tuning</i>
Total Epoch (Request)	30	30
Epoch Berjalan	23	19
Best Epoch	17	13
Best Validation Accuracy	60,14%	69,48%
Min Validation Loss	$\approx 0,86$	$\approx 0,75$
Epoch Min Loss	23	13
Stabilitas Training	Tinggi (kurva smooth)	Sedang (lebih fluktuatif)
Stabilitas Validation	Cenderung stabil	Lebih fluktuatif
Overfitting	Sangat rendah (gap kecil)	Rendah–sedang (gap meningkat)

Parameter	Transfer Learning	<i>Fine-tuning</i>
Kemampuan Generalisasi	Baik	Sedikit menurun di akhir
Kemampuan Ekstraksi Fitur	Terbatas (fitur generik)	Lebih spesifik (fitur domain-aware)

Berdasarkan Tabel 4.11, dapat diamati bahwa pendekatan transfer learning menunjukkan stabilitas pelatihan yang lebih baik dibandingkan *fine-tuning*. Hal ini ditunjukkan oleh kurva akurasi dan loss yang cenderung lebih halus serta selisih antara training dan *validation accuracy* yang relatif kecil. Kondisi tersebut mengindikasikan bahwa model menghasilkan performa klasifikasi yang lebih baik pada data validasi. Namun, akibat dari penggunaan backbone yang sepenuhnya dibekukan, kemampuan model dalam menyesuaikan fitur terhadap karakteristik citra mata ikan menjadi terbatas, sehingga performa akurasi berhenti pada kisaran yang relatif rendah.

Sebaliknya, pada pendekatan *fine-tuning*, terjadi peningkatan performa yang cukup signifikan, ditandai dengan kenaikan *validation accuracy* hingga mencapai 69,48% serta penurunan *validation loss* yang lebih optimal. Hal ini menunjukkan bahwa pembukaan sebagian layer backbone memungkinkan model untuk mempelajari representasi fitur yang lebih spesifik terhadap domain data. Akibatnya, perbedaan visual yang bersifat halus, seperti kejernihan kornea dan refleksi cahaya pada mata ikan, dapat diidentifikasi dengan lebih baik.

Meskipun demikian, peningkatan kemampuan tersebut diikuti dengan munculnya indikasi *overfitting* ringan, yang terlihat dari meningkatnya gap antara training dan *validation accuracy* pada epoch akhir. Kondisi ini menunjukkan bahwa model mulai terlalu menyesuaikan diri terhadap data latih, sehingga kemampuan generalisasi sedikit menurun. Dengan kata lain, *fine-tuning* memberikan trade-off antara peningkatan akurasi dan penurunan stabilitas pelatihan.

Secara keseluruhan, penerapan *fine-tuning* memberikan peningkatan performa yang signifikan dibandingkan skenario *transfer learning*. Hal ini ditunjukkan oleh peningkatan *validation accuracy* dari sekitar 60% menjadi 69%. Peningkatan ini terjadi karena sebagian layer backbone diperbarui sehingga model mampu mempelajari fitur yang lebih spesifik terhadap karakteristik visual citra

mata ikan, seperti kejernihan kornea, refleksi cahaya, dan perubahan tekstur. Dengan demikian, *fine-tuning* terbukti efektif dalam meningkatkan kemampuan model untuk membedakan kelas dengan perbedaan visual yang bersifat halus, sekaligus tetap menjaga stabilitas proses pelatihan.


4.4.5 Explainable AI (Grad-CAM)

Pada penelitian ini, interpretasi model dilakukan menggunakan pendekatan *Explainable Artificial Intelligence (XAI)* dengan metode Grad-CAM (*Gradient-weighted Class Activation Mapping*). Metode ini digunakan untuk memvisualisasikan area pada citra yang memberikan kontribusi terbesar terhadap keputusan klasifikasi yang dihasilkan oleh model. Grad-CAM bekerja dengan memanfaatkan gradien pada layer konvolusi terakhir untuk menghasilkan peta aktivasi (*heatmap*) yang menunjukkan bagian citra yang menjadi fokus utama model selama proses prediksi. Area dengan intensitas tinggi (warna merah-kuning) menunjukkan kontribusi yang besar terhadap keputusan model, sedangkan area dengan intensitas rendah (warna biru) menunjukkan kontribusi yang lebih kecil.

Untuk memberikan analisis yang lebih komprehensif, visualisasi Grad-CAM ditampilkan dalam dua kondisi, yaitu:


1. Prediksi benar (*correct classification*) sebanyak tiga contoh
2. Prediksi salah (*misclassification*) sebanyak tiga contoh

Pendekatan ini digunakan untuk mengevaluasi apakah model memfokuskan perhatian pada area yang relevan, baik pada kondisi benar maupun salah.




Gambar 4.24 Grad-CAM pada Kelas *HighlyFresh* (Prediksi Benar)

Berdasarkan visualisasi Grad-CAM, area aktivasi dengan intensitas tertinggi terfokus pada bagian kornea dan pupil yang terlihat jernih serta memiliki refleksi cahaya yang kuat. Fokus aktivasi yang terpusat menunjukkan bahwa model berhasil mengenali karakteristik visual utama pada kelas HighlyFresh secara konsisten. Kondisi ini mengindikasikan bahwa tingkat kejernihan kornea dan pantulan cahaya menjadi indikator dominan yang digunakan model dalam menentukan tingkat kesegaran tinggi. Selain itu, distribusi perhatian model terlihat lebih stabil dan terarah dibandingkan kelas lainnya. Akibatnya, model mampu menghasilkan prediksi dengan confidence yang tinggi dan tingkat kesalahan yang lebih rendah. Temuan ini menunjukkan bahwa kelas HighlyFresh memiliki pola visual yang relatif lebih mudah dibedakan karena ciri kesegarannya masih sangat jelas dan kontras.



Gambar 4.25 Grad-CAM pada Kelas NotFresh (Prediksi Benar)


Pada kelas NotFresh, area aktivasi utama terlihat berada pada bagian mata yang cenderung lebih gelap, keruh, dan memiliki distribusi warna yang tidak merata. Model tidak hanya memfokuskan perhatian pada pusat pupil, tetapi juga pada area sekitar kornea yang menunjukkan perubahan tekstur dan penurunan kejernihan. Pola aktivasi tersebut menunjukkan bahwa model mampu menangkap indikasi degradasi visual yang berkaitan dengan penurunan kualitas ikan. Akibatnya, kondisi tidak segar dapat dikenali dengan cukup baik meskipun terdapat variasi pencahayaan pada citra. Dibandingkan kelas Fresh, distribusi fitur pada kelas NotFresh terlihat lebih konsisten sehingga proses klasifikasi menjadi lebih stabil.



Gambar 4.26 Grad-CAM pada Kelas Fresh (Prediksi Benar)


Pada kelas Fresh, distribusi aktivasi terlihat lebih menyebar dibandingkan kelas HighlyFresh dan NotFresh, terutama pada area refleksi cahaya dan sebagian kornea. Kondisi ini menunjukkan bahwa model belum menemukan satu fitur dominan yang benar-benar kuat, melainkan mempertimbangkan beberapa karakteristik visual secara bersamaan. Nilai confidence prediksi sebesar 51,49% menunjukkan bahwa model memang berhasil memberikan prediksi yang benar, namun tingkat keyakinannya masih relatif rendah. Hal ini mengindikasikan adanya ambiguitas visual antara kelas Fresh dengan kelas lainnya, khususnya HighlyFresh. Secara visual, kelas Fresh berada pada kondisi transisi sehingga tingkat kejernihan kornea, tekstur, dan refleksi cahaya masih memiliki kemiripan dengan kedua kelas di sekitarnya.

Selain itu, pengaruh intensitas pencahayaan menyebabkan area aktivasi terlihat memanjang dan kurang terpusat secara stabil. Akibatnya, model mengalami kesulitan dalam menentukan fitur yang paling dominan. Meskipun demikian, probabilitas kelas Fresh tetap menjadi nilai tertinggi dibandingkan kelas lain sehingga prediksi masih dikategorikan benar. Temuan ini menunjukkan bahwa tantangan utama pada kelas Fresh bukan hanya pada akurasi klasifikasi, tetapi juga pada kestabilan representasi fitur akibat karakteristik visual yang bersifat gradual.



Gambar 4.27 Grad-CAM pada Kasus Fresh Misclassification


Pada kasus ini, citra dengan label asli Fresh diprediksi sebagai HighlyFresh. Berdasarkan visualisasi Grad-CAM, model memfokuskan perhatian pada area kornea dan refleksi cahaya yang terlihat cukup terang. Intensitas aktivasi yang tinggi pada area tersebut menyebabkan model menginterpretasikan citra sebagai kondisi yang lebih segar dibandingkan label sebenarnya. Kondisi ini menunjukkan bahwa refleksi cahaya memiliki pengaruh yang sangat besar dalam proses pengambilan keputusan model. Akibatnya, peningkatan intensitas cahaya pada beberapa bagian kornea dapat menyebabkan pergeseran prediksi ke kelas HighlyFresh. Temuan ini memperlihatkan bahwa batas visual antara kelas Fresh dan HighlyFresh masih bersifat gradual sehingga sensitivitas terhadap pencahayaan menjadi cukup tinggi.



Gambar 4.28 Grad-CAM pada Kasus Fresh Misclassification

Pada kasus ini, citra HighlyFresh diprediksi sebagai NotFresh. Aktivasi model terlihat menyebar ke area sekitar mata yang memiliki tekstur lebih gelap dan kurang terfokus pada bagian kornea yang jernih. Kondisi tersebut menyebabkan model menangkap pola visual yang menyerupai karakteristik ikan tidak segar. Akibatnya, model gagal mengidentifikasi fitur dominan yang seharusnya

merepresentasikan tingkat kesegaran tinggi. Berdasarkan hasil analisis confusion matrix dan Grad-CAM, sebagian besar kesalahan klasifikasi tidak disebabkan oleh fokus model pada area yang tidak relevan, melainkan oleh kemiripan karakteristik visual antar kelas. Kelas Fresh merupakan kelas yang paling sulit dibedakan karena berada pada kondisi transisi antara Highly Fresh dan Not Fresh. Perbedaan tingkat kejernihan kornea, refleksi cahaya, dan tekstur mata sering kali terjadi secara bertahap sehingga batas visual antar kelas menjadi tidak tegas. Selain itu, variasi pencahayaan pada citra dapat memperkuat atau mengurangi refleksi cahaya yang digunakan model sebagai indikator kesegaran, sehingga berkontribusi terhadap terjadinya kesalahan klasifikasi.



Gambar 4.29 Grad-CAM pada Kasus Fresh Misclassification

Pada kasus ini, citra NotFresh diprediksi sebagai Fresh. Visualisasi Grad-CAM menunjukkan bahwa model memberikan perhatian yang cukup besar pada area refleksi cahaya di bagian atas kornea. Pantulan cahaya tersebut menyebabkan sebagian karakteristik visual tampak lebih menyerupai kondisi ikan yang masih segar. Akibatnya, model tidak sepenuhnya menangkap indikasi penurunan kualitas visual secara keseluruhan, seperti tingkat kekeruhan dan perubahan tekstur pada area mata ikan.

Kondisi ini menunjukkan bahwa refleksi cahaya dapat menjadi fitur yang bersifat ambigu karena mampu meningkatkan maupun menyesatkan proses klasifikasi apabila distribusinya tidak konsisten. Ketergantungan model terhadap area dengan kontras tinggi dapat menyebabkan sebagian informasi visual lain yang juga penting menjadi kurang diperhatikan. Hal tersebut menjelaskan mengapa

kesalahan klasifikasi masih dapat terjadi meskipun model telah menunjukkan performa yang cukup baik secara keseluruhan. Temuan ini juga mengindikasikan bahwa variasi pencahayaan merupakan salah satu faktor yang memengaruhi tingkat kesulitan klasifikasi kesegaran ikan berbasis citra.

Secara umum, hasil Grad-CAM menunjukkan bahwa model memfokuskan perhatian pada area yang secara biologis dan visual memang relevan terhadap indikator kesegaran ikan, yaitu kornea, pupil, dan refleksi cahaya. Temuan ini memperkuat bahwa keputusan model tidak dilakukan secara acak, melainkan berdasarkan fitur visual yang sesuai dengan karakteristik objek penelitian. Selain itu, visualisasi tersebut memberikan bukti bahwa model berhasil mempelajari pola-pola visual yang berkaitan dengan tingkat kesegaran ikan. Dengan demikian, interpretabilitas model meningkat dan validitas proses klasifikasi menjadi lebih dapat dipertanggungjawabkan.

Berdasarkan seluruh visualisasi Grad-CAM, diperoleh beberapa temuan utama sebagai berikut:


1. Model secara konsisten memfokuskan perhatian pada area mata ikan, khususnya kornea, pupil, dan refleksi cahaya, sehingga dapat disimpulkan bahwa model telah mempelajari fitur visual yang relevan terhadap tingkat kesegaran ikan.
2. Kesalahan klasifikasi umumnya tidak disebabkan oleh fokus model pada area yang tidak relevan, melainkan karena adanya kemiripan karakteristik visual antar kelas yang bersifat gradual.
3. Kelas Fresh menjadi kelas yang paling sulit diklasifikasikan karena berada pada kondisi transisi antara HighlyFresh dan NotFresh, sehingga batas visual antar kelas tidak terlihat secara tegas.
4. Refleksi cahaya menjadi fitur yang paling dominan dalam proses klasifikasi. Namun, variasi intensitas cahaya dan kondisi pencahayaan juga dapat menyebabkan distribusi perhatian model menjadi ambigu dan memengaruhi hasil prediksi.

Dengan demikian, Grad-CAM tidak hanya membantu menjelaskan alasan di balik prediksi model, tetapi juga menunjukkan bahwa tantangan utama klasifikasi terletak pada kemiripan fitur visual dan sensitivitas terhadap pencahayaan. Hal ini memperkuat interpretabilitas model sekaligus mendukung validitas hasil penelitian yang telah diperoleh. Visualisasi yang dihasilkan menunjukkan bahwa model secara konsisten memanfaatkan area mata ikan sebagai sumber informasi utama dalam proses klasifikasi. Temuan tersebut sejalan dengan teori yang menyatakan bahwa perubahan pada kornea, pupil, dan tingkat kejernihan mata merupakan indikator penting dalam penentuan kesegaran ikan. Oleh karena itu, hasil Grad-CAM memberikan bukti tambahan bahwa model telah mempelajari fitur yang relevan dengan tujuan penelitian dan tidak hanya bergantung pada pola yang bersifat acak.

4.5 Analisis Hasil dan Diskusi

4.5.1 Ringkasan Hasil Evaluasi Performa MobileNetV2

Berdasarkan hasil evaluasi pada data uji (*test set*), diperoleh perbandingan performa model antara skenario transfer learning dan *fine-tuning* sebagaimana ditunjukkan pada Gambar 4.30.



Gambar 4.30 Performa Model pada Data Uji

Berdasarkan Gambar 4.30, terlihat bahwa model dengan pendekatan *fine-tuning* secara konsisten menghasilkan performa yang lebih baik dibandingkan dengan model transfer learning pada seluruh metrik evaluasi yang digunakan, yaitu accuracy, precision, recall, dan F1-score. Peningkatan tersebut menunjukkan bahwa proses pembaruan sebagian layer backbone mampu meningkatkan kualitas representasi fitur yang dipelajari model. Fitur yang lebih spesifik memungkinkan model mengenali karakteristik visual kesegaran ikan dengan lebih baik dibandingkan fitur generik hasil *pretraining*. Dengan demikian, *fine-tuning* memberikan kontribusi positif terhadap kemampuan klasifikasi model secara keseluruhan.

Pada metrik accuracy, model transfer learning memperoleh nilai sebesar 0,5991, sedangkan model *fine-tuning* mencapai 0,6948. Peningkatan ini menunjukkan bahwa proses *fine-tuning* mampu meningkatkan kemampuan model dalam melakukan klasifikasi secara keseluruhan. Kondisi ini terjadi karena sebagian layer backbone diperbarui sehingga fitur yang dihasilkan menjadi lebih sesuai dengan karakteristik citra mata ikan. Akibatnya, model dapat mengenali pola visual dengan lebih tepat.

Pada metrik precision, model transfer learning memperoleh nilai sebesar 0,5990, sementara model *fine-tuning* mencapai 0,6855. Peningkatan precision menunjukkan bahwa kesalahan prediksi positif dapat dikurangi setelah dilakukan *fine-tuning*. Hal ini mengindikasikan bahwa model menjadi lebih selektif dalam menentukan kelas sehingga prediksi yang dihasilkan lebih akurat. Dengan berkurangnya jumlah prediksi yang salah, reliabilitas model dalam mengidentifikasi tingkat kesegaran ikan juga mengalami peningkatan.

Selanjutnya, pada metrik recall, model transfer learning memperoleh nilai sebesar 59,56%, sedangkan model *fine-tuning* mencapai 68,43%. Peningkatan recall menunjukkan bahwa model *fine-tuning* memiliki kemampuan yang lebih baik dalam mengidentifikasi seluruh sampel yang benar pada masing-masing kelas. Dengan kata lain, jumlah data yang berhasil dikenali dengan benar meningkat, terutama pada kelas yang sebelumnya sulit dibedakan.

Pada metrik F1-score, yang merupakan kombinasi antara precision dan recall, model transfer learning memperoleh nilai sebesar 0,5940, sedangkan model *fine-tuning* mencapai 0,6846. Peningkatan nilai ini menunjukkan bahwa model *fine-tuning* memiliki keseimbangan yang lebih baik antara kemampuan mendeteksi dan ketepatan prediksi. Nilai F1-score yang lebih tinggi menunjukkan bahwa peningkatan performa tidak hanya terjadi pada satu metrik tertentu, tetapi secara konsisten pada berbagai aspek evaluasi. Dengan demikian, model *fine-tuning* dapat dianggap lebih andal dalam melakukan klasifikasi kesegaran ikan dibandingkan model transfer learning.

Secara keseluruhan, peningkatan performa yang konsisten pada seluruh metrik menunjukkan bahwa penerapan *fine-tuning* memberikan dampak positif terhadap kualitas model. Permasalahan utama pada transfer learning, yaitu keterbatasan fitur yang masih bersifat generik, dapat diatasi dengan pembaruan sebagian layer backbone. Dengan demikian, model mampu mempelajari representasi fitur yang lebih spesifik terhadap karakteristik kesegaran ikan. Kemampuan adaptasi tersebut memungkinkan model mengenali perbedaan visual antar kelas secara lebih efektif dibandingkan pendekatan transfer learning standar.

Selain itu, penggunaan metrik berbasis macro-average memastikan bahwa evaluasi performa tidak hanya dipengaruhi oleh kelas dengan jumlah data yang lebih besar, tetapi juga mempertimbangkan performa pada seluruh kelas secara seimbang. Hal ini penting karena perbedaan visual antar kelas bersifat halus (subtle), sehingga evaluasi yang adil terhadap setiap kelas sangat diperlukan. Pendekatan ini memberikan gambaran yang lebih representatif mengenai kemampuan model dalam menangani seluruh kategori kesegaran ikan. Dengan demikian, hasil evaluasi yang diperoleh dapat digunakan sebagai dasar yang lebih objektif dalam menilai kualitas model.

Dengan demikian, dapat disimpulkan bahwa pendekatan *fine-tuning* tidak hanya meningkatkan nilai akurasi, tetapi juga meningkatkan stabilitas dan keseimbangan performa model dalam mengklasifikasikan seluruh kategori kesegaran ikan. Peningkatan tersebut terlihat secara konsisten pada metrik

accuracy, precision, recall, dan F1-score. Hasil ini menunjukkan bahwa proses penyesuaian sebagian layer backbone berhasil meningkatkan kemampuan representasi fitur pada domain kesegaran ikan. Oleh karena itu, *fine-tuning* dapat dianggap sebagai strategi yang efektif untuk mengoptimalkan performa MobileNetV2 pada tugas klasifikasi kesegaran ikan berbasis citra digital.

4.5.2 Analisis Confusion Matrix dan Pola Kesalahan

Confusion matrix digunakan untuk memberikan analisis yang lebih mendalam mengenai performa model pada setiap kelas kesegaran ikan. Berbeda dengan metrik accuracy yang hanya menunjukkan performa secara global, confusion matrix memungkinkan identifikasi distribusi prediksi benar dan kesalahan klasifikasi secara spesifik pada masing-masing kelas. Analisis ini menjadi penting karena perbedaan visual antar kelas kesegaran ikan bersifat gradual, sehingga diperlukan evaluasi yang lebih rinci untuk memahami pola kesalahan model.



Gambar 4.31 Confusion Matrix

Gambar 4.31(a) menunjukkan confusion matrix hasil klasifikasi pada skenario transfer learning, sedangkan Gambar 4.31(b) menunjukkan confusion matrix hasil klasifikasi setelah dilakukan fine-tuning. Pada kedua confusion matrix

tersebut, nilai diagonal menunjukkan jumlah prediksi yang benar, sedangkan nilai di luar diagonal menunjukkan jumlah kesalahan klasifikasi antar kelas. Semakin besar nilai pada diagonal utama, semakin baik kemampuan model dalam mengklasifikasikan kelas yang sesuai.

Berdasarkan Gambar 4.31(a), jumlah prediksi benar masih relatif terbatas pada beberapa kelas. Terlihat bahwa kesalahan klasifikasi cukup sering terjadi antara kelas Fresh dan HighlyFresh, serta antara Fresh dan NotFresh. Kondisi ini menunjukkan bahwa model transfer learning masih mengalami kesulitan dalam membedakan karakteristik visual yang memiliki kemiripan tinggi.

Sebaliknya, Gambar 4.31(b) menunjukkan peningkatan jumlah prediksi benar pada hampir seluruh kelas setelah dilakukan fine-tuning. Nilai pada diagonal utama terlihat lebih tinggi dibandingkan Gambar 4.31(a), terutama pada kelas Fresh dan HighlyFresh. Selain itu, jumlah kesalahan klasifikasi pada beberapa pasangan kelas juga mengalami penurunan. Hasil ini menunjukkan bahwa proses fine-tuning membantu model mempelajari representasi fitur yang lebih spesifik terhadap karakteristik citra mata ikan.

Untuk mempermudah interpretasi hasil confusion matrix, jumlah prediksi benar dan kesalahan klasifikasi pada masing-masing kelas dirangkum dalam bentuk tabel. Nilai prediksi benar menunjukkan jumlah citra yang berhasil diklasifikasikan sesuai label aktual, sedangkan nilai kesalahan menunjukkan jumlah citra yang diprediksi ke kelas lain.

1. Analisis Transfer Learning

Untuk mempermudah interpretasi confusion matrix, jumlah prediksi benar dan kesalahan klasifikasi pada masing-masing kelas dirangkum pada Tabel 4.11. Nilai prediksi benar menunjukkan jumlah citra yang berhasil diklasifikasikan sesuai label aktual, sedangkan nilai kesalahan menunjukkan jumlah citra yang diprediksi ke kelas lain.

Tabel 4.11 Analisis Confusion Matrix Transfer Learning

Kelas Aktual	Prediksi Benar	Salah ke Fresh	Salah ke HighlyFresh	Salah ke NotFresh
Fresh	72	–	31	29
HighlyFresh	123	27	–	27
NotFresh	77	25	28	–

Berdasarkan Tabel 4.11, model pada skenario transfer learning masih mengalami kesalahan klasifikasi yang cukup signifikan pada seluruh kelas. Pada kelas Fresh, hanya 72 citra yang berhasil diklasifikasikan dengan benar, sedangkan 31 citra diprediksi sebagai HighlyFresh dan 29 citra diprediksi sebagai NotFresh. Kondisi ini menunjukkan bahwa kelas Fresh merupakan kelas yang paling sulit dibedakan karena berada pada kondisi transisi antara ikan yang sangat segar dan tidak segar. Secara visual, kelas Fresh masih memiliki kornea yang relatif jernih dan refleksi cahaya yang cukup kuat seperti kelas HighlyFresh, namun pada beberapa citra juga mulai menunjukkan penurunan kejernihan yang menyerupai kelas NotFresh.

Pada kelas HighlyFresh, sebanyak 123 citra berhasil diklasifikasikan dengan benar, sedangkan masing-masing 27 citra diprediksi sebagai Fresh dan NotFresh. Kesalahan ini menunjukkan bahwa variasi pencahayaan dan refleksi cahaya pada area mata dapat memengaruhi proses klasifikasi. Beberapa citra HighlyFresh yang memiliki pencahayaan kurang optimal menyebabkan tingkat kejernihan kornea tampak menurun sehingga karakteristik visualnya menjadi lebih mirip dengan kelas Fresh maupun NotFresh.

Sementara itu, pada kelas NotFresh terdapat 77 citra yang berhasil diprediksi dengan benar, sedangkan 25 citra diprediksi sebagai Fresh dan 28 citra diprediksi sebagai HighlyFresh. Kesalahan tersebut menunjukkan bahwa beberapa citra NotFresh masih memiliki pantulan cahaya atau tekstur mata yang menyerupai

kondisi yang lebih segar. Akibatnya, model mengalami kesulitan dalam membedakan karakteristik visual yang bersifat gradual antar kelas.

Secara keseluruhan, pola kesalahan pada tahap transfer learning menunjukkan bahwa model masih bergantung pada fitur-fitur visual yang bersifat umum (*generic features*) karena seluruh layer backbone MobileNetV2 masih dibekukan. Akibatnya, model belum mampu menangkap perbedaan visual yang lebih spesifik, seperti tingkat kejernihan kornea, distribusi refleksi cahaya, dan perubahan tekstur pada mata ikan. Temuan ini menunjukkan bahwa transfer learning tanpa fine-tuning belum cukup untuk mengakomodasi karakteristik visual spesifik yang terdapat pada citra mata ikan.

2. Analisis *Fine-tuning*

Tabel 4.12 Analisis Confusion Matrix Fine-tuning

Kelas Aktual	Prediksi Benar	Salah ke Fresh	Salah ke HighlyFresh	Salah ke NotFresh
Fresh	91	–	18	23
HighlyFresh	135	25	–	17
NotFresh	80	30	29	–

Berdasarkan Tabel 4.12, jumlah prediksi benar meningkat pada hampir seluruh kelas setelah dilakukan fine-tuning. Pada kelas Fresh, jumlah prediksi benar meningkat dari 72 menjadi 91 citra, sedangkan kesalahan prediksi ke kelas HighlyFresh menurun dari 31 menjadi 18 citra. Peningkatan ini menunjukkan bahwa model menjadi lebih mampu membedakan karakteristik visual yang berada pada kondisi transisi, terutama tingkat kejernihan kornea dan distribusi refleksi cahaya yang membedakan kelas Fresh dengan HighlyFresh.

Pada kelas HighlyFresh, jumlah prediksi benar meningkat dari 123 menjadi 135 citra. Kesalahan prediksi ke kelas NotFresh juga menurun dari 27 menjadi 17 citra. Hasil tersebut menunjukkan bahwa fine-tuning memungkinkan model mempelajari fitur yang lebih spesifik terhadap karakteristik ikan yang sangat segar,

seperti kornea yang lebih jernih, pantulan cahaya yang lebih kuat, serta tekstur mata yang masih terlihat jelas. Dengan adanya penyesuaian pada sebagian layer backbone, representasi fitur yang dihasilkan menjadi lebih sesuai dengan karakteristik dataset penelitian.

Sementara itu, pada kelas NotFresh jumlah prediksi benar meningkat dari 77 menjadi 80 citra. Namun, kesalahan klasifikasi masih relatif tinggi, yaitu 30 citra diprediksi sebagai Fresh dan 29 citra diprediksi sebagai HighlyFresh. Kondisi ini menunjukkan bahwa beberapa citra NotFresh masih memiliki karakteristik visual yang menyerupai kelas yang lebih segar, terutama ketika terdapat refleksi cahaya yang cukup kuat atau tingkat kekeruhan kornea yang tidak terlalu jelas. Variasi pencahayaan selama proses pengambilan gambar juga dapat menyebabkan sebagian indikator visual kesegaran terlihat berbeda dari kondisi sebenarnya.

Secara keseluruhan, fine-tuning berhasil mengurangi kesalahan klasifikasi dibandingkan tahap transfer learning karena model tidak lagi hanya mengandalkan fitur-fitur umum hasil pretraining. Pembaruan sebagian layer backbone memungkinkan model mempelajari karakteristik visual yang lebih spesifik terhadap citra mata ikan, seperti kejernihan kornea, pola refleksi cahaya, dan perubahan tekstur permukaan mata. Meskipun demikian, kesalahan klasifikasi masih ditemukan pada kelas-kelas yang memiliki perbedaan visual yang bersifat gradual, sehingga pencahayaan dan kemiripan karakteristik antar kelas tetap menjadi tantangan dalam proses klasifikasi kesegaran ikan berbasis citra digital.

3. Perbandingan Pola Kesalahan

Berdasarkan hasil confusion matrix pada tahap transfer learning dan fine-tuning, dapat diidentifikasi beberapa pola kesalahan utama. Kesalahan klasifikasi yang paling dominan terjadi antara kelas Fresh dan HighlyFresh. Kondisi ini menunjukkan bahwa kedua kelas memiliki karakteristik visual yang sangat mirip, terutama pada tingkat kejernihan kornea dan refleksi cahaya yang masih terlihat cukup kuat. Akibatnya, model sering mengalami kesulitan dalam menentukan batas yang tegas antara kedua kelas tersebut.

Selain itu, kelas Fresh merupakan kelas yang paling sulit diklasifikasikan dibandingkan kelas lainnya. Secara visual, kelas Fresh berada pada kondisi transisi

antara HighlyFresh dan NotFresh sehingga memiliki karakteristik yang dapat menyerupai kedua kelas tersebut. Tingkat kejernihan mata, tekstur kornea, serta distribusi refleksi cahaya pada kelas Fresh tidak selalu menunjukkan perbedaan yang jelas. Kondisi ini menyebabkan model lebih rentan melakukan kesalahan prediksi pada kelas Fresh dibandingkan kelas lainnya.

Hasil analisis juga menunjukkan bahwa kelas HighlyFresh mengalami peningkatan performa yang paling signifikan setelah dilakukan fine-tuning. Peningkatan tersebut menunjukkan bahwa proses fine-tuning berhasil membantu model mempelajari karakteristik visual yang lebih spesifik terhadap citra mata ikan. Dengan membuka sebagian layer backbone MobileNetV2, model tidak lagi hanya mengandalkan fitur-fitur umum hasil pretraining, tetapi juga mampu menyesuaikan representasi fitur dengan karakteristik dataset penelitian.

Secara umum, perbedaan antar kelas kesegaran ikan bersifat gradual dan ditandai oleh perubahan visual yang relatif halus (*subtle visual differences*), terutama pada aspek kejernihan kornea, tekstur permukaan mata, serta distribusi refleksi cahaya. Oleh karena itu, fine-tuning diterapkan untuk meningkatkan kemampuan model dalam menangkap perbedaan visual tersebut. Hasil yang diperoleh menunjukkan adanya peningkatan jumlah prediksi benar pada seluruh kelas serta penurunan jumlah kesalahan klasifikasi dibandingkan tahap transfer learning. Temuan ini mengindikasikan bahwa representasi fitur yang dihasilkan setelah fine-tuning menjadi lebih spesifik terhadap domain citra mata ikan.

4. Kesimpulan Analisis Confusion Matrix

Secara keseluruhan, penerapan fine-tuning tidak hanya meningkatkan performa model secara global, tetapi juga memperbaiki distribusi kesalahan klasifikasi pada setiap kelas. Model menjadi lebih mampu membedakan karakteristik visual antar tingkat kesegaran ikan, terutama pada kelas yang memiliki kemiripan visual yang tinggi. Meskipun demikian, kesalahan klasifikasi masih ditemukan pada kelas Fresh karena karakteristik visualnya berada pada kondisi transisi antara HighlyFresh dan NotFresh. Hasil analisis confusion matrix menunjukkan bahwa peningkatan performa model tidak hanya tercermin dari nilai accuracy, tetapi juga dari berkurangnya jumlah kesalahan klasifikasi pada masing-

masing kelas. Temuan ini memperkuat bahwa strategi fine-tuning berperan penting dalam meningkatkan kemampuan generalisasi MobileNetV2 untuk tugas klasifikasi kesegaran ikan berbasis citra mata ikan.

4.5.3 Perbandingan Antar Skenario Pelatihan

Perbandingan antar skenario pelatihan dilakukan untuk mengevaluasi pengaruh penerapan *fine-tuning* terhadap performa model. Evaluasi difokuskan pada perbedaan kemampuan model dalam mencapai nilai *validation accuracy* terbaik pada masing-masing skenario. Analisis ini dilakukan untuk mengetahui sejauh mana pembaruan sebagian layer backbone mampu meningkatkan kualitas representasi fitur yang dipelajari model. Dengan membandingkan kedua skenario, efektivitas strategi *fine-tuning* dapat dinilai secara lebih objektif berdasarkan hasil yang diperoleh selama proses pelatihan dan validasi.

Berdasarkan hasil pelatihan, pada tahap transfer learning diperoleh *validation accuracy* sebesar 60,14% pada epoch ke-17. Nilai tersebut menunjukkan bahwa model telah mampu memanfaatkan fitur generik hasil *pretraining*, namun masih mengalami keterbatasan dalam membedakan karakteristik visual kesegaran ikan yang bersifat halus. Akibatnya, model cenderung kurang sensitif terhadap perbedaan antar kelas yang memiliki kemiripan visual, seperti kejernihan kornea, distribusi refleksi cahaya, dan perubahan tekstur.

Setelah dilakukan *fine-tuning*, performa model mengalami peningkatan dengan *validation accuracy* mencapai 69,48% pada epoch ke-23. Peningkatan ini menunjukkan bahwa pembukaan sebagian layer backbone memungkinkan penyesuaian representasi fitur secara lebih spesifik terhadap domain citra mata ikan. Dengan demikian, model tidak hanya mengandalkan fitur generik, tetapi juga mampu mempelajari pola visual yang lebih relevan.

Selisih performa antara kedua skenario mencapai sekitar 9,34 poin persentase. Peningkatan ini mengindikasikan bahwa penggunaan fitur generik tanpa penyesuaian belum cukup optimal untuk menangkap perbedaan visual yang bersifat subtle. Sebaliknya, melalui *fine-tuning*, sebagian layer konvolusi diperbarui menggunakan learning rate yang lebih kecil sehingga proses pembaruan bobot berlangsung secara lebih stabil. Dampaknya, fitur tingkat menengah dan tinggi

dapat disesuaikan dengan karakteristik data, sehingga kemampuan diskriminasi antar kelas meningkat.

Selain itu, hasil *fine-tuning* telah melampaui target akurasi sebesar 65%, sedangkan transfer learning masih berada di bawah target tersebut. Hal ini menunjukkan bahwa penyesuaian pada layer backbone memberikan kontribusi signifikan terhadap peningkatan performa model. Dari sisi proses pelatihan, *fine-tuning* memerlukan jumlah epoch yang lebih banyak untuk mencapai performa optimal. Namun, proses tersebut menghasilkan model dengan kemampuan generalisasi yang lebih baik, yang ditunjukkan oleh kestabilan performa pada data validasi.

Dengan demikian, dapat disimpulkan bahwa penerapan *fine-tuning* tidak hanya meningkatkan nilai akurasi, tetapi juga memperbaiki kemampuan model dalam memahami pola visual yang lebih kompleks. Oleh karena itu, *fine-tuning* dapat dianggap sebagai tahap yang krusial dalam pengembangan model klasifikasi kesegaran ikan berbasis citra. Hasil yang diperoleh menunjukkan bahwa penyesuaian sebagian layer backbone memberikan kontribusi nyata terhadap peningkatan kualitas representasi fitur yang digunakan model. Temuan ini sekaligus memperkuat bahwa transfer learning yang dikombinasikan dengan *fine-tuning* merupakan pendekatan yang efektif untuk mengatasi keterbatasan dataset dan karakteristik visual yang bersifat subtle pada klasifikasi kesegaran ikan.

4.5.4 Diskusi Efisiensi Parameter dan Kompleksitas Model

Untuk mengevaluasi efisiensi model yang diusulkan, dilakukan perbandingan dengan model pada penelitian sebelumnya yang menggunakan arsitektur MobileNetV1 MB-BE pada dataset yang sama. Analisis difokuskan pada dua aspek utama, yaitu akurasi klasifikasi dan jumlah parameter model. Kedua aspek tersebut dipilih karena dapat menggambarkan keseimbangan antara performa dan kebutuhan sumber daya komputasi.

Tabel 4.13 Perbandingan Kompleksitas Model

<i>Model</i>	<i>Akurasi</i>	<i>Jumlah Parameter</i>
<i>MobileNetV1 MB-BE [8]</i>	63,21%	3,16 juta
<i>MobileNetV2 Fine-tuning</i>	69,48%	2,59 juta

Berdasarkan Tabel 4.13, model MobilNetV2 yang diusulkan menghasilkan akurasi sebesar 69,48%, lebih tinggi dibandingkan MobileNetV1 MB-BE yang memperoleh akurasi sebesar 63,21%. Hasil tersebut menunjukkan peningkatan performa sebesar 6,27 poin persentase pada dataset yang sama. Peningkatan ini mengindikasikan bahwa MobileNetV2 memiliki kemampuan ekstraksi fitur yang lebih baik dibandingkan pendahulunya. Selain itu, penerapan *transfer learning* dan *fine-tuning* turut berkontribusi dalam meningkatkan kemampuan model untuk mengenali karakteristik visual kesegaran ikan.

Selain menghasilkan akurasi yang lebih tinggi, MobileNetV2 juga memiliki jumlah parameter yang lebih kecil dibandingkan MobileNetV1 MB-BE. MobileNetV2 memiliki sekitar 2,59 juta parameter, sedangkan MobileNetV1 MB-BE memiliki sekitar 3,16 juta parameter. Hal ini menunjukkan bahwa peningkatan performa yang diperoleh tidak diikuti oleh peningkatan kompleksitas model, sehingga MobileNetV2 mampu memanfaatkan parameter yang tersedia secara lebih efisien.

Hasil perbandingan menunjukkan bahwa peningkatan jumlah parameter bukan satu-satunya faktor yang menentukan keberhasilan klasifikasi. Efektivitas arsitektur dalam mengekstraksi dan merepresentasikan fitur visual juga berperan penting dalam menghasilkan performa yang baik. Dalam penelitian ini, MobileNetV2 mampu menghasilkan akurasi yang lebih tinggi meskipun menggunakan jumlah parameter yang lebih sedikit dibandingkan MobileNetV1 MB-BE.

Model MobileNetV2 yang diusulkan mampu mencapai performa yang kompetitif dengan jumlah parameter yang jauh lebih kecil dibandingkan ResNet50. Keunggulan tersebut menunjukkan bahwa peningkatan jumlah parameter tidak selalu menjadi satu-satunya faktor yang menentukan keberhasilan klasifikasi. Efektivitas arsitektur dalam memanfaatkan parameter yang tersedia juga berperan penting dalam menghasilkan performa yang baik. Dengan demikian, efisiensi model menjadi salah satu aspek penting yang perlu dipertimbangkan dalam pengembangan sistem klasifikasi berbasis *deep learning*.

Peningkatan performa MobileNetV2 dalam penelitian ini tidak hanya berasal dari arsitektur model, tetapi juga dari penerapan strategi *fine-tuning* yang memungkinkan penyesuaian representasi fitur terhadap karakteristik citra mata ikan. Melalui pembaruan sebagian layer *backbone*, model dapat mempelajari fitur yang lebih spesifik dibandingkan fitur generik hasil *pretraining*. Selain itu, hasil visualisasi Grad-CAM menunjukkan bahwa model memfokuskan perhatian pada area yang relevan, seperti kornea, pupil, dan refleksi cahaya. Temuan tersebut menunjukkan bahwa proses klasifikasi dilakukan berdasarkan fitur visual yang sesuai dengan indikator kesegaran ikan.

Secara keseluruhan, hasil perbandingan menunjukkan bahwa model yang diusulkan memiliki keseimbangan yang baik antara performa dan efisiensi. MobileNetV2 mampu meningkatkan akurasi dibandingkan penelitian sebelumnya yang menggunakan MobileNetV1 MB-BE, sekaligus mengurangi jumlah parameter model. Hasil ini menunjukkan bahwa optimasi melalui transfer learning dan fine-tuning berhasil meningkatkan kualitas representasi fitur tanpa menambah kompleksitas model. Dengan demikian, MobileNetV2 dapat dianggap sebagai alternatif yang efektif untuk klasifikasi kesegaran ikan karena mampu menghasilkan performa yang lebih baik dengan kebutuhan komputasi yang tetap efisien.

4.5.5 Diskusi Interpretabilitas Model Menggunakan Grad-CAM

Selain mengevaluasi performa model berdasarkan metrik klasifikasi, analisis juga dilakukan terhadap efisiensi model serta kemampuan interpretasi hasil prediksi. Evaluasi ini penting untuk memastikan bahwa model yang diusulkan tidak hanya memiliki performa yang baik, tetapi juga efisien secara komputasi dan dapat dijelaskan secara visual. Dalam pengembangan sistem berbasis kecerdasan buatan, aspek interpretabilitas menjadi faktor penting karena dapat meningkatkan transparansi proses pengambilan keputusan model. Oleh karena itu, penelitian ini tidak hanya berfokus pada peningkatan akurasi, tetapi juga pada kemampuan model untuk menghasilkan prediksi yang dapat dipahami.

Berdasarkan hasil eksperimen, model MobileNetV2 dengan *fine-tuning* menghasilkan *validation accuracy* sebesar 69,48%. Jika dibandingkan dengan

penelitian sebelumnya yang menggunakan arsitektur MobileNetV1 MB-BE dan memperoleh akurasi sebesar 63,21%, maka model yang diusulkan menunjukkan peningkatan performa sebesar 6,27 poin persentase. Selain peningkatan akurasi, MobileNetV2 juga memiliki jumlah parameter yang lebih kecil, yaitu sekitar 2,59 juta parameter dibandingkan 3,16 juta parameter pada MobileNetV1 MB-BE. Temuan ini menunjukkan bahwa model yang diusulkan tidak hanya lebih akurat, tetapi juga lebih efisien dari sisi kompleksitas komputasi.

Pada penelitian sebelumnya, MobileNetV1 MB-BE dirancang untuk meningkatkan kualitas representasi fitur melalui kombinasi bottleneck dan expansion convolution yang dipadukan dengan residual transition. Pendekatan tersebut terbukti mampu meningkatkan performa dibandingkan beberapa arsitektur lightweight lainnya. Namun demikian, akurasi yang dihasilkan masih berada di bawah 70%, sehingga masih terdapat ruang untuk peningkatan performa model. Kondisi ini menunjukkan bahwa fitur yang dipelajari masih dapat dioptimalkan lebih lanjut melalui strategi pelatihan yang lebih adaptif.

Sebaliknya, pada penelitian ini peningkatan performa diperoleh melalui penerapan *fine-tuning* pada MobileNetV2 yang memungkinkan sebagian layer backbone diperbarui selama proses pelatihan. Strategi tersebut memberikan kesempatan bagi model untuk menyesuaikan representasi fitur dengan karakteristik visual citra mata ikan yang digunakan dalam penelitian. Akibatnya, model dapat mempelajari pola visual yang lebih spesifik dibandingkan hanya mengandalkan fitur generik hasil *pretraining*. Hasil ini menunjukkan bahwa proses adaptasi fitur memiliki kontribusi yang signifikan terhadap peningkatan performa klasifikasi.

Dari sisi interpretabilitas, penelitian ini memanfaatkan metode Grad-CAM untuk memvisualisasikan area citra yang menjadi fokus perhatian model selama proses prediksi. Hasil visualisasi menunjukkan bahwa model secara konsisten memberikan perhatian pada area mata ikan, khususnya pada bagian kornea, pupil, dan refleksi cahaya. Area-area tersebut diketahui merupakan indikator visual utama yang sering digunakan dalam penilaian kesegaran ikan secara manual. Dengan demikian, visualisasi Grad-CAM memberikan bukti bahwa model memanfaatkan fitur yang relevan dengan karakteristik biologis objek penelitian.

Pada sampel yang berhasil diklasifikasikan dengan benar, aktivasi Grad-CAM terlihat terpusat pada area mata yang memiliki karakteristik visual dominan sesuai dengan tingkat kesegarannya. Hal ini menunjukkan bahwa model telah berhasil mempelajari fitur-fitur penting yang membedakan setiap kelas kesegaran. Sebaliknya, pada kasus kesalahan klasifikasi, perhatian model tetap terfokus pada area yang relevan, namun mengalami kesulitan dalam membedakan perbedaan visual yang sangat halus antar kelas. Kondisi tersebut mengindikasikan bahwa kesalahan prediksi lebih banyak dipengaruhi oleh kemiripan karakteristik visual dibandingkan kesalahan dalam menentukan area perhatian.

Temuan ini juga sejalan dengan hasil analisis confusion matrix yang menunjukkan bahwa kesalahan klasifikasi paling sering terjadi antara kelas Fresh dan HighlyFresh. Kedua kelas tersebut memiliki karakteristik visual yang sangat berdekatan, terutama pada tingkat kejernihan kornea dan distribusi refleksi cahaya. Akibatnya, model memerlukan representasi fitur yang lebih diskriminatif untuk membedakan kedua kelas secara konsisten. Meskipun demikian, hasil *fine-tuning* menunjukkan bahwa jumlah kesalahan klasifikasi dapat dikurangi dibandingkan skenario transfer learning tanpa pembaruan backbone.

Secara keseluruhan, penelitian ini menunjukkan bahwa peningkatan performa model tidak hanya bergantung pada pemilihan arsitektur CNN, tetapi juga pada strategi pelatihan dan kemampuan interpretasi yang digunakan. MobileNetV2 dengan *fine-tuning* mampu menghasilkan performa yang lebih baik sekaligus mempertahankan efisiensi model melalui jumlah parameter yang relatif kecil. Selain itu, penggunaan Grad-CAM memberikan transparansi terhadap proses pengambilan keputusan model sehingga hasil klasifikasi dapat dijelaskan secara visual. Dengan demikian, model yang diusulkan tidak hanya efektif dari sisi performa, tetapi juga memiliki tingkat interpretabilitas yang mendukung validitas hasil penelitian.

4.5.6 Diskusi Perbandingan Hasil Penelitian dengan Penelitian Terdahulu

Penelitian ini dikembangkan berdasarkan penelitian sebelumnya yang dilakukan oleh Prasetyo et al. [7] mengenai klasifikasi kesegaran mata ikan menggunakan arsitektur MobileNetV1 Bottleneck with Expansion (MB-BE).

Penelitian tersebut berhasil menunjukkan bahwa pendekatan berbasis Convolutional Neural Network (CNN) mampu digunakan untuk mengklasifikasikan tingkat kesegaran ikan berdasarkan citra mata. Selain itu, MB-BE dilaporkan sebagai salah satu model dengan performa terbaik pada dataset Freshness of Fish Eyes (FFE) dibandingkan beberapa arsitektur lightweight lainnya. Meskipun demikian, hasil yang diperoleh masih menunjukkan akurasi di bawah 70%, sehingga penulis penelitian tersebut menyatakan bahwa masih terdapat peluang untuk meningkatkan performa klasifikasi.

Salah satu temuan penting pada penelitian sebelumnya adalah adanya kesulitan model dalam membedakan karakteristik visual antar tingkat kesegaran yang memiliki kemiripan tinggi. Perbedaan kondisi mata ikan pada kategori HighlyFresh, Fresh, dan NotFresh sering kali hanya ditunjukkan oleh perubahan visual yang bersifat gradual. Kondisi tersebut menyebabkan proses ekstraksi fitur menjadi lebih kompleks karena model harus mampu mengenali perbedaan visual yang sangat halus. Oleh karena itu, diperlukan pendekatan yang mampu menghasilkan representasi fitur yang lebih sesuai dengan karakteristik domain citra mata ikan.

Untuk menjawab permasalahan tersebut, penelitian ini menerapkan strategi transfer learning dan *fine-tuning* pada arsitektur MobileNetV2. Berbeda dengan pendekatan sebelumnya yang berfokus pada modifikasi struktur arsitektur, penelitian ini menekankan pada proses adaptasi fitur melalui pembaruan sebagian layer backbone selama pelatihan. Pendekatan tersebut memungkinkan model menyesuaikan representasi fitur yang sebelumnya dipelajari dari dataset umum ke karakteristik visual yang lebih spesifik pada citra mata ikan. Dengan demikian, peningkatan performa diperoleh melalui proses pembelajaran yang lebih adaptif terhadap domain penelitian.

Hasil yang diperoleh menunjukkan bahwa *fine-tuning* memberikan kontribusi yang signifikan terhadap kemampuan model dalam membedakan kelas-kelas kesegaran yang memiliki kemiripan visual tinggi. Temuan ini menunjukkan bahwa kualitas representasi fitur tidak hanya ditentukan oleh kompleksitas arsitektur, tetapi juga oleh strategi pelatihan yang digunakan. Dengan kata lain, peningkatan performa dapat dicapai tanpa harus meningkatkan jumlah parameter

secara signifikan. Hal ini memperkuat bahwa proses adaptasi fitur merupakan salah satu faktor penting dalam pengembangan model klasifikasi citra berbasis *deep learning*.

Selain peningkatan performa klasifikasi, penelitian ini juga memberikan kontribusi pada aspek interpretabilitas model melalui penggunaan Grad-CAM. Penelitian sebelumnya berfokus pada pencapaian performa klasifikasi, namun belum memberikan penjelasan visual mengenai area citra yang digunakan model dalam mengambil keputusan. Pada penelitian ini, visualisasi Grad-CAM menunjukkan bahwa model secara konsisten memfokuskan perhatian pada area kornea, pupil, dan refleksi cahaya yang memang menjadi indikator utama kesegaran ikan. Temuan tersebut memberikan bukti bahwa proses klasifikasi dilakukan berdasarkan fitur visual yang relevan dengan karakteristik objek penelitian.

Secara keseluruhan, penelitian ini tidak hanya menghasilkan peningkatan performa dibandingkan penelitian terdahulu, tetapi juga memberikan pemahaman yang lebih mendalam mengenai proses pengambilan keputusan model. Kontribusi yang diberikan mencakup penerapan strategi *fine-tuning* untuk meningkatkan kemampuan adaptasi fitur serta penggunaan Grad-CAM untuk meningkatkan interpretabilitas hasil klasifikasi. Dengan demikian, penelitian ini berhasil memperluas temuan penelitian sebelumnya dan memberikan pendekatan yang lebih komprehensif dalam klasifikasi kesegaran ikan berbasis citra mata.

BAB V

SIMPULAN DAN SARAN

5.1 Simpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa arsitektur MobileNetV2 mampu digunakan untuk melakukan klasifikasi kesegaran ikan berdasarkan citra mata ikan. Melalui tahapan *Knowledge Discovery in Databases* (KDD), model berhasil mempelajari karakteristik visual yang berkaitan dengan tingkat kesegaran ikan, seperti kejernihan kornea, kondisi pupil, dan refleksi cahaya. Hasil penelitian menunjukkan bahwa indikator-indikator visual tersebut memiliki peran penting dalam membedakan tingkat kesegaran ikan secara otomatis menggunakan pendekatan *deep learning*.

Penerapan strategi *fine-tuning* memberikan kontribusi terhadap peningkatan kemampuan model dalam mengenali pola visual yang lebih spesifik pada dataset penelitian. Dibandingkan dengan pendekatan *transfer learning* yang hanya memanfaatkan fitur generik hasil *pretraining*, *fine-tuning* memungkinkan model menyesuaikan representasi fitur dengan karakteristik citra mata ikan. Temuan ini menunjukkan bahwa proses adaptasi fitur merupakan faktor penting dalam meningkatkan kualitas klasifikasi pada data yang memiliki perbedaan visual yang relatif halus.

Selain menghasilkan performa klasifikasi yang baik, model yang diusulkan juga menunjukkan efisiensi yang lebih baik dibandingkan penelitian sebelumnya yang menggunakan MobileNetV1 MB-BE. Hasil tersebut menunjukkan bahwa peningkatan performa tidak selalu harus diikuti oleh peningkatan kompleksitas model. Efektivitas arsitektur dalam memanfaatkan parameter yang tersedia serta penerapan strategi pelatihan yang tepat berperan penting dalam menghasilkan model yang efisien dan tetap kompetitif.

Hasil interpretasi menggunakan Grad-CAM menunjukkan bahwa model secara konsisten memfokuskan perhatian pada area yang relevan dengan indikator kesegaran ikan, yaitu kornea, pupil, dan refleksi cahaya. Temuan ini memperkuat bahwa proses klasifikasi dilakukan berdasarkan fitur visual yang sesuai dengan karakteristik objek penelitian. Meskipun masih ditemukan kesalahan klasifikasi

pada kelas yang memiliki kemiripan visual tinggi, penelitian ini menunjukkan bahwa kombinasi MobileNetV2 dan *fine-tuning* merupakan pendekatan yang efektif untuk klasifikasi kesegaran ikan berbasis citra mata ikan.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, beberapa saran dapat diajukan untuk pengembangan penelitian selanjutnya.

Pertama, penelitian selanjutnya disarankan untuk mengembangkan model hingga tahap implementasi pada sistem nyata, seperti aplikasi mobile atau perangkat berbasis *edge computing*. Hal ini penting karena pada penelitian ini model masih berada pada tahap eksperimen dan evaluasi. Dengan dilakukannya implementasi, performa model dapat diuji secara langsung pada kondisi lapangan yang memiliki variasi pencahayaan, sudut pengambilan gambar, dan lingkungan yang lebih kompleks. Dengan demikian, manfaat model dalam proses inspeksi kualitas ikan secara real-time dapat dievaluasi secara lebih komprehensif.

Kedua, penelitian selanjutnya disarankan untuk lebih memfokuskan pada penanganan variasi pencahayaan dan intensitas cahaya pada citra mata ikan. Hasil penelitian menunjukkan bahwa refleksi cahaya, kejernihan kornea, dan tekstur mata merupakan fitur visual yang berperan penting dalam proses klasifikasi. Namun, variasi pencahayaan yang tidak konsisten masih berpotensi menyebabkan kesalahan klasifikasi, terutama pada kelas yang memiliki karakteristik visual yang mirip. Oleh karena itu, penerapan teknik *preprocessing* yang lebih adaptif, seperti *brightness normalization*, *contrast enhancement*, atau *illumination correction*, dapat dipertimbangkan untuk meningkatkan stabilitas ekstraksi fitur dan kemampuan generalisasi model.

Ketiga, penelitian selanjutnya disarankan untuk menggunakan dataset yang lebih besar dan lebih beragam. Pada penelitian ini, dataset yang digunakan berasal dari satu sumber dataset publik dan masih memiliki distribusi kelas yang tidak sepenuhnya seimbang. Penambahan variasi data, baik dari sisi kondisi pencahayaan, sudut pengambilan gambar, kualitas citra, maupun jenis ikan yang berbeda, diharapkan dapat membantu model mempelajari pola visual yang lebih representatif serta meningkatkan kemampuan generalisasi pada kondisi nyata.

Keempat, penelitian selanjutnya disarankan untuk membandingkan MobileNetV2 dengan arsitektur yang lebih modern, seperti EfficientNetV2, Vision Transformer (ViT), dan ConvNeXt. Perbandingan tersebut dapat memberikan gambaran yang lebih komprehensif mengenai keunggulan dan keterbatasan masing-masing arsitektur dalam klasifikasi kesegaran ikan berbasis citra mata ikan, baik dari sisi performa maupun efisiensi komputasi.

Kelima, penelitian selanjutnya disarankan untuk menerapkan metode validasi yang lebih komprehensif, seperti *K-Fold Cross Validation* atau *Stratified K-Fold Cross Validation*. Pendekatan ini dapat memberikan evaluasi yang lebih representatif terhadap stabilitas performa model dibandingkan penggunaan satu skenario pembagian data, sehingga validitas hasil penelitian dapat ditingkatkan.

Keenam, penelitian selanjutnya disarankan untuk melakukan analisis kontribusi masing-masing komponen dalam proses pelatihan model, seperti *data augmentation*, *transfer learning*, dan *fine-tuning*. Analisis tersebut dapat dilakukan melalui pendekatan *ablation study* sehingga pengaruh setiap komponen terhadap performa model dapat diketahui secara lebih terukur dan sistematis.



DAFTAR PUSTAKA

- [1] E. Prasetyo, N. Suciati, N. P. Sutramiani, A. Adiananda, and A. P. W. K. Dewi, "DaFiF: A complete dataset for fish's freshness problems," 2024. doi: 10.1016/j.dib.2024.111016.
- [2] N. M. S. Iswari, Wella, and Ranny, "Fish freshness classification method based on fish image using k-Nearest Neighbor," in *Proceedings of 2017 4th International Conference on New Media Studies, CONMEDIA 2017*, 2017, pp. 87–91. doi: 10.1109/CONMEDIA.2017.8266036.
- [3] E. Suprayitno, "Kajian Kesegaran Ikan Di Pasar Tradisional Dan Modern Kota Malang," *JFMR-Journal Fish. Mar. Res.*, vol. 4, no. 2, pp. 289–295, Aug. 2020, doi: 10.21776/ub.jfmr.2020.004.02.13.
- [4] O. J. Fisher *et al.*, "Considerations, challenges and opportunities when developing data-driven models for process manufacturing systems," *Comput. Chem. Eng.*, vol. 140, 2020, doi: 10.1016/j.compchemeng.2020.106881.
- [5] M. A. Rayan, A. Rahim, M. A. Rahman, M. A. Marjan, and U. A. M. E. Ali, "Fish freshness classification using combined deep learning model," 2021. doi: 10.1109/ACMI53878.2021.9528138.
- [6] J. M. L. Valeriano and C. C. Hortinela, "Classification of Salmon Freshness In Situ Using Convolutional Neural Network †," *Eng. Proc.*, vol. 92, no. 1, 2025, doi: 10.3390/engproc2025092012.
- [7] E. Helmud, C. E. Widodo, and O. D. Nurhayati, "Image-Based Fish Freshness Classification Using Two-Phase Transfer Learning with Deep Learning Fusion Model," *J. Appl. Data Sci.*, vol. 6, no. 4, pp. 2974–2988, 2025, doi: 10.47738/jads.v6i4.988.
- [8] E. Prasetyo, R. Purbaningtyas, R. D. Adityo, N. Suciati, and C. Fatichah, "Combining MobileNetV1 and Depthwise Separable convolution bottleneck with Expansion for classifying the freshness of fish eyes," *Inf. Process. Agric.*, vol. 9, no. 4, pp. 485–496, 2022, doi: 10.1016/j.inpa.2022.01.002.
- [9] S. M. Hamidy, Y. Kuvvetli, Y. Sakarya, S. T. Özkütük, and Y. Özoğul, "Deep Learning-Based Prediction of Fish Freshness and Purchasability Using Multi-Angle Image Data," *Foods*, vol. 15, no. 1, p. 68, 2025, doi: 10.3390/foods15010068.
- [10] V. Naveen and S. Sountharajan, "A Lightweight Multimodal Framework With Dilated CNN Audio Modeling and SE-Enhanced MobileNetV2 for Real-Time Sentiment Analysis of Customer Product Reviews," *IEEE Access*, vol. 13, pp. 217825–217845, 2025, doi: 10.1109/ACCESS.2025.3648722.
- [11] K. N. Sudiardjo, I. N. Alam, W. Wijaya, and L. A. Wulandhari, "Diagnostic Uncertainty in Pneumonia Detection Using CNN MobileNetV2 and CNN from Scratch," 2024. doi: 10.1109/ICoABCD63526.2024.10704486.
- [12] S. Thirumaladevi, K. Veera Swamy, and M. Sailaja, "Improved transfer learning of CNN through fine-tuning and classifier ensemble for scene classification," 2022. doi: 10.1007/s00500-022-07145-1.
- [13] M. Banjaransari and A. Prahara, "Image Classification of Wayang Using Transfer Learning and Fine-Tuning of CNN Models," *Bul. Ilm. Sarj. Tek.*

- Elektro*, vol. 5, no. 4, pp. 632–641, 2023, doi: 10.12928/biste.v5i4.9977.
- [14] E. C. Medeiros, L. M. Almeida, and J. G. de A. T. Filho, “Computer vision and machine learning for tuna and salmon meat classification,” 2021. doi: 10.3390/informatics8040070.
 - [15] M. Fanfani, M. Marulli, and P. Nesi, “Addressing Domain Shift in Pedestrian Detection from Thermal Cameras without Fine-Tuning or Transfer Learning,” 2023. doi: 10.1109/SMARTCOMP58114.2023.00078.
 - [16] M. A. Sánchez-Medina, P. Batres-Mendoza, M. A. Solís-Arrazola, E. I. Guerra-Hernández, M. A. Sotelo-Figueroa, and A. Espinal, “A Comparative Study of Transfer Learning and Fine-Tuning for Facial Paralysis Image Classification,” 2025. doi: 10.1007/978-3-031-88279-1_6.
 - [17] N. K. Chauhan, K. Singh, S. Namdeo, and A. Muley, “An Evaluative Investigation of Deep Learning Models by Utilizing Transfer Learning and Fine-Tuning for Cervical Cancer Screening of Whole Slide Pap-Smear Images,” 2023. doi: 10.1109/CERA59325.2023.10455623.
 - [18] K. M. Mendez, L. Pritchard, S. N. Reinke, and D. I. Broadhurst, “Toward collaborative open data science in metabolomics using Jupyter Notebooks and cloud computing,” *Metabolomics*, vol. 15, no. 10, p. 125, 2019, doi: 10.1007/s11306-019-1588-0.
 - [19] A. V. Ambili, A. V. Senthil Kumar, and R. Latip, “Cnn-Mobilenetv2- Deep Learning-Based Alzheimer’S Disease Prediction and Classification,” *J. Theor. Appl. Inf. Technol.*, vol. 101, no. 9, pp. 3590–3600, 2023, [Online]. Available: <https://www.scopus.com/inward/record.uri?partnerID=HzOxMe3b&scp=85163166613&origin=inward>
 - [20] S. Chowdhury, S. Tisha, M. Rahman, and G. Hamerly, “Efficient Selective Pre-Training for Imbalanced Fine-Tuning Data in Transfer Learning,” 2024. doi: 10.1109/BigData62323.2024.10825627.
 - [21] A. Musaev, A. Anorboev, and J. M. Youn, “Optimized Epoch Selection Ensemble: Integrating Custom CNN and Fine-Tuned MobileNetV2 for Maling Dataset Classification,” *IEEE Access*, vol. 13, pp. 45623–45633, 2025, doi: 10.1109/ACCESS.2025.3547791.
 - [22] M. B. Yildiz, E. T. Yasin, and M. Koklu, “Fisheye freshness detection using common deep learning algorithms and machine learning methods with a developed mobile application,” *Eur. Food Res. Technol.*, vol. 250, no. 7, pp. 1919–1932, 2024, doi: 10.1007/s00217-024-04493-0.
 - [23] S. Biswas, C. Nahata, S. Ghosh, S. Sahoo, and D. Biswas, “Fish Freshness Detection Via Hybrid CNN-LSTM: An Interpretable Deep Learning Model,” 2025. doi: 10.1007/978-3-031-82706-8_37.
 - [24] H. Sanga, P. Saka, M. Nanded, K. N. Alpuri, and S. Nadella, “Tilapia Fish Freshness Detection Using CNN Models,” 2024. doi: 10.1007/978-3-031-56703-2_6.
 - [25] H. Bichri, A. Chergui, and M. Hain, “Image Classification with Transfer Learning Using a Custom Dataset: Comparative Study,” *Procedia Comput. Sci.*, vol. 220, pp. 48–54, 2023, doi: 10.1016/j.procs.2023.03.009.
 - [26] R. F. S. Peries, S. Adeeba, M. F. S. Ahamed, and B. T. G. S. Kumara, “AI-Driven Solutions for Automated Fish Freshness Classification Using CNN

- Architectures,” 2025. doi: 10.1109/SCSE65633.2025.11031016.
- [27] P.-H. Hoang, N.-T. Trinh, V.-M. Tran, and T.-T.-H. Phan, “Enhanced Fish Freshness Classification with Incremental Handcrafted Feature Fusion,” *arXiv Prepr.*, vol. arXi:2510., 2025, [Online]. Available: <http://arxiv.org/abs/2510.17145>
- [28] C. Balım, N. Olgun, and M. Çalışan, “Leveraging Feature Fusion of Image Features and Laser Reflectance for Automated Fish Freshness Classification,” *Sensors*, vol. 25, no. 14, 2025, doi: 10.3390/s25144374.
- [29] M. Hasan, N. Vasker, M. M. Hossain, M. I. Bhuiyan, J. Biswas, and M. R. Ahmmad Rashid, “Framework for fish freshness detection and rotten fish removal in Bangladesh using mask R-CNN method with robotic arm and fisheye analysis,” *J. Agric. Food Res.*, vol. 16, p. 101139, 2024, doi: 10.1016/j.jafr.2024.101139.
- [30] B. Biswas, D. Mandal, C. Paul, R. Debnath, A. D. Raha, and M. Gain, “Deep Learning for Fish Freshness Detection: An XAI Oriented Knowledge Validation Based Approach,” 2025. doi: 10.1109/ECCE64574.2025.11013117.
- [31] X. Sun *et al.*, “Colorimetric and fluorescent probe assisted by smartphone app for monitoring fish freshness,” *Food Chem.*, vol. 473, 2025, doi: 10.1016/j.foodchem.2025.143013.
- [32] D. F. Anas, I. Jaya, and Nurjanah, “Design and implementation of fish freshness detection algorithm using deep learning,” 2021. doi: 10.1088/1755-1315/944/1/012007.
- [33] Y. Yuan, B. Zhou, and Z. Wu, “Fish freshness detection based on an electronic nose and machine vision,” *Food Ferment. Ind.*, vol. 50, no. 24, pp. 313–320, 2024, doi: 10.13995/j.cnki.11-1802/ts.039633.
- [34] C. Shi, Z. Ji, J. Zhang, Z. Jia, and X. Yang, “Preparation and characterization of intelligent packaging film for visual inspection of tilapia fillets freshness using cyanidin and bacterial cellulose,” *Int. J. Biol. Macromol.*, vol. 205, pp. 357–365, 2022, doi: 10.1016/j.ijbiomac.2022.02.072.
- [35] R. Raju and T. M. Thasleema, “Nutrient Deficiency Detection and Yield Loss Prediction in Black Pepper Using U2Net and Ensemble of Shallow CNN and MobileNetV2,” *J. Plant Nutr. Soil Sci.*, vol. 189, no. 1, pp. 59–68, 2025, doi: 10.1002/jpln.70031.
- [36] E. T. Yasin, I. A. Ozkan, and M. Koklu, “Detection of fish freshness using artificial intelligence methods,” *Eur. Food Res. Technol.*, vol. 249, no. 8, pp. 1979–1990, 2023, doi: 10.1007/s00217-023-04271-4.
- [37] D. Kato, C. Gu, J. Yu, and C. Zhang, “Improving Fish Freshness Classification with Fish Eye Segmentation Guidance,” 2023. doi: 10.1109/GCCE59613.2023.10315518.
- [38] S. D. Febriana, G. A. Mutiara, and B. Erfianto, “E-Sniffer: Raw Meat Freshness Detection Tool Based on Odor Classification and Fuzzy Logic Utilizing Gas Fusion Sensor,” *Instrum. Mes. Metrol.*, vol. 24, no. 2, pp. 97–109, 2025, doi: 10.18280/i2m.240201.
- [39] T. Choudhury, A. Aryan, H. F. Mahdi, V. R. Arunachalaeshwaran, and T. Sarkar, “CNN-Based Freshness Grading of Mourala Fish (*Amblypharyngodon Mola*),” 2023. doi: 10.1007/978-981-19-7663-6_47.

- [40] G. Harriat Christa, J. Jesica, K. Anisha, and K. M. Sagayam, "CNN-based mask detection system using OpenCV and MobileNetV2," 2021. doi: 10.1109/ICSPC51351.2021.9451688.
- [41] A. Taheri-Garavand, A. Nasiri, A. Banan, and Y. D. Zhang, "Smart deep learning-based approach for non-destructive freshness diagnosis of common carp fish," *J. Food Eng.*, vol. 278, 2020, doi: 10.1016/j.jfoodeng.2020.109930.
- [42] N. Ben Salem, Y. Bennani, and T. Papastergiou, "Selective Fine-Tuning for Deep Transfer Learning," 2026. doi: 10.1007/978-981-95-4094-5_18.
- [43] V. Plotnikova, M. Dumas, and F. Milani, "Adaptations of data mining methodologies: A systematic literature review," *PeerJ Comput. Sci.*, vol. 6, pp. 1–43, 2020, doi: 10.7717/PEERJ-CS.267.
- [44] I. Gede Sujana Eka Putra, I. Ketut Gede Darma Putra, M. Sudarma, and A. A. K. O. Sudana, "Classification of Tuna Meat Grade Quality Based on Color Space Using Wavelet and k-Nearest Neighbor Algorithm," 2023. doi: 10.1109/ICSGTEIS60500.2023.10424189.
- [45] J. M. V. D. B. Jayasundara *et al.*, "Deep learning for automated fish grading," *J. Agric. Food Res.*, vol. 14, 2023, doi: 10.1016/j.jafr.2023.100711.
- [46] P. Heidarian *et al.*, "Cross-Domain Land Surface Temperature Retrieval via Strategic Fine-Tuning-Based Transfer Learning: Application to GF5-02 VIMI Imagery," *Remote Sens.*, vol. 17, no. 23, 2025, doi: 10.3390/rs17233803.
- [47] E. Lee, S. S. Lee, M. Lee, K. Kim, and S. J. Jang, "Strategic Improvements in CNN Accelerators: Optimizing PE Utilization for MobileNetV2," 2024. doi: 10.1109/ISOC62682.2024.10762664.
- [48] M. Rehan, M. S. I. Malik, and M. M. Jamjoom, "Fine-Tuning Transformer Models Using Transfer Learning for Multilingual Threatening Text Identification," *IEEE Access*, vol. 11, pp. 106503–106515, 2023, doi: 10.1109/ACCESS.2023.3320062.
- [49] J. P. Rodrigues, O. R. Pacheco, and P. L. Correia, "Seabream Freshness Classification Using Vision Transformers," 2024. doi: 10.1007/978-3-031-49018-7_36.
- [50] S. Aphale, A. Jha, and E. John, "High Accuracy Arrhythmia Classification using Transfer Learning with Fine-Tuning," 2022. doi: 10.1109/UEMCON54665.2022.9965693.
- [51] S. Golder *et al.*, "Lightweight and Trustworthy Deep Learning Model for Fish Freshness Detection: An XAI-Driven Approach," 2024. doi: 10.1109/ICCIT64611.2024.11022429.
- [52] M. Singla, K. Singh Gill, R. Chauhan, H. S. Pokhariya, and G. Sunil, "The Use of MobileNetV2 for Bag Classification Visualisation of a CNN model based on Deep Learning," 2024. doi: 10.1109/I2CT61223.2024.10543660.
- [53] I. N. A. Nastase, S. Moldovanu, K. C. Biswas, and L. Moraru, "Role of inter- and extra-lesion tissue, transfer learning, and fine-tuning in the robust classification of breast lesions," *Sci. Rep.*, vol. 14, no. 1, 2024, doi: 10.1038/s41598-024-74316-5.
- [54] A. Shabbir *et al.*, "Satellite and Scene Image Classification Based on Transfer Learning and Fine Tuning of ResNet50," *Math. Probl. Eng.*, vol.

- 2021, 2021, doi: 10.1155/2021/5843816.
- [55] X. Xu, X. Wang, Y. Ding, X. Zhou, and Y. Ding, "Integration of lanthanide MOFs/methylcellulose-based fluorescent sensor arrays and deep learning for fish freshness monitoring," *Int. J. Biol. Macromol.*, vol. 265, 2024, doi: 10.1016/j.ijbiomac.2024.131011.
 - [56] A. P. Bhopale and A. Tiwari, "An Application of Transfer Learning: Fine-Tuning BERT for Spam Email Classification," 2022. doi: 10.1007/978-3-030-82469-3_6.
 - [57] Y. Fan *et al.*, "Integrating EEM fluorescence spectroscopy with machine and deep learning models for multi-output prediction of fish freshness," *Appl. Food Res.*, vol. 5, no. 2, 2025, doi: 10.1016/j.afres.2025.101374.
 - [58] X. Wu *et al.*, "Prediction method of large yellow croaker (*Larimichthys crocea*) freshness based on improved residual neural network," *J. Food Meas. Charact.*, vol. 18, no. 4, pp. 2995–3007, 2024, doi: 10.1007/s11694-024-02381-5.
 - [59] Y. Lecun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015, doi: 10.1038/nature14539.
 - [60] R. Mahendran and G. P. Seneviratne, "Using CNN to Identify the Condition of Edible Fish," 2022. doi: 10.1109/ICITR57877.2022.9993419.
 - [61] P. J. Karim, S. R. Mahmood, and M. Sah, "Brain Tumor Classification using Fine-Tuning based Deep Transfer Learning and Support Vector Machine," *Int. J. Comput. Digit. Syst.*, vol. 13, no. 1, pp. 83–96, 2023, doi: 10.12785/ijcds/130108.
 - [62] Y. Wang *et al.*, "Transfer Learning in Physics-Informed Neural Networks: Full Fine-Tuning, Lightweight Fine-Tuning, and Low-Rank Adaptation," *Int. J. Mech. Syst. Dyn.*, vol. 5, no. 2, pp. 212–235, 2025, doi: 10.1002/msd2.70030.
 - [63] I. Nasri, A. Messaoudi, K. Kassmi, M. Karrouchi, and H. Snoussi, "Adaptive Fine-tuning for Deep Transfer Learning Based Traffic Signs Classification," 2021. doi: 10.1109/ISAECT53699.2021.9668592.
 - [64] M. Kumar, H. Khulbe, M. Z. Khan, and Vikas, "Skin Lesion 7 Class Classification using MobileNetV2 CNN," 2024. doi: 10.1109/ACET61898.2024.10730501.
 - [65] A. Davila, J. Colan, and Y. Hasegawa, "Bio-Inspired Fine-Tuning for Selective Transfer Learning in Image Classification," *IEEE Access*, vol. 13, pp. 129234–129249, 2025, doi: 10.1109/ACCESS.2025.3587524.
 - [66] J. Tang, Z. Zhu, and S. Guo, "Fishery migration under the influence of global warming," 2021. doi: 10.1088/1755-1315/631/1/012015.
 - [67] A. B. Deepa and V. Paul, "Brain Tumor Classification With Selective Fine Tuning Using Transfer Learning," *Sci. Technol. Asia*, vol. 30, no. 2, pp. 71–83, 2025, [Online]. Available: <https://www.scopus.com/inward/record.uri?partnerID=HzOxMe3b&scp=105008920322&origin=inward>
 - [68] A. Choopool *et al.*, "Evaluating Optimal Deep Learning Models for Freshness Assessment of Silver Barb Through Technique for Order Preference by Similarity to Ideal Solution with Linear Programming," *Computers*, vol. 14, no. 3, 2025, doi: 10.3390/computers14030105.

- [69] S. A. Sanjaya and S. A. Rakhmawan, "Face Mask Detection Using MobileNetV2 in the Era of COVID-19 Pandemic," in *2020 International Conference on Data Analytics for Business and Industry: Way Towards a Sustainable Economy, ICDABI 2020*, 2020, pp. 1–5. doi: 10.1109/ICDABI51230.2020.9325631.
- [70] A. Davila, J. Colan, and Y. Hasegawa, "Adaptive Transfer Learning for Surgical Tool Presence Detection in Laparoscopic Videos Through Gradual Freezing Fine-Tuning," *Int. J. Imaging Syst. Technol.*, vol. 35, no. 6, 2025, doi: 10.1002/ima.70218.
- [71] C. Prasetyo, Eko; Adityo, Raden Dimas; Suciati, Nanik; Fatichah, "The Freshness of the Fish Eyes Dataset," 2022, *Mendeley*. doi: 10.17632/XZYX7PBR3W.1.
- [72] F. Rasheed, A. A. Dar, S. Ahmad, and G. Hussain, "Comparative Analysis of Deep State-of-the-Art CNN Architectures Over Food-101 Dataset Using Transfer Learning and the Impact of Fine Tuning," 2026. doi: 10.1007/978-981-96-6095-7_20.
- [73] G. Halevi, H. Moed, and J. Bar-Ilan, "Suitability of Google Scholar as a source of scientific information and as a source of data for scientific evaluation—Review of the Literature," *J. Informetr.*, vol. 11, no. 3, pp. 823–834, 2017, doi: 10.1016/j.joi.2017.06.005.
- [74] J. A. Teixeira da Silva and S. Nazarovets, "The publish or perish, publish and perish, publish then perish, and now retract and perish cultures in academia," *Naunyn. Schmiedeberg's Arch. Pharmacol.*, vol. 399, no. 3, pp. 3115–3131, 2025, doi: 10.1007/s00210-025-04651-5.
- [75] Q. Duan, X. Xu, D. Li, W. Li, and C. Liu, "Non-destructive Detection of Fish Freshness Based on CHG-LDA," *Nongye Jixie Xuebao/Transactions Chinese Soc. Agric. Mach.*, vol. 52, no. 10, pp. 385–393, 2021, doi: 10.6041/j.issn.1000-1298.2021.10.040.
- [76] I. M. Zwetsloot, A. Kuiper, T. S. Akkerhuis, and H. de Koning, "Lean Six Sigma meets data science: Integrating two approaches based on three case studies," *Qual. Eng.*, vol. 30, no. 3, pp. 419–431, 2018, doi: 10.1080/08982112.2018.1434892.
- [77] R. K. Banoth and B. V. R. Murthy, "Soil Image Classification Using Transfer Learning Approach: MobileNetV2 with CNN," *SN Comput. Sci.*, vol. 5, no. 1, 2024, doi: 10.1007/s42979-023-02500-x.
- [78] Y. Wu, "A Study on Fish Image Classification via Multi-Model Ensemble and Data Augmentation: The Case of Philippine Ports," 2025. doi: 10.1109/CVIDL65390.2025.11086018.
- [79] R. Karmaker, M. A. Tinky, and S. Akter, "Deep Learning and Image Processing Approach for Fish Freshness Detection," 2024. doi: 10.1109/PEEIACON63629.2024.10800710.
- [80] E. Dilek and M. Dener, "Enhancement of Video Anomaly Detection Performance Using Transfer Learning and Fine-Tuning," *IEEE Access*, vol. 12, pp. 73304–73322, 2024, doi: 10.1109/ACCESS.2024.3404553.
- [81] C. Q. X. Poh, C. U. Ubeynarayana, and Y. M. Goh, "Safety leading indicators for construction sites: A machine learning approach," *Autom. Constr.*, vol. 93, pp. 375–386, 2018, doi: 10.1016/j.autcon.2018.03.022.

- [82] B. Jeyavathana R, K. Chellappan, and M. S. Ganeshan, "Attention-assisted ensemble CNN–MobileNetV2–transformer architecture for automated TB diagnosis," *Biomed. Signal Process. Control*, vol. 119, 2026, doi: 10.1016/j.bspc.2026.109778.
- [83] M. Rani and M. Kumar, "Efficient Human Activity Recognition Using a Hybrid MobileNetV2-CNN Model," *Natl. Acad. Sci. Lett.*, 2025, doi: 10.1007/s40009-025-01720-4.
- [84] Q. Ouyang, Z. Fan, H. Chang, M. Shoaib, and Q. Chen, "Analyzing TVB-N in snakehead by Bayesian-optimized 1D-CNN using molecular vibrational spectroscopic techniques: Near-infrared and Raman spectroscopy," *Food Chem.*, vol. 464, 2025, doi: 10.1016/j.foodchem.2024.141701.
- [85] N. Duklan, S. Kumar, H. Maheshwari, R. Singh, S. D. Sharma, and S. Swami, "CNN Architectures for Image Classification: A Comparative Study Using ResNet50V2, ResNet152V2, InceptionV3, Xception, and MobileNetV2," *SSRG Int. J. Electron. Commun. Eng.*, vol. 11, no. 9, pp. 11–21, 2024, doi: 10.14445/23488549/IJECE-V11I9P102.
- [86] N. K. Chauhan, D. Kumar, S. N. Gupta, A. Kumar, M. Kumar, and P. S. Chatterjee, "Evaluating Deep Learning Models for Brain Tumor Detection Utilizing Transfer Learning and Fine-Tuning Approach," 2025. doi: 10.1109/ESIC64052.2025.10962659.
- [87] J. Cui *et al.*, "A Chlorophyll-a Concentration Inversion Model Based on Adaptive Fine-Tuning Transfer Learning Method and Self-Attention Mechanism," *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.*, vol. 18, pp. 25357–25373, 2025, doi: 10.1109/JSTARS.2025.3611596.



LAMPIRAN

Lampiran A Turnitin Similarity Report

Lampiran B Form Konsultasi Bimbingan

Lampiran C Formulir Penggunaan Perangkat Kecerdasan Artifisial (AI)



UMN

UNIVERSITAS
MULTIMEDIA
NUSANTARA

JUSTIN STEPHEN_OPTIMASI MOBILENETV2_BAB1-5_FINAL
1.pdf

ORIGINALITY REPORT

19%

SIMILARITY INDEX

15%

INTERNET SOURCES

11%

PUBLICATIONS

9%

STUDENT PAPERS

PRIMARY SOURCES

1

kc.umn.ac.id

Internet Source

5%

2

Submitted to UPN Veteran Yogyakarta

Student Paper

1%

3

Riko Angga Bayu Kusuma -, Bambang Irawan -, Abdul Khamid -. "KLASIFIKASI PENYAKIT KULIT WAJAH MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK EFFICIENTNET-B3", Jurnal Informatika dan Teknik Elektro Terapan, 2026

Publication

1%

4

jurnal.umb.ac.id

Internet Source

<1%

5

Eko Fuji Pangestu -, Bambang Irawan -. "KLASIFIKASI PENYAKIT TANAMAN PADI MENGGUNAKAN METODE CONVOLUTIONAL NEURAL NETWORK DENGAN ARSITEKTUR MOBILNETV2", Jurnal Informatika dan Teknik Elektro Terapan, 2026

Publication

<1%

6

jurnal.utu.ac.id

Internet Source

<1%

7

Submitted to Telkom University

Student Paper

<1%

NUSANTARA

**Form Bimbingan Skripsi
Program Studi Information Systems
Semester Genap 2025/2026**



Nama : JUSTIN STEPHEN
NIM : 00000072126
Angkatan : 2022
Dosen Pembimbing : Monika Evelin Johan, S.Kom., M.M.S.I. (Pembimbing)

No	Tanggal	Jam	Keterangan	Tanggal Approval
1	22 Januari 2026	10:00	Membahas Struktur dan Rancangan pada Bab 1 Menggunakan Perbandingan Penelitian Terdahulu	15 Mei 2026 13:18
2	02 Februari 2026	10:00	Membahas Draft Thesis pada Bab 1-3, terkait pemilihan dan tujuan penggunaan model MobileNetV2	15 Mei 2026 13:18
3	06 Februari 2026	14:00	Membahas Progress Bab 1-3, Terkait penelitian terdahulu dan format penulisan	15 Mei 2026 13:18
4	23 Februari 2026	14:00	Membahas Lebih Rinci pada bab 1-2, Pada rumusan masalah dan tujuan penelitian	15 Mei 2026 13:18
5	17 Maret 2026	10:00	Membahas Bab 3 Terkait Metodologi Penelitian hingga teknik analisis data	15 Mei 2026 13:18
6	31 Maret 2026	14:00	Membahas Draft Thesis pada Bab 3 dan 4	15 Mei 2026 13:18
7	14 April 2026	16:00	Membahas Keseluruhan Laporan dari bab 1 sampai 5	15 Mei 2026 13:18
8	07 Mei 2026	10:00	Membahas Bab 4 dan 5	15 Mei 2026 13:18

FORMULIR PENGGUNAAN PERANGKAT KECERDASAN ARTIFISIAL (AI)

Nama Lengkap : Justin Stephen

NIM : 00000072126

Program Studi : Sistem Informasi

Judul Laporan/Tugas : Optimasi MobileNetV2 Menggunakan Strategi *Fine-tuning* untuk

Klasifikasi Kesegaran Ikan Berbasis Citra Digital

No	Nama Tool AI	Alamat Web/Url	Prompt	Tanggal Akses	Output yang dihasilkan
1	ChatGPT	https://chatgpt.com/share/6a07329a-c050-83ec-beb6-1a8d5aeca02a	Bagaimana cara membuat penulisan abstrak penelitian CNN agar lebih ringkas dan akademik?	15 May 2026	
2	ChatGPT	https://chatgpt.com/share/6a07329a-c050-83ec-beb6-1a8d5aeca02a	Tolong bantu perbaiki penjelasan hasil <i>fine-tuning</i> MobileNetV2 agar lebih formal untuk penulisan skripsi	15 May 2026	
3	ChatGPT	https://chatgpt.com/share/6a07329a-c050-83ec-beb6-1a8d5aeca02a	Apa penjelasan yang tepat untuk <i>overfitting</i> ringan pada model CNN	15 May 2026	

			dalam penelitian klasifikasi citra?		
4	ChatGPT	https://chatgpt.com/share/6a07329a-c050-83ec-beb6-1a8d5aeca02a	Tolong bantu membuat kalimat kesimpulan penelitian agar lebih sesuai dengan format artikel jurnal	15 May 2026	
5	ChatGPT	https://chatgpt.com/share/6a07329a-c050-83ec-beb6-1a8d5aeca02a	Bagaimana cara menjelaskan hasil Grad-CAM pada klasifikasi kesegaran ikan agar lebih mudah dipahami?	15 May 2026	